Машинное обучение

Сорокоумов П.С.

КНТ МФТИ

2026 г.

Тема 1

Условия получения зачёта

Общая направленность

Полезные ссылки

Краткие сведения из теории вероятности

Условия получения зачёта

Лекции
Практика
Теория

Получение зачёта

Курс состоит из еженедельных занятий: лекций, 9 практических работ, сдачи теории.

Для получения зачёта нужно:

- сдать все практические работы;
- ответить на контрольные вопросы по каждой из них;
- сдать теорию.

Сдача практики, начиная с третьей недели, проводится в конце занятия.

Темы, изучаемые на лекциях: обучение с учителем

1. Постановка задач в машинном обучении: модель, выборка, параметры, гиперпараметры, функции потерь. Обучение с учителем и без учителя;
2. Регрессия: линейная, полиномиальная, ридж-, LASSO; RANSAC, сплайны, ядерное сглаживание;
3. Классификация:
   - линейная: пороговая, метод опорных векторов (SVM);
   - вероятностная: наивный байес, логистическая регрессия, нормальный дискриминантный анализ, линейный дискриминант Фишера. Смеси распределений: EM-алгоритм, гауссовы смеси, сети радиальных базисных функций;
   - метрическая: метод ближайшего соседа и его вариации;
   - логическая: решающий список, решающее дерево, их упрощение;
   - каскадирование классификаторов: бустинг (AdaBoost), бэггинг, случайный лес.

Темы, изучаемые на лекциях: обучение без учителя

4. Обучение без учителя:
   - снижение размерности: анализ главных компонентов, анализ независимых компонентов;
   - кластеризация: графовые, метрические, статистические методы; иерархические подходы; качество кластеризации;
   - распознавание выбросов: минимальный определитель ковариации, одноклассовый метод опорных векторов, локальный уровень выброса;
   - шкалирование: метод Ньютона-Рафсона, карта Кохонена;

Темы, изучаемые на лекциях: нейросетевые модели

5. Нейросетевые модели:
   - формальный нейрон, неглубокие нейронные сети: многослойный персептрон, сеть Хопфилда;
   - обучение сетей: градиентный спуск (стохастический, импульс, Adam), регуляризация;
   - базовые глубокие сети: свёрточные сети, остаточные сети, реккурентные сети, трансформеры, графовые сети;
   - генеративные сети: состязательные сети, нормализующие потоки, вариационные автокодировщики, диффузионные модели;

6. Обучение с подкреплением: модель многорукого бандита, Q-обучение, глубокое Q-обучение, SARSA, актёр-критик, PPO.

Практические работы (1)

9 практических работ:

1. регрессия;
2. простейшие виды классификации;
3. многослойные персептроны;
4. кластеризация числовых и текстовых данных;
5. свёрточные сети;
6. автокодировщики;
7. трансформеры;
8. генеративные состязательные сети;
9. обучение с подкреплением.

По каждой будут высланы материалы: описание работы и набросок кода на Python, на котором можно основывать своё решение.

Можно писать на любом языке, но рекомендуется Python; примеры будут на scikit-learn и pytorch (в нейросетевой части).

Практические работы (2)

По каждой практической работе нужно:

- выполнить по высланному описанию подготовительные упражнения;
- разработать программу по выбранному индивидуальному варианту задания;
- сдать программу;
- ответить на контрольные вопросы, имеющиеся в описании работы.

Непосредственно приём работы выполняется очно; в исключительных случаях — удалённо, по видеосвязи; можно присылать работы для предварительной проверки на почту petr.sorokoumov@yandex.ru или задавать по ней же вопросы.

Практические работы (3)

Необходимо понимать весь сдаваемый код.

Если при сдаче учащийся не сможет объяснить смысл какой-то части кода, сдача прекращается на одну неделю (до следующего занятия); на зачётной неделе и за неделю до неё — на 2 дня.

Если смысл каких-то примеров кода неясен, нужно обязательно разобраться с ним до начала сдачи.

Сдача теории

В середине курса (примерно на 9 неделе) и в конце (на зачётной неделе) состоится сдача теоретических вопросов по пройденному лекционному материалу. Конкретные даты определим дополнительно.

На каждой сдаче всем будут выданы один или два вопроса: один для тех, кто сдал работы 1–5 (в первую сдачу) либо работы 6–9 (во вторую сдачу), два — для остальных.

Списки вопросов будут доступны за 2 недели до каждого этапа сдачи; на подготовку каждого вопроса даётся 30 минут. При ответе можно пользоваться своими записями, сделанными за эти 30 минут, и ничем больше.

Общая направленность

Классификация
Пример регрессии
Пример кластеризации
Пример обучения с подкреплением
Проблемы машинного обучения

Базовая идея машинного обучения

Жаргонное описание: «построение алгоритмов, способных обучаться».

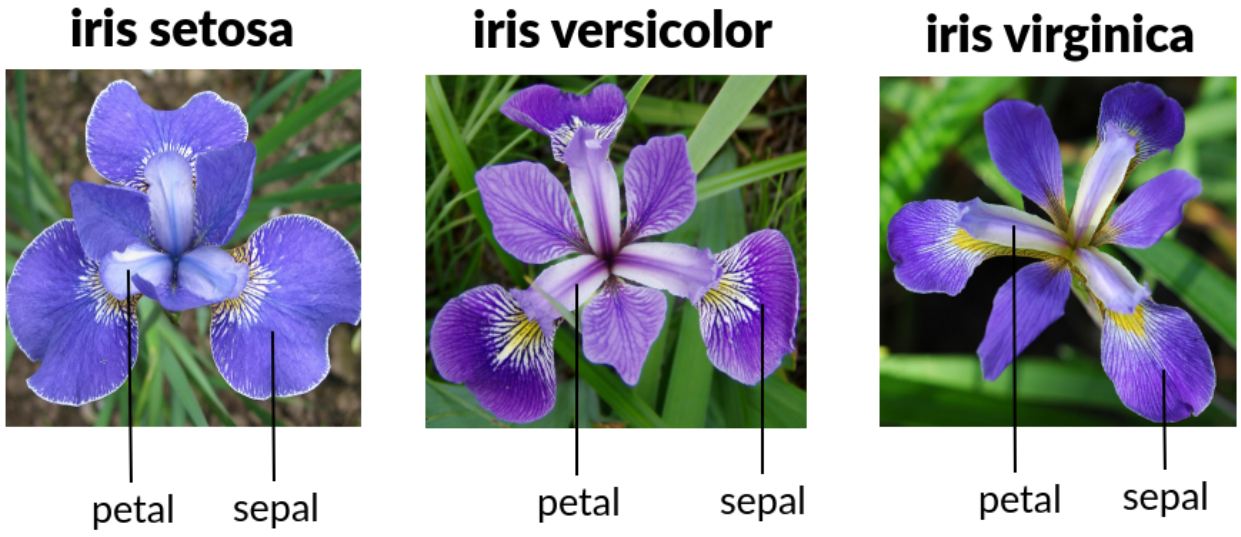
Более точное: построение алгоритмов для **восстановления общих закономерностей по частным примерам**; т.е. нужно выявить по имеющимся заведомо неполным данным взаимосвязи, которые есть не только в них, но и во всех других случаях.

Обычно машинное обучение используется для задач, которые сложно описать формально, но просто дать несколько примеров решений и попытаться обобщить их.

По сути это **подгон под данные**, но с пониманием допущений и ограничений.

Примеры задач: классификация

По множеству объектов, принадлежащих к нескольким группам (классам), надо построить алгоритм поиска класса для произвольного объекта

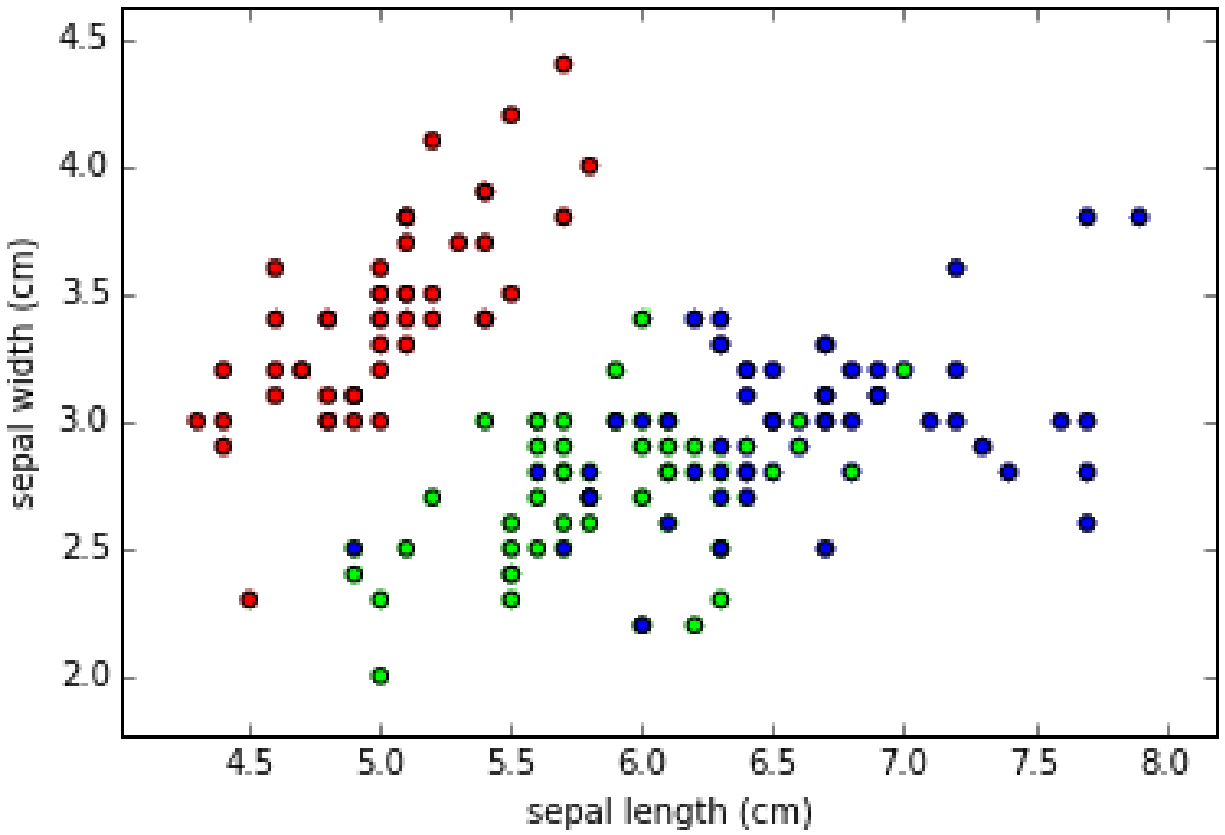


Ирисы Фишера[1]: пусть измерены по 4 параметра у 150 цветков ирисов трёх видов: длина и ширина наружной (sepal) и внутренней (petal) долей околоцветника. Можно ли, измерив эти же четыре параметра у другого цветка ириса одного из этих видов, найти этот вид?

[1] Fisher R. The use of multiple measurements in taxonomic problems // Annals of Eugenics. 7 (2): 1936.: pp. 179–188.

Визуализация по двум параметрам

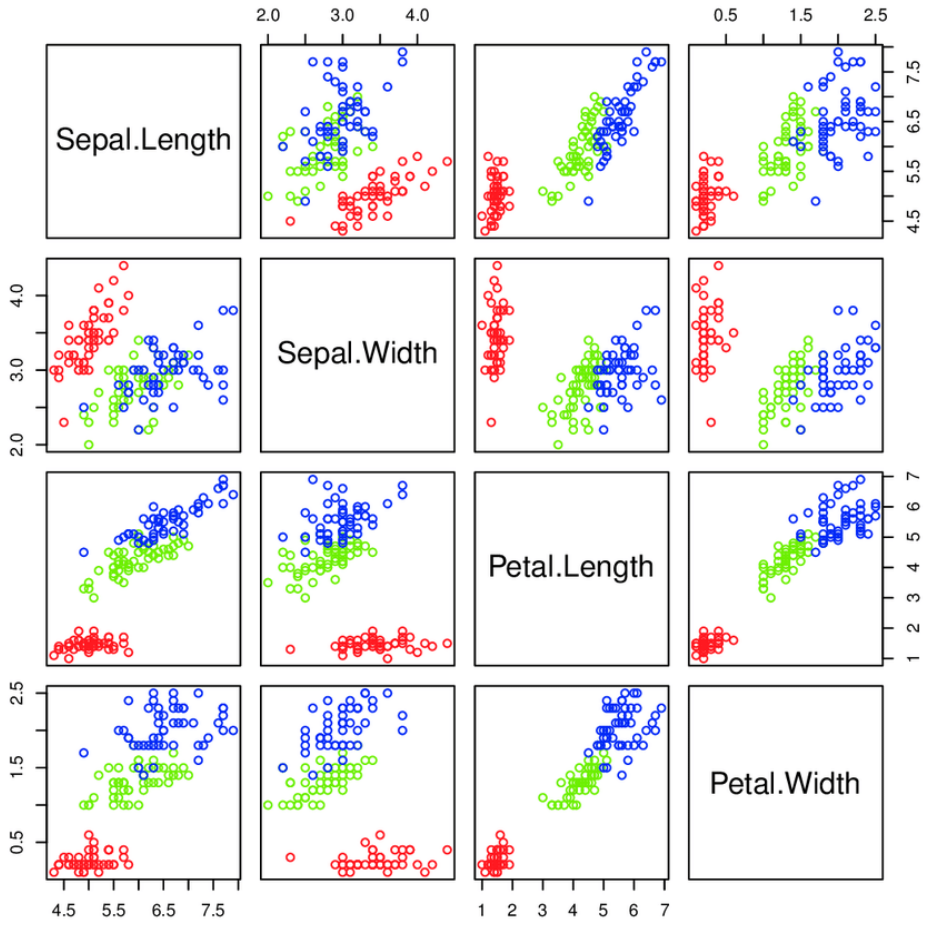
Если взять два параметра (sepal length и sepal width), получим следующую диаграмму разброса:



Вопрос: как по этим двум параметрам предсказывать вид лучше всего?

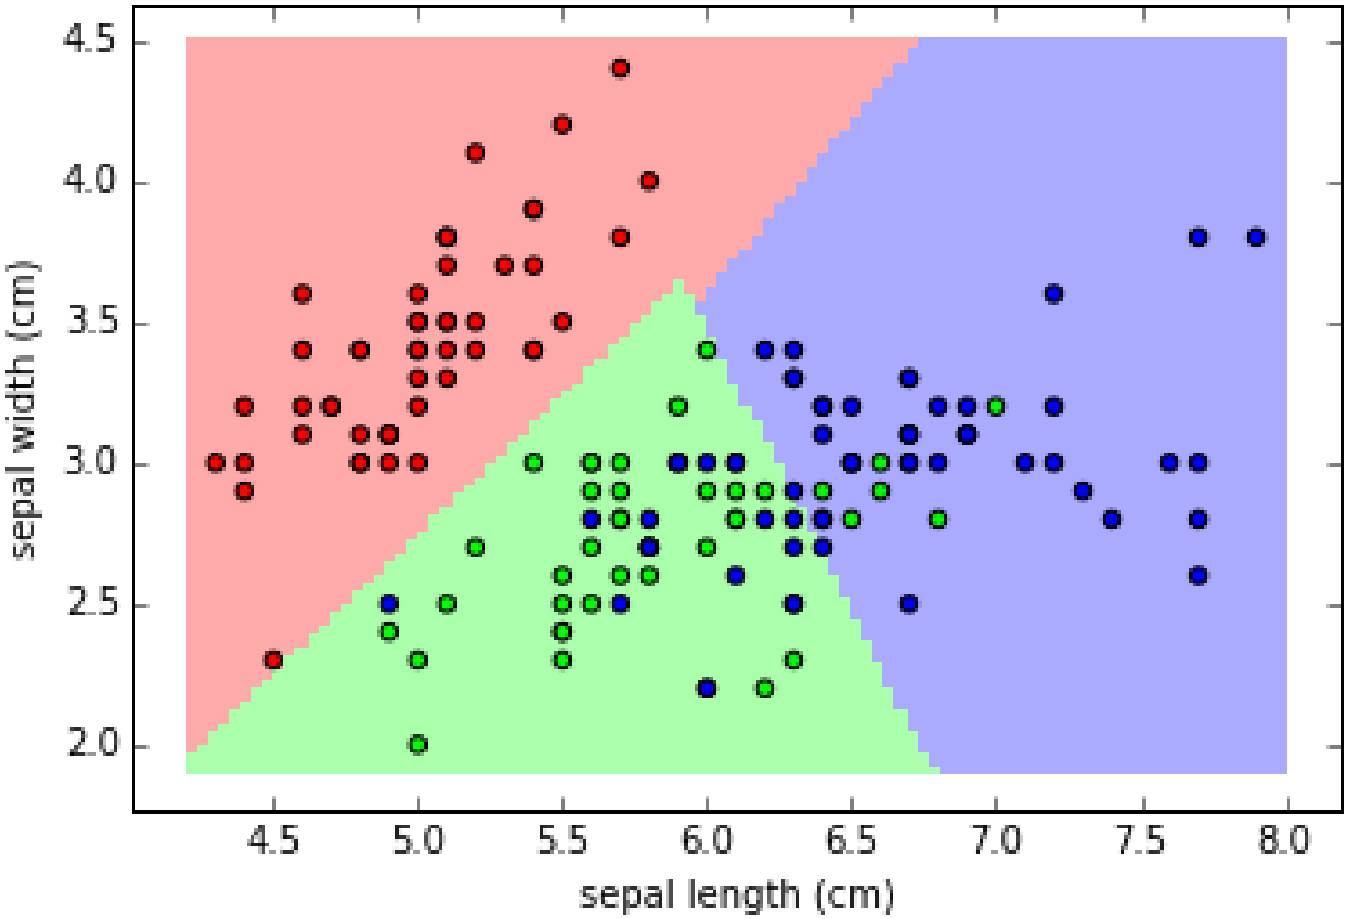
Визуализация по всем четырём параметрам

Вопрос: насколько поможет использование всех четырёх параметров?



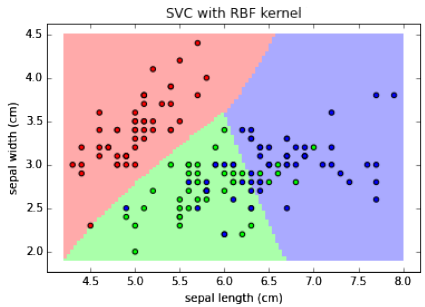
Пример решения

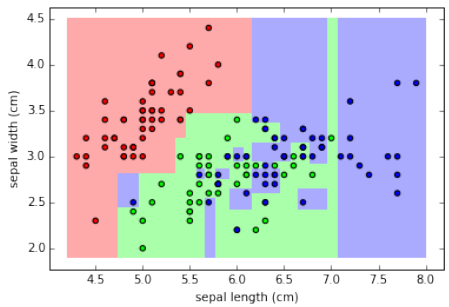
Решение задачи классификации системой опорных векторов с линейным ядром

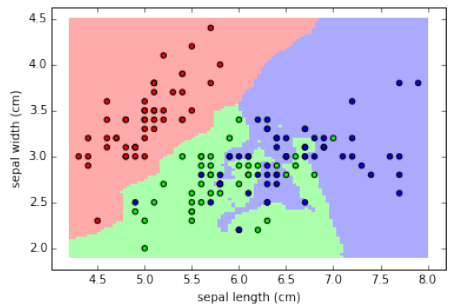


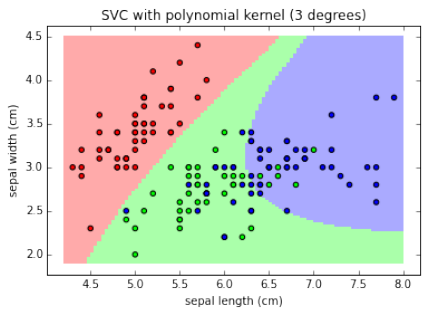
Какое из возможных решений предпочесть?

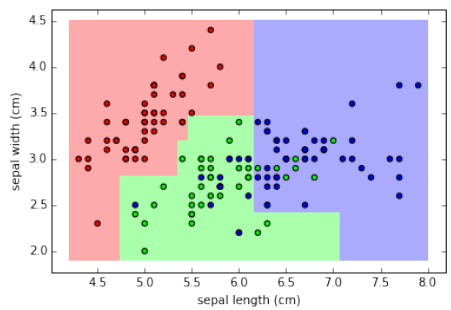
Возможны и другие решения:







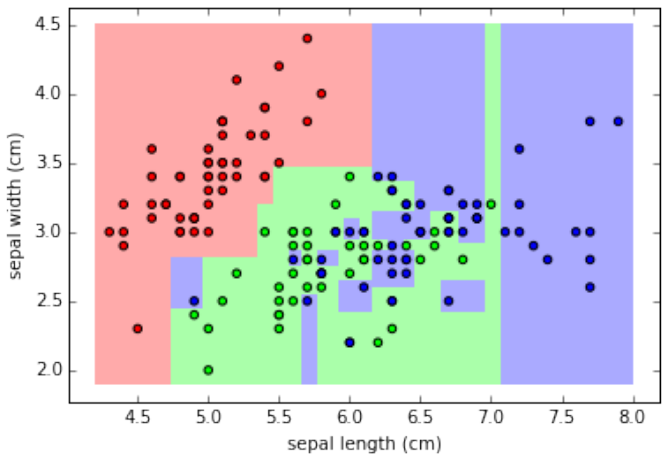


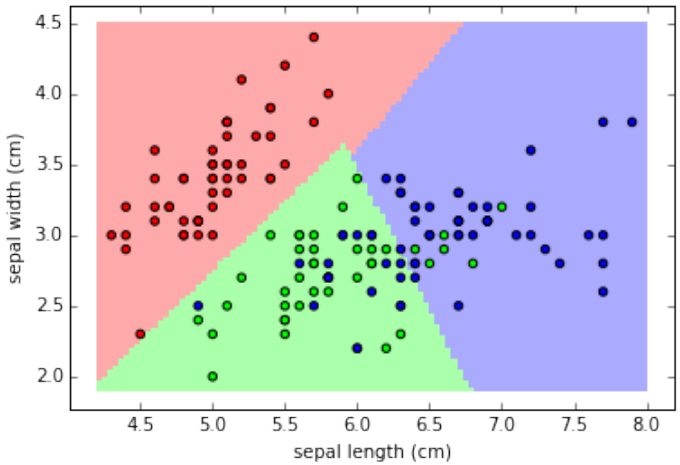


Какое из них правильное?

Типичная особенность задач машинного обучения

Что лучше: идеально подогнать решение к исходным данным или упростить его?

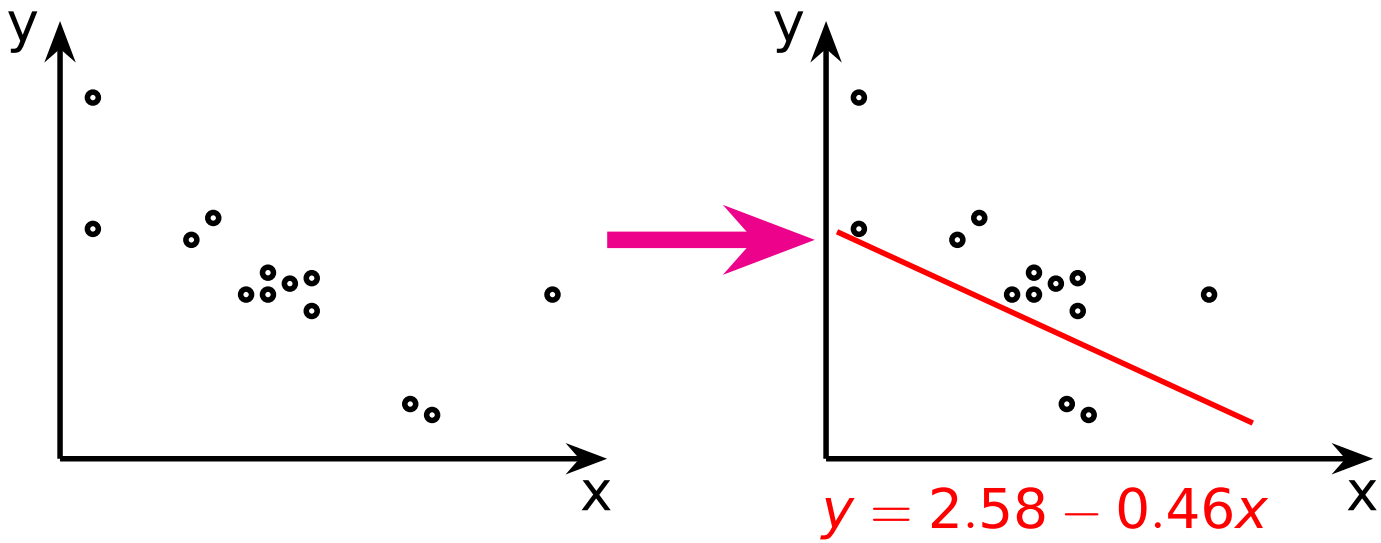




Единого применимого во всех случаях решения нет. Приходится достигать баланса между точностью на исходных данных и прогнозируемой точностью в произвольном случае.

Примеры задач: регрессия

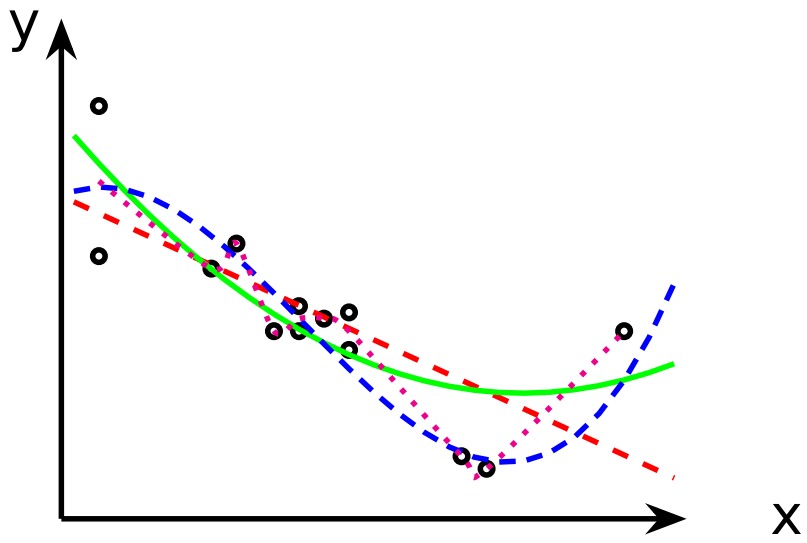
Задача регрессии: построить функцию по набору её значений, в которых могут быть погрешности:



Примечание: классификация — это регрессия, в которой значения функции — номера классов, т.е. она дискретна.

Примеры задач: регрессия (2)

Общепримениимого решения опять нет:



- - - - $y = 2.58 - 0.46x$

——— $y = 3.18 - 1.18x + 0.16x^2$

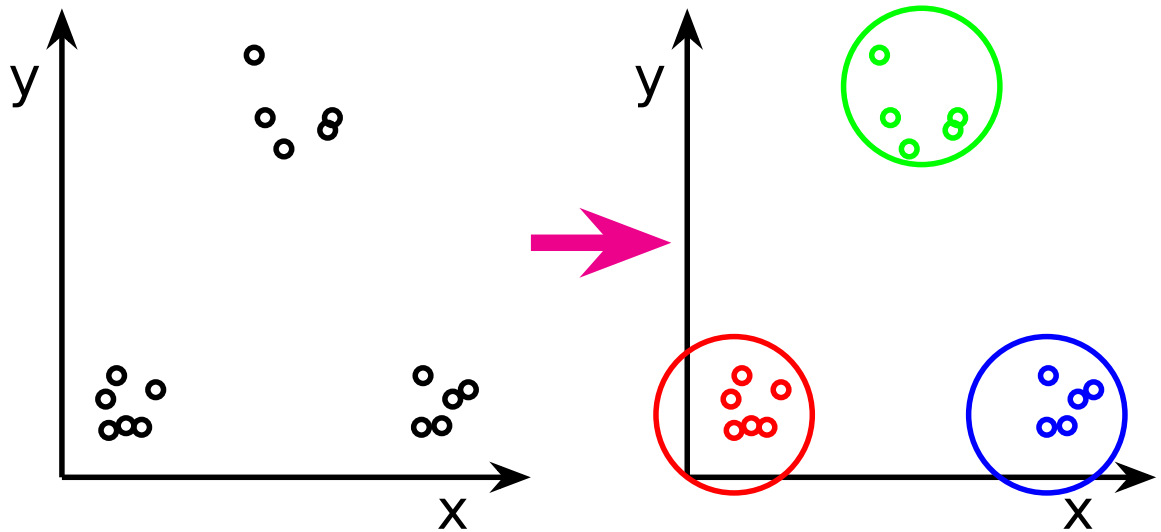
- - - - - $y = 2.58 + 0.46x - 0.76x^2 + 0.13x^3$

····· Кубический сплайн

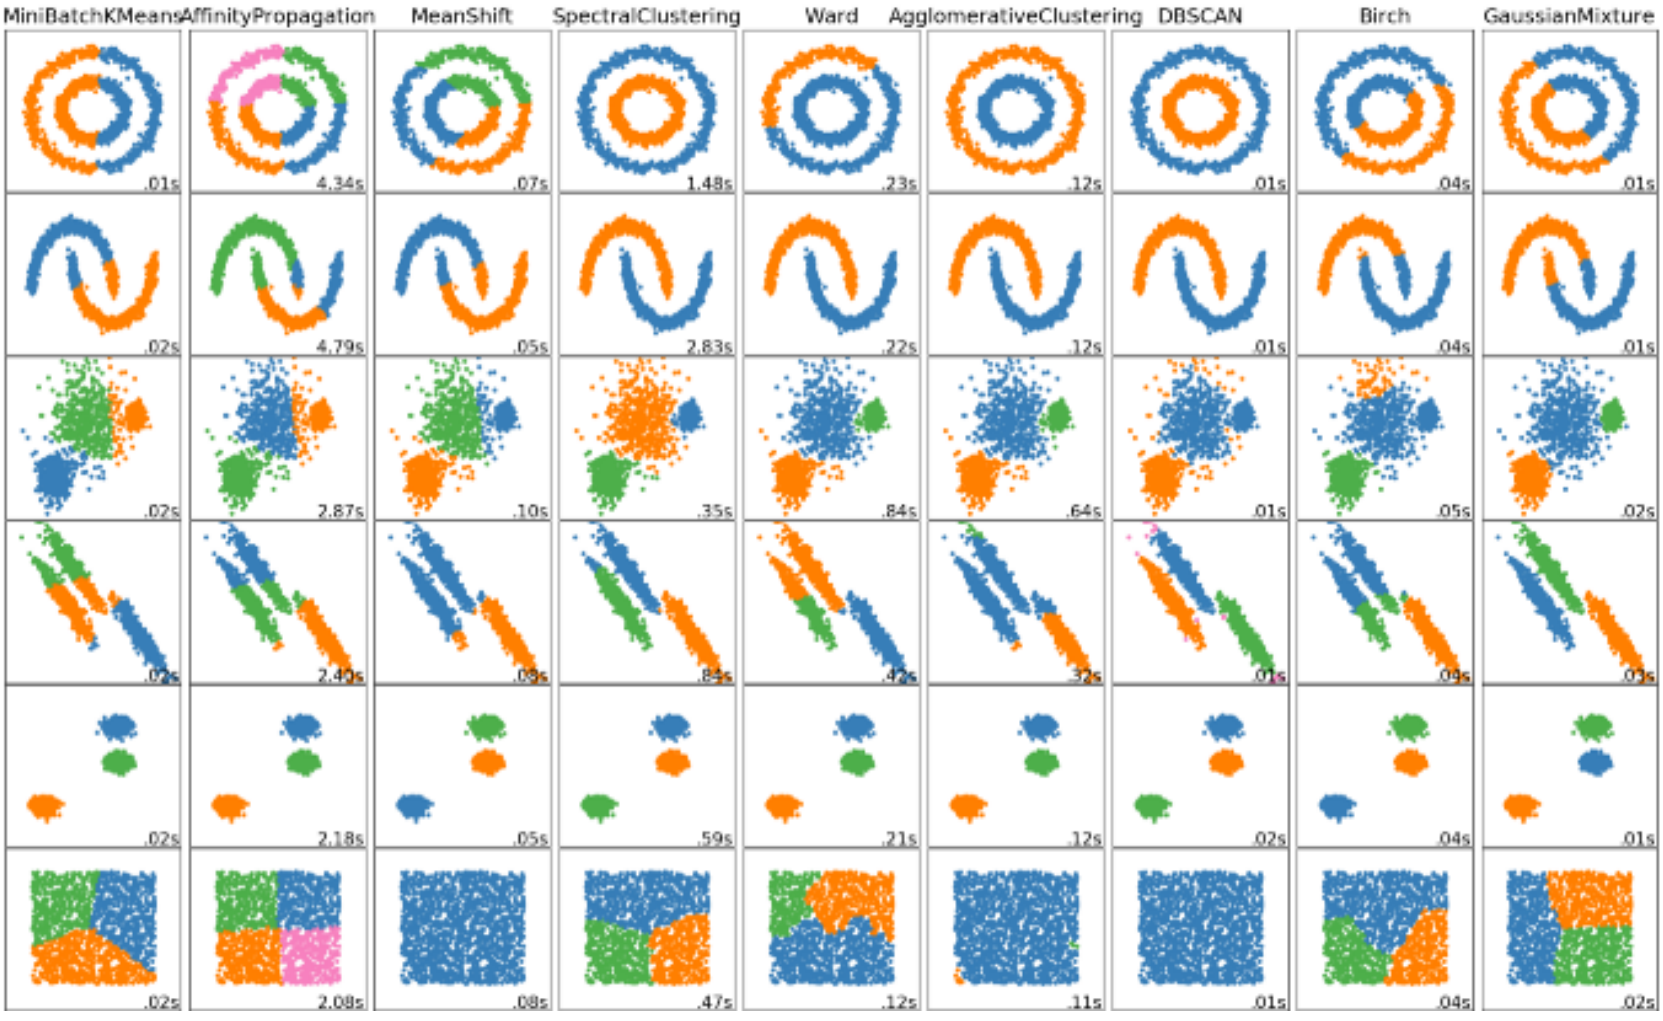
Приемлемый вариант снова выбирается, исходя из специфики задачи.

Примеры задач: кластеризация

Пусть имеется множество примеров данных, описывающих объекты. Требуется разделить эти примеры на группы по схожести друг с другом, исходя из имеющихся данных:

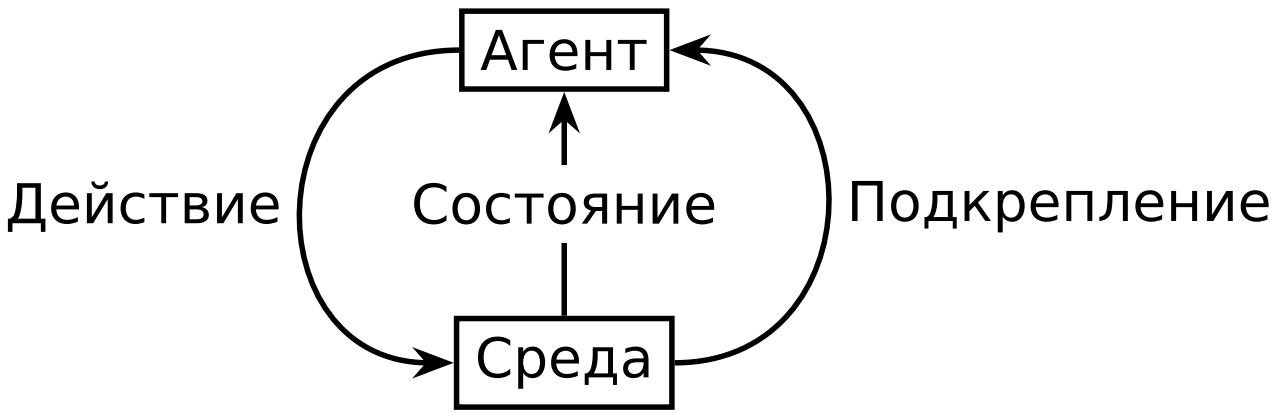


Множество подходов к кластеризации



Примеры задач: обучение с подкреплением

Пусть некая система, способная к самостоятельным действиям (агент) выполняет поставленную задачу в некоторой среде, получая информацию об удачности своих действий (т.н. подкрепление). Требуется найти наилучший алгоритм поведения агента.



В отличие от прошлых вариантов, можно активно собирать информацию, а не просто пользоваться уже готовой.

Зачем это нужно?

- Для решения сложных задач, в которых тяжело построить достаточно точную модель или найти решение для построенной;
- для передачи системе человеческих знаний: распознавание, управление «по примеру»;
- для работы в среде с большой размерностью и наличием шумов.



Примеры использования обучения с подкреплением

- Распознавание и идентификация объектов;
- захват объектов различной формы манипулятором;
- общение с пользователем (чатботы);
- движение автомобиля по дорожной разметке в реальных условиях;
- обработка результатов экспериментов (распознавание тенденций и выбросов);
- предсказание поведения сложных систем.

Общие проблемы машинного обучения

Типичные проблемы:

- большая размерность;
- частичная информация;
- большая роль случайностей.

Пути их решения:

- аппроксимация;
- динамическое программирование (рекурсивное решение подзадач);
- математическое программирование (оптимизация);
- уменьшение размерности.

Основные группы методов

- **Обучение с учителем**: в каждом примере есть правильный ответ для него, и требуется найти функцию, дающую этот ответ. Классификация, регрессия, прогнозирование и др.;
- **обучение без учителя**: правильных ответов в примерах нет. Кластеризация, распознавание выбросов, заполнение отсутствующих в примерах признаков, генерация и др.;
- **обучение с подкреплением**: ответов нет, но имеются подсказки — награды за принимаемые решения;
- ещё: частичное обучение, трансдуктивное обучение, активное обучение и др.

Частое заблуждение

Можно использовать в качестве модели искусственные нейронные сети (Artificial Neural Networks, ANN); это распространённый, но не единственный тип моделей.

Модель — это математическое представление функции, которая обучается. **Под обучением понимается настройка параметров** для более точного решения задачи.

Преимущества: возможность применения алгоритма обратного распространения ошибок для эффективного с вычислительной точки зрения решения задачи оптимизации.

Недостатки: сложность интерпретации результатов, непредсказуемость скорости и качества обучения.

Какие проблемы остаются?

- Некорректность постановки многих задач: задача корректно поставлена, если её решение существует, единственно и устойчиво, а в машинном обучении это часто не так;
- плохая обусловленность многих задач: малые ошибки входных данных ведут к большим ошибкам решений;
- правильный выбор модели и алгоритма (No Free Lunch Theorem): в общем случае нет подхода, лучше подходящего для поиска неизвестной функции по отдельным примерам, чем слепой поиск;
- переобучение (overfitting);
- подготовка данных (мусор на входе — мусор на выходе);
- длительность обучения, размер выборок.

Различие с математической статистикой

Многие похожие задачи решает ещё одна дисциплина — математическая статистика: это тоже использование имеющихся данных для прогнозирования.

Жёсткой границы нет, многие методы успешно применяются и там, и там.

Основное отличие: в статистике обязательно оценивают достоверность, качество выдаваемого решения; для этого оно должно быть интерпретируемо на каждом этапе, что обеспечить весьма сложно.

Методы статистики строже и лучше подходят для ответственных применений, но более ограничены.

Группы моделей

По времени наибольшего распространения можно выделить:

1. до 2006 г.: традиционные модели с упором на математические аспекты; роль нейросетей мала (один из классификаторов/регрессоров), глубоких сетей нет;
2. 2006–2016 гг.: распространение базовых глубоких сетей — свёрточных, реккурентных, остаточных;
3. с 2017 г.: комбинирование традиционных моделей и глубоких сетей: трансформеры и их производные; глубокое обучение с подкреплением.

Модели более старых видов активно используются в более новых разработках, поэтому приходится изучать их все.

Полезные ссылки

Полезные ресурсы и ссылки

Основные сведения:

1. Воронцов К.В. Курс лекций по машинному обучению — классические методы;
2. Гудфэллоу Я., Бенджио Дж., Курвилль А. Глубокое обучение. 2018 (Deep learning, 2016) — базовые глубокие сети;
3. Принс С. Машинное обучение от основ до продвинутых моделей. 2025 (Understanding deep learning, 2023). — современные глубокие сети;
4. Саттон Р., Барто Э. Обучение с подкреплением. Введение. 2020 (Reinforcement learning: an introduction, 2nd ed., 2018) — обучение с подкреплением;
5. короткий рассказ про методы: Рассел С., Норвиг П. Искусственный интеллект. Современный подход. Том 3, часть V - М.: Вильямс, изд. 4, 2021
6. www.machinelearning.ru
7. Викиконспекты университета ИТМО

Краткие сведения из теории вероятности

Понятие вероятности
Функция распределения
Числовые параметры случайной величины
Распространённые законы распределения
Зависимость случайных величин

Событие

Событие — факт, который в процессе опыта может произойти либо не произойти (но не то и другое одновременно).

Примеры событий: выпадение «3» при броске игрального кубика, выпадение орла при броске монеты, приход поезда в установленное время.

Если опытов проводится достаточно много, то событие случается обычно не во всех из них. Например если долго бросать игральный кубик, то выпадение «3» будет иногда происходить, иногда — не происходить.

Частота события — доля опытов, в которых событие произошло. Если одинаковых опытов было N штук, а событие A произошло N_A раз, то частота этого события в этой серии опытов равна $\frac{N_A}{N}$.

Вероятность

Чтобы понять, насколько часто могут происходить события, полезно было бы ввести числовую характеристику частоты — вероятность P (probability). Примем, что:

- вероятность события, которое никогда не происходит — 0;
- вероятность события, которое происходит всегда — 1;
- вероятность события, которое происходит иногда, лежит между 0 и 1;
- если K разных событий происходят с одинаковой частотой, причём какое-то из них произойдёт гарантированно, то вероятность каждого из них равна $\frac{1}{K}$.

Примеры расчёта вероятности

Вопрос: какова вероятность события A_3 — выпадения «3» на шестигранном игральном кубике?

Примеры расчёта вероятности

Вопрос: какова вероятность события A_3 — выпадения «3» на шестигранном игральном кубике?
Ответ: выпадение каждой грани одинаково вероятно, всего граней 6, поэтому
$P(A_1) = P(A_2) = P(A_3) = P(A_4) = P(A_5) = P(A_6) = \frac{1}{6}$

Вопрос: какова вероятность события B — выпадения орла при броске монеты?

Примеры расчёта вероятности

Вопрос: какова вероятность события A_3 — выпадения «3» на шестигранном игральном кубике?
Ответ: выпадение каждой грани одинаково вероятно, всего граней 6, поэтому
$P(A_1) = P(A_2) = P(A_3) = P(A_4) = P(A_5) = P(A_6) = \frac{1}{6}$

Вопрос: какова вероятность события B — выпадения орла при броске монеты?
Ответ: $P(B) = \frac{1}{2}$.

Из опытных данных известно, что при многочисленных повторениях опыта **частота появления события стремится к его вероятности**.

Случайная величина

Пусть имеется какая-нибудь характеристика объекта (числовая или категориальная), которая у разных объектов принимает разные значения:

- рост или вес у человека;
- цена или производитель у товара и т.п.

Если считать событием появление какого-то конкретного значения характеристики, то можно сказать, что это значение появляется с некоторой вероятностью. Например, у разных людей разный рост, поэтому имеются некоторые вероятности того, что рост человека 180 см или 160 см.

Случайная величина (random variable) — величина, принимающая те или иные значения с некоторой вероятностью.

Отличие вероятности от нечёткости

На всякий случай: часто с вероятностью путают нечёткость (fuzziness) применяемого нами естественного языка:

Событие «Этот человек имеет рост 180 см» имеет некоторую вероятность, которую можно определить для любого множества людей. Для этого надо просто найти в нём долю людей с этим ростом.

Событие «Этот человек высокий» зависит от того, что мы понимаем под словом «высокий». Если преодолеть эту неопределённость, т.е. математически строго указать «под высоким ростом понимается рост 180 см или больше», то у него появится вероятность.

Иногда вместо такого доопределения вводят функцию принадлежности к множеству «высокий», которая имеет значение 1 у высоких, 0 у точно не принадлежащих к высоким и промежуточные значения у остальных; при этом получается т.н. «лингвистическая переменная». Эта область изучается **нечёткой логикой** (fuzzy logic); она не имеет отношения к теории вероятности.

Многомерная случайная величина

Очень часто несколько разных случайных величин удобно обрабатывать вместе; они могут образовывать вектор, матрицу и т.п. Такие комбинации нескольких величин называют **многомерными случайными величинами**. Примеры:

- точка (x, y, z) трёхмерного пространства, описывающая положение центра объекта — многомерная случайная величина;
- набор параметров (x, y, θ), описывающий положение фигуры на плоскости (координаты её центра и угол ориентации) — многомерная случайная величина.

Размерности компонентов многомерных величин могут не совпадать.

Условная вероятность

Часто вероятности разных событий связаны; удобно выражать эту связь условной вероятностью.

Вероятность события A при условии, что произошло событие B, обозначают $P(A|B)$.

Пример: вероятность того, что на шестигранном кубике выпало значение «3», равна $P(A) = \frac{1}{6}$.
Вопрос: какова вероятность выпадения «3», если выпавшее значение — нечётное?

Условная вероятность

Часто вероятности разных событий связаны; удобно выражать эту связь условной вероятностью.

Вероятность события A при условии, что произошло событие B, обозначают $P(A|B)$.

Пример: вероятность того, что на шестигранном кубике выпало значение «3», равна $P(A) = \frac{1}{6}$.
Вопрос: какова вероятность выпадения «3», если выпавшее значение — нечётное?
Ответ: $P(A|B) = \frac{1}{3}$, где B — выпадение нечётного числа.

Вопрос: какова вероятность выпадения «3», если выпавшее значение — чётное?

Условная вероятность

Часто вероятности разных событий связаны; удобно выражать эту связь условной вероятностью.

Вероятность события A при условии, что произошло событие B, обозначают $P(A|B)$.

Пример: вероятность того, что на шестигранном кубике выпало значение «3», равна $P(A) = \frac{1}{6}$.
Вопрос: какова вероятность выпадения «3», если выпавшее значение — нечётное?
Ответ: $P(A|B) = \frac{1}{3}$, где B — выпадение нечётного числа.

Вопрос: какова вероятность выпадения «3», если выпавшее значение — чётное?
Ответ: $P(A|\bar{B}) = 0$, где $\bar{B}$ — выпадение чётного числа.

Представление вероятностей

Если случайная величина — категориальная (дискретная), можно показать вероятности её значений в виде таблицы:

значение величины X	1	2	3	4
вероятность	0.1	0.3	0.2	0.4

С непрерывными величинами это невозможно. Пусть, например, θ — случайная величина угла поворота колёс автомобиля. Понятно, что количество разных значений θ бесконечно много и даже несчётно, поэтому в таблицу их не уместить

Функция распределения

Рассчитаем для случайной величины X следующую функцию $F(x)$: вероятность того, что значение этой случайной величины меньше x: $F(x) = P(X < x)$. Такая F — функция распределения этой величины.
Например, для величины X с прошлого слайда:

значение величины X	1	2	3	4
вероятность	0.1	0.3	0.2	0.4

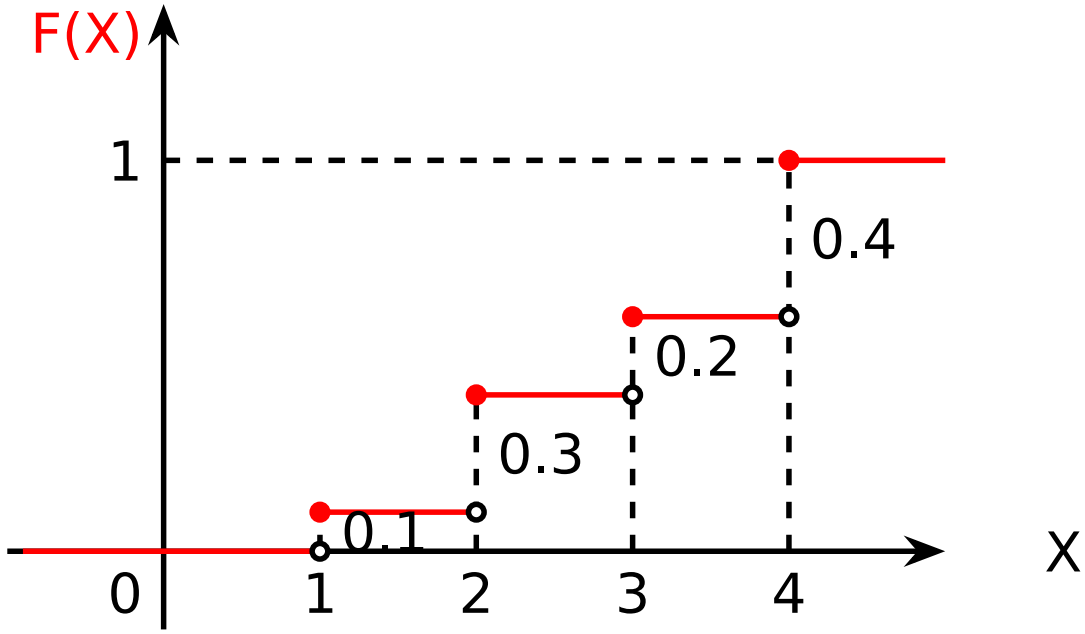
$$
\begin{aligned}
x < 1 &\to F = 0 \\
1 \le x < 2 &\to F = 0.1 \\
2 \le x < 3 &\to F = 0.1 + 0.3 = 0.4 \\
3 \le x < 4 &\to F = 0.1 + 0.3 + 0.2 = 0.6 \\
4 \le x &\to F = 0.1 + 0.3 + 0.2 + 0.4 = 1
\end{aligned}
\tag{1}
$$

Очевидно, что всегда $F(-\infty) = 0$, $F(\infty) = 1$.

График функции распределения

значение величины X	1	2	3	4
вероятность	0.1	0.3	0.2	0.4

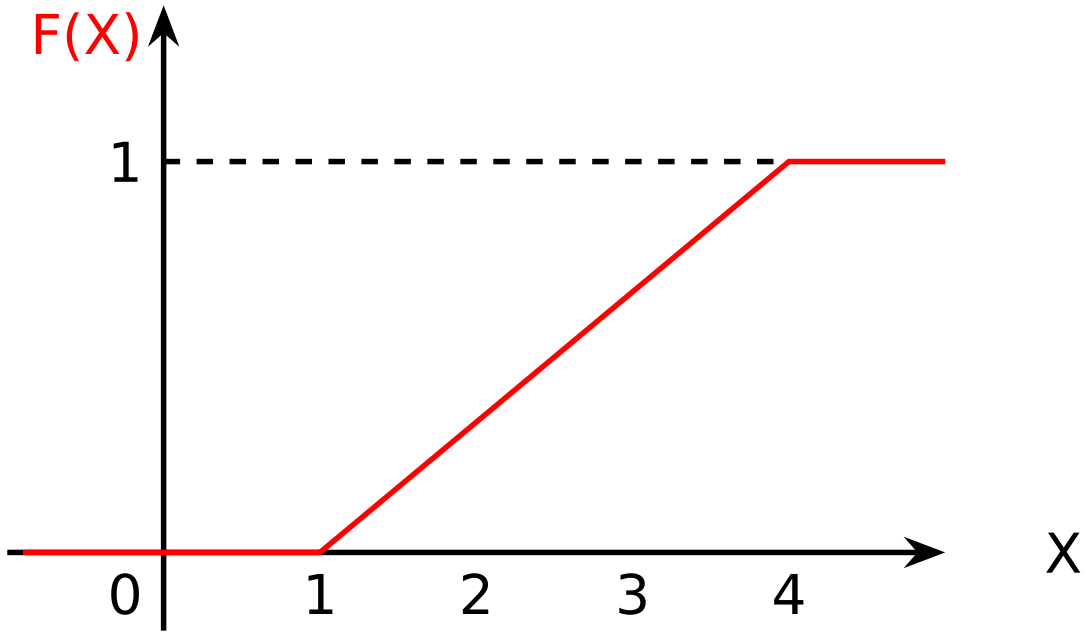
Функцию распределения удобно показывать графически:



Для дискретных величин эта функция разрывна, для непрерывных — может быть непрерывной.

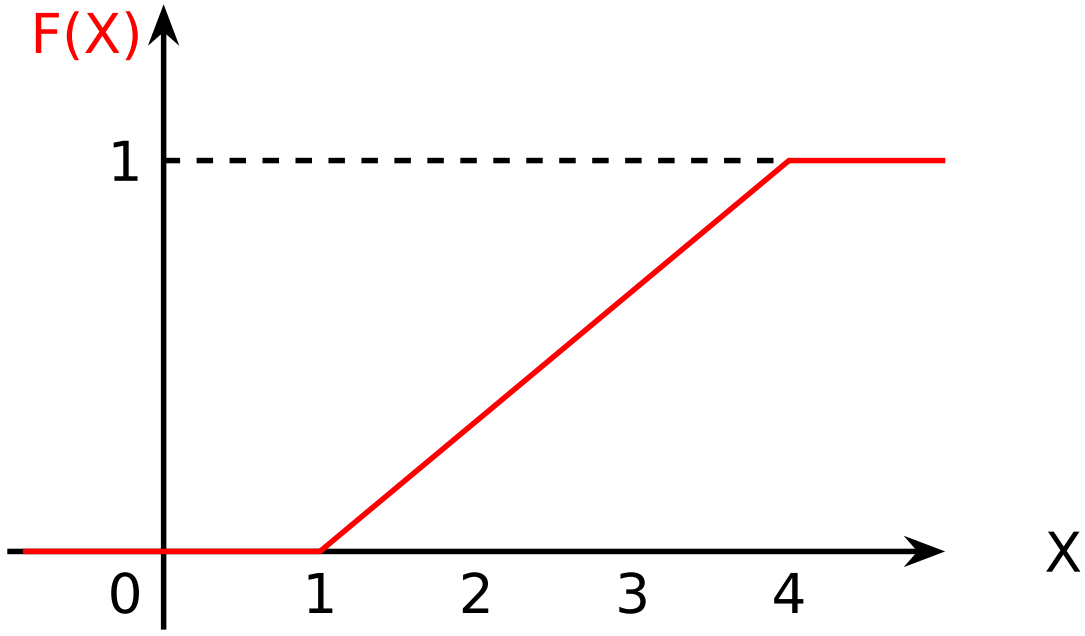
Пример функции распределения

Вопрос: что можно сказать о непрерывной случайной величине X, график функции распределения которой показан ниже?



Пример функции распределения

Вопрос: что можно сказать о непрерывной случайной величине X, график функции распределения которой показан ниже?



Ответ: величина X принимает значения с 1 до 4 с равной вероятностью.

Плотность распределения

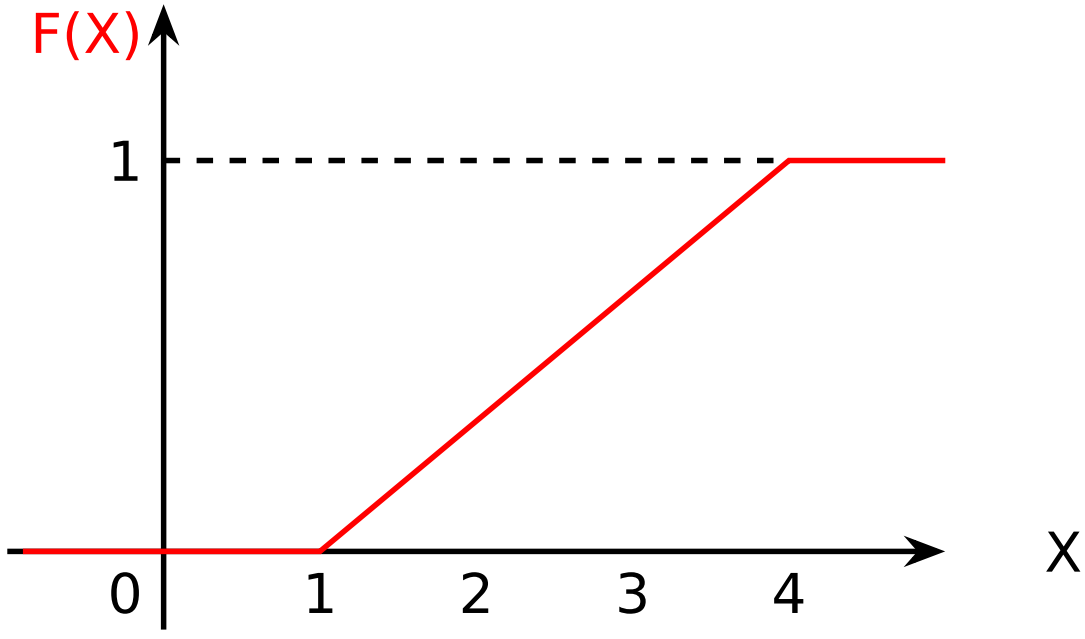
Часто удобно использовать не функцию распределения саму по себе, а её производную — **функцию плотности распределения**:
Если для случайной величины X известна функция распределения $F(x)$, то функция плотности распределения $f(x) = F'(x)$.

Физический смысл плотности: она тем больше в точке x, чем больше вероятность встретить значение x.

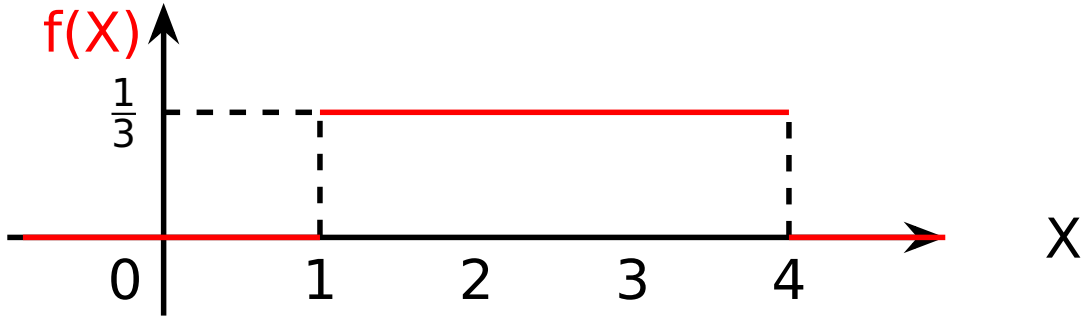
Вероятность значения от x_1 до x_2: $P = \int\limits_{x_1}^{x_2} f(x)dx$

Свойства: $f(-\infty) = 0$, $f(\infty) = 0$, $\int\limits_{-\infty}^{\infty} f(x)dx = 1$.

Пример плотности распределения



Рассчитаем производную:



Совместная функция распределения

Если случайная величина многомерная, то можно ввести для её компонентов $X_1, X_2, ..., X_N$ совместную функцию распределения:

$$F(x_1, x_2, ..., x_N) = P(X_1 < x_1, X_2 < x_2, ..., X_N < x_N)$$

Если зафиксировать все переменные, кроме одной, на некоторых значениях, совместная функция превратится в обычную.

Функция плотности вводится для многомерного случая аналогично одномерному; для её существования требуется дифференцируемость F. Свойства также аналогичны.

Числовые параметры случайной величины

Часто можно отвлечься от точного распределения случайной величины и для краткости охарактеризовать её просто числами.

Математическое ожидание дискретной случайной величины X, или её **среднее значение** (mean value, estimation):

$$\mathbb{E}[X] = \sum_{x_i \in X} x_i P(x_i)$$

Физический смысл: просуммируем все возможные значения этой величины с «весами», равными их вероятностям.

То же для непрерывной случайной величины:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx$$

Примеры расчёта математического ожидания

значение величины X	1	2	3	4
вероятность	0.1	0.3	0.2	0.4

$$\mathbb{E}[X] = 1 * 0.1 + 2 * 0.3 + 3 * 0.2 + 4 * 0.4 = 2.9$$

Для равномерной распределённой от 1 до 4 величины:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} xf(x)dx = \int_{1}^{4} x\frac{1}{3}dx = \int_{1}^{4} \frac{xdx}{3} = \frac{1}{3}\frac{x^2}{2}\Big|_{1}^{4} = \frac{8}{3} - \frac{1}{6} = 2.5$$

Центральные моменты

Второй центральный момент дискретной случайной величины:

$$\mu_2[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_{x_i \in X} (x_i - \mathbb{E}[X])^2 P(x_i)$$

Третий:

$$\mu_3[X] = \mathbb{E}[(X - \mathbb{E}[X])^3] = \sum_{x_i \in X} (x_i - \mathbb{E}[X])^3 P(x_i)$$

Физический смысл — среднее значение квадрата (куба) её отклонения от математического ожидания.
Для непрерывного случая — аналогично, но с интегралами:

$$\mu_2[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 f(x) dx$$

$$\mu_3[X] = \mathbb{E}[(X - \mathbb{E}[X])^3] = \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^3 f(x) dx$$

Дисперсия

Второй центральный момент иначе называют дисперсией (variance, *V* или *Var*). Чем больше дисперсия, тем сильнее отклоняется величина от среднего значения. Примеры расчёта дисперсии:

значение величины X	1	2	3	4
вероятность	0.1	0.3	0.2	0.4

Среднее значение получено ранее $\mathbb{E}[X] = 2.9$
Дисперсия: $Var[X] = (1-2.9)^2 * 0.1 + (2-2.9)^2 * 0.3 + (3-2.9)^2 * 0.2 + (4-2.9)^2 * 0.4 = 1.09$

Для равномерно распределённой случайной величины:

$$Var[X] = \int_1^4 (x-2.5)^2 \frac{1}{3} dx = \frac{1}{3} \frac{(x-2.5)^3}{3} \Big|_1^4 = \frac{1.5^3 + 1.5^3}{9} = \frac{3}{4}$$

Среднеквадратическое отклонение

Размерность дисперсии — та же, что у квадрата величины X, поэтому иногда удобнее использовать корень из неё, имеющий ту же размерность, что и X; его называют среднеквадратическое отклонение σ (standard deviation):

$$\sigma[X] = \sqrt{Var[X]}$$

Вопрос: когда дисперсия величины равна нулю?

Среднеквадратическое отклонение

Размерность дисперсии — та же, что у квадрата величины X, поэтому иногда удобнее использовать корень из неё, имеющий ту же размерность, что и X; его называют среднеквадратическое отклонение σ (standard deviation):

$$\sigma[X] = \sqrt{Var[X]}$$

Вопрос: когда дисперсия величины равна нулю?
Ответ: когда величина не случайная, а детерминированная;
Вопрос: может ли дисперсия быть отрицательной?

Среднеквадратическое отклонение

Размерность дисперсии — та же, что у квадрата величины X, поэтому иногда удобнее использовать корень из неё, имеющий ту же размерность, что и X; его называют среднеквадратическое отклонение σ (standard deviation):

$$\sigma[X] = \sqrt{Var[X]}$$

Вопрос: когда дисперсия величины равна нулю?
Ответ: когда величина не случайная, а детерминированная;
Вопрос: может ли дисперсия быть отрицательной?
Ответ: она — сумма квадратов, поэтому нет.

Равномерное распределение

Uniform distribution

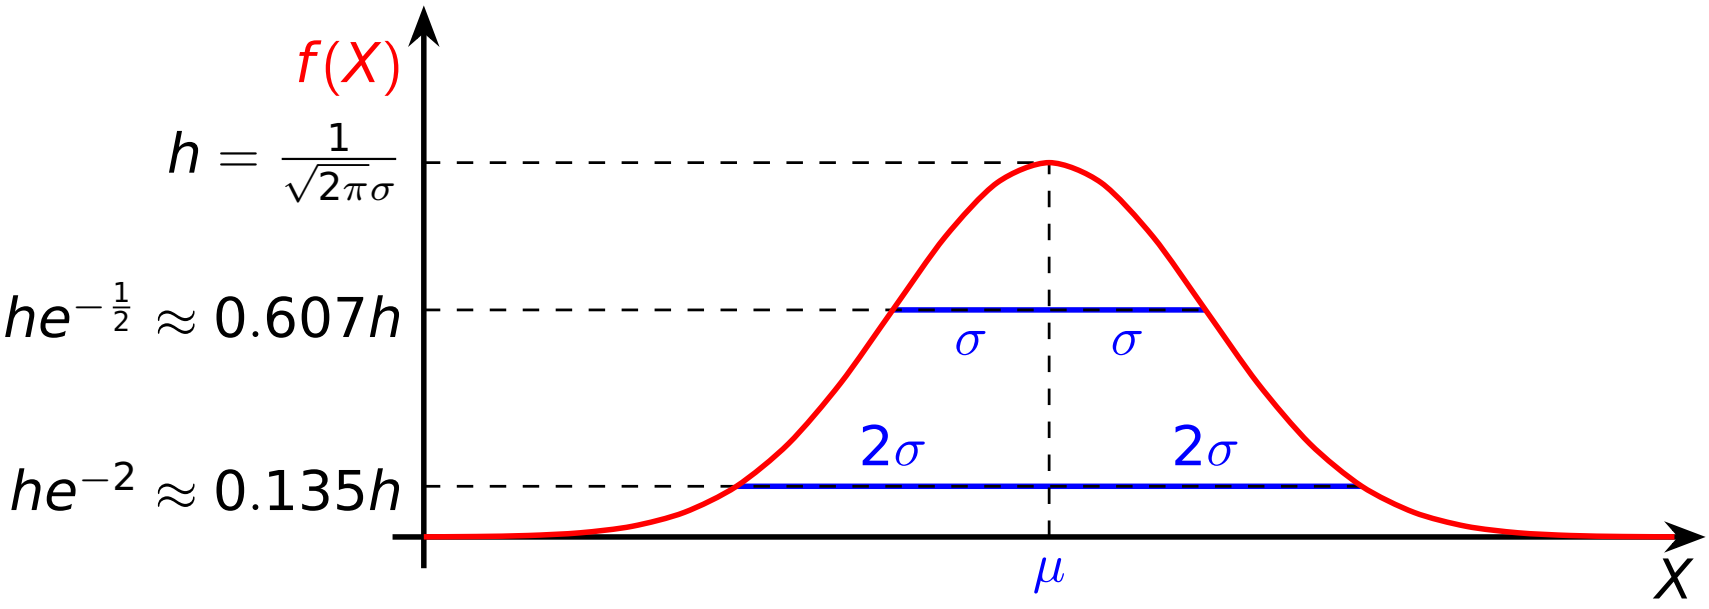


Плотность распределения: $f(x) = \frac{1}{b-a}, a < x < b$

Среднее значение: $\mathbb{E}[X] = \frac{a+b}{2}$, дисперсия $Var[X] = \frac{(b-a)^2}{12}$

Нормальное распределение

Normal distribution, Gaussian distribution



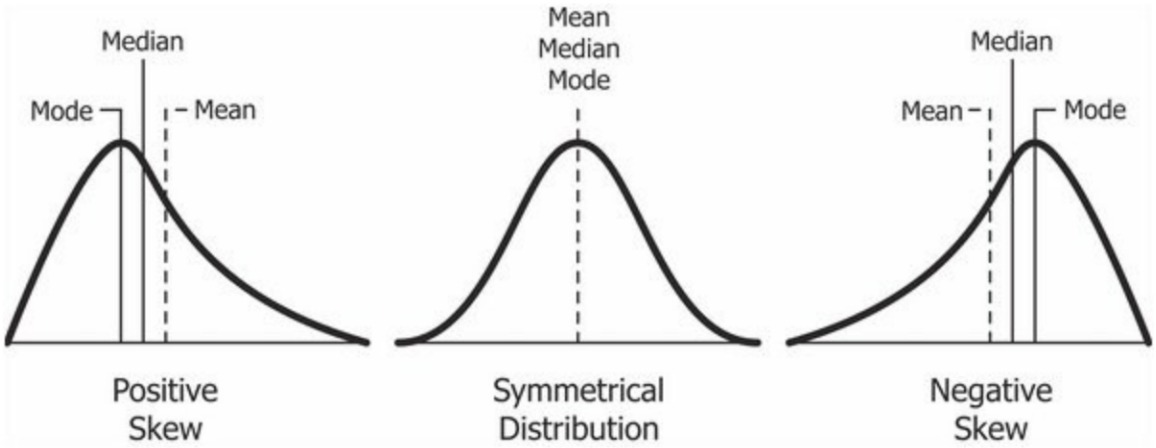
$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} = \mathcal{N}(x, \mu, \sigma)$$

Среднее значение — μ, дисперсия — σ^2

Мода и медиана

Часто используются и другие параметры функции распределения:

Мода (mode) — самое вероятное значение величины.
Медиана (median) — такое значение, что половина данных меньше него, половина - больше.



Если у функции распределения один максимум, она одномодовая; если несколько — многомодовая.

Зависимость событий

Вопрос: приведите примеры случайных величин

Зависимость событий

Вопрос: приведите примеры случайных величин
Ответ: число на брошенном игровом кубике, рост человека и т.п.
Вопрос: приведите пример пары зависимых случайных величин (можно — из бытовых, неформальных соображений)

Зависимость событий

Вопрос: приведите примеры случайных величин
Ответ: число на брошенном игровом кубике, рост человека и т.п.
Вопрос: приведите пример пары зависимых случайных величин (можно — из бытовых, неформальных соображений)
Ответ: рост человека и его вес, уровень дохода и средняя продолжительность жизни и т.п.

Более формально: если есть два события A и B и $P(A|B) = P(A)$, а также $P(B|A) = P(B)$, будем называть события независимыми. Иначе события зависимы.

Можно доказать, что для независимых событий вероятность их одновременного наступления $P(AB)$ равна произведению их вероятностей по отдельности $P(A)$ и $P(B)$: $P(AB) = P(A)P(B)$.

Ковариация

Если перейти от событий к величинам так же, как раньше (каждое выпадение конкретного значения величины будем считать событием), то можно формально ввести зависимые и независимые величины.

Пусть имеется набор из пар значений случайных величин X и Y: $(x_1, y_1), (x_2, y_2), \ldots$. Ковариация (covariance) X и Y определяется как
$Cov[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$

Физический смысл: если X и Y обычно уклоняются от среднего их значения в одну сторону, то ковариация растёт, если в разные - падает.

Свойства ковариации

Симметричность:
$Cov[X, Y] = Cov[Y, X]$

Ковариация величины с самой собой равна дисперсии:
$Cov[X, X] = \mathbb{E}[(X - \mathbb{E}[X])(X - \mathbb{E}[X])] = Var[X]$

При раскрытии скобок получаем:
$Cov[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] =$
$\mathbb{E}[XY - X\mathbb{E}[Y]) - Y\mathbb{E}[X]) + \mathbb{E}[X]\mathbb{E}[Y]] =$
$= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$
Это значит, что ковариация равна нулю при $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.
Поэтому **ковариация независимых случайных величин равна нулю**.

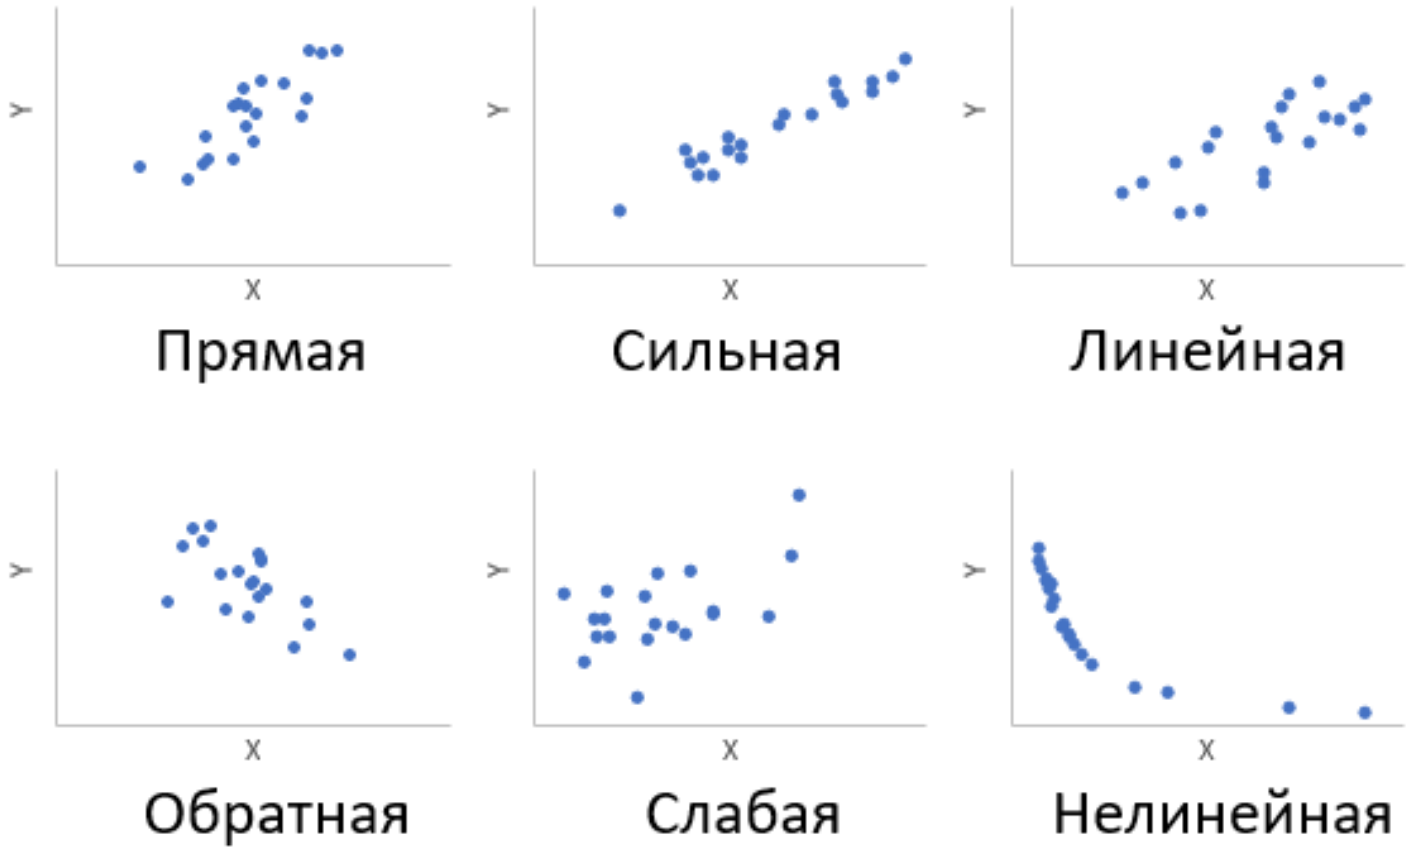
Но **если ковариация нулевая, не всегда** X **и** Y **независимы**!

Корреляция

Коэффициент корреляции между X и Y получается, если разделить их ковариацию на их среднеквадратические отклонения:
$Corr[X,Y] = \frac{Cov[X,Y]}{\sqrt{Var[X]Var[Y]}}$

Можно доказать, что корреляция равна 1 или -1, если X и Y линейно зависимы: $Y = KX + B$; при $K > 0$ $Corr = 1$, при $K < 0$ $Corr = -1$. Можно использовать корреляцию как меру силы линейной зависимости

Визуальные различия при разных корреляциях



Матрица ковариации

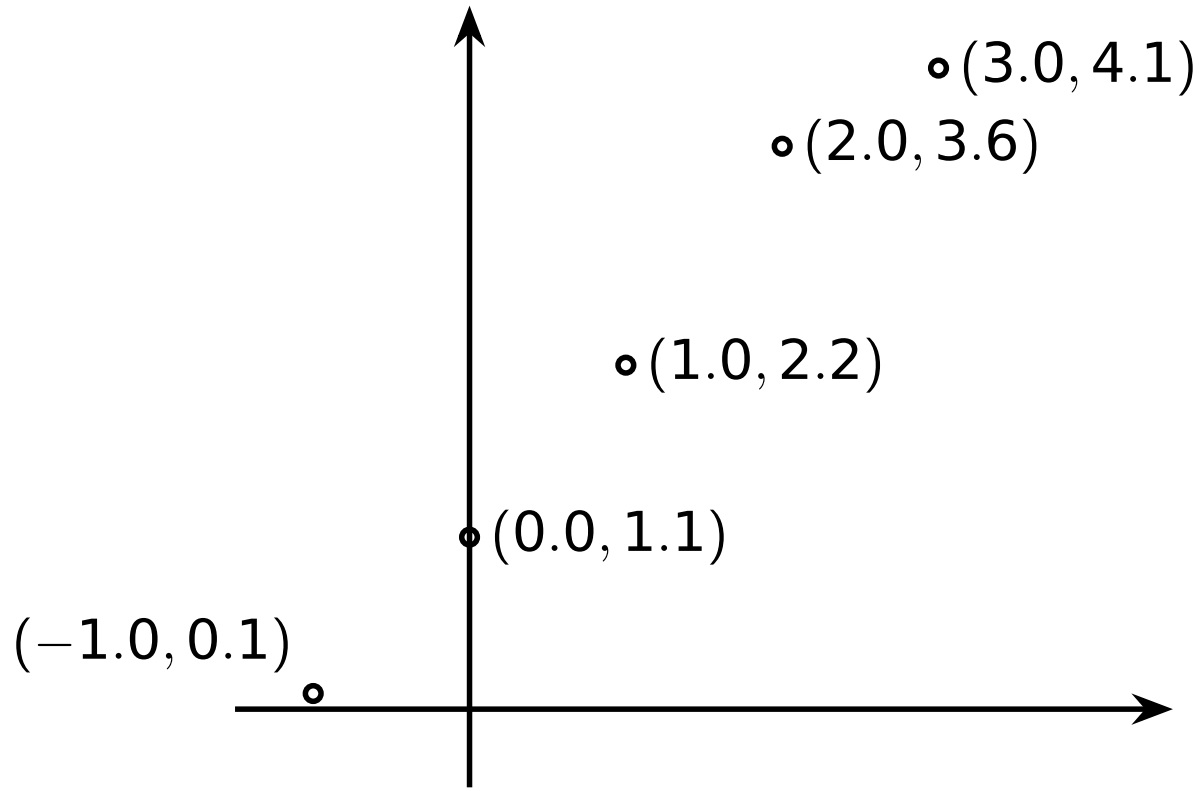
Если взаимозависимых случайных величин много, между каждой их парой может быть зависимость. Чтобы свести все данных о ковариациях воедино, часто составляют матрицу ковариации.

Пусть в измерении имеется N случайных величин $X_i, i = 1..N$. Тогда матрица ковариации - квадратная матрица размером $N \times N$, элемент которой с индексами (i, j) равен $Cov[X_i, X_j]$.

Свойства матрицы ковариации:

- на её главной диагонали стоят дисперсии соответствующих случайных величин $Cov[X_i, X_i] = Var[X_i]$, поэтому диагональные элементы неотрицательны;
- ковариация симметрична, поэтому матрица тоже симметрична.

Пример ковариации и корреляции



Найдём для таких данных дисперсию каждой переменной, ковариацию двух переменных, матрицу ковариации.

Вычисление характеристик: матожидание

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$

Вычислим математические ожидания X и Y.
Вопрос: как будем считать?

Вычисление характеристик: матожидание

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$

Вычислим математические ожидания X и Y.
Вопрос: как будем считать?

$$\mathbb{E}[Z] = \sum_{z_i \in Z} z_i P(z_i)$$

Вероятности всех встреченных в выборке значений равны, поэтому $\mathbb{E}[Z] = \frac{1}{5} \sum_{i=1}^{5} z_i$

Вычисление характеристик: матожидание

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$

Вычислим математические ожидания X и Y.
Вопрос: как будем считать?

$$\mathbb{E}[Z] = \sum_{z_i \in Z} z_i P(z_i)$$

Вероятности всех встреченных в выборке значений равны, поэтому $\mathbb{E}[Z] = \frac{1}{5} \sum_{i=1}^{5} z_i$

$$\mathbb{E}[X] = \frac{-1 + 0 + 1 + 2 + 3}{5} = 1$$
$$\mathbb{E}[Y] = \frac{0.1 + 1.1 + 2.2 + 3.6 + 4.1}{5} = 2.22$$

Вычисление характеристик: дисперсия

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$

Вычислим дисперсии X и Y.

Вопрос: по какой формуле будем считать?

Вычисление характеристик: дисперсия

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$

Вычислим дисперсии X и Y.
Вопрос: по какой формуле будем считать?

$$Var[Z] = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$$

$$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$$

Вычисление характеристик: дисперсия

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$

Вычислим дисперсии X и Y.

Вопрос: по какой формуле будем считать?

$$Var[Z] = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$$

$$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$$

$$Var[X] = \frac{(-1-1)^2 + (0-1)^2 + (1-1)^2 + (2-1)^2 + (3-1)^2}{5} = 2$$

$$Var[Y] = \frac{(0.1-2.22)^2 + (1.1-2.22)^2 + (2.2-2.22)^2 + \ldots}{5}$$

$$\frac{\ldots + (3.6-2.22)^2 + (4.1-2.22)^2}{5} \approx 2.24$$

Вычисление характеристик: ковариация

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$
$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$

Вопрос: по какой формуле будем считать?

Вычисление характеристик: ковариация

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$
$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$

Вопрос: по какой формуле будем считать?

$$Cov[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Вычисление характеристик: ковариация

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$
$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$

Вопрос: по какой формуле будем считать?

$$Cov[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

$$Cov[X, Y] = \frac{(-1-1)(0.1-2.22) + (0-1)(1.1-2.22) + ...}{5}$$
$$\frac{... + (1-1)(2.2-2.22) + (2-1)(3.6-2.22) + ...}{5}$$
$$\frac{... + (3-1)(4.1-2.22)}{5} = 2.1$$

Вычисление характеристик: матрица ковариации

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$
$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$
$Var[X] = 2, Var[Y] = 2.24, Cov[X, Y] = 2.1$

Вопрос: какого размера матрица? Из чего она состоит?

Вычисление характеристик: матрица ковариации

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$
$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$
$Var[X] = 2, Var[Y] = 2.24, Cov[X, Y] = 2.1$

Вопрос: какого размера матрица? Из чего она состоит?
Ответ: на каждую переменную по одной строке и одному столбцу; на диагонали — её дисперсия, в других местах — попарные ковариации с прочими переменными.

Вычисление характеристик: матрица ковариации

$(X, Y) : (-1.0, 0.1), (0.0, 1.1), (1.0, 2.2), (2.0, 3.6), (3.0, 4.1)$
$\mathbb{E}[X] = 1, \mathbb{E}[Y] = 2.22$
$Var[X] = 2, Var[Y] = 2.24, Cov[X, Y] = 2.1$

Вопрос: какого размера матрица? Из чего она состоит?
Ответ: на каждую переменную по одной строке и одному столбцу; на диагонали — её дисперсия, в других местах — попарные ковариации с прочими переменными.

$$\begin{pmatrix} Var[X] & Cov[X, Y] \\ Cov[Y, X] & Var[Y] \end{pmatrix} = \begin{pmatrix} 2 & 2.1 \\ 2.1 & 2.24 \end{pmatrix}$$

Тема 2

Терминология

Линейная регрессия

Прочие виды регрессии

Терминология

Базовые термины
Обучаемый алгоритм
Вероятностные аспекты
Деление выборки на части

Терминология

Общий вид большинства задач: дано конечное множество **прецедентов (объектов, ситуаций)**, по каждому из которых собраны некоторые данные.

Требуется по этим данным выявить общие зависимости, закономерности, взаимосвязи, присущие не только имеющимся примерам, но вообще всем прецедентам, в том числе тем, которые ещё не наблюдались.

Совокупность всех имеющихся описаний прецедентов называется **выборкой** (dataset). Каждое описание состоит из набора **признаков** (features), которые могут быть числами, изображениями, сигналами, характеристиками ошибок, вероятностями, достоверностями, текстами и т.п.

Типичные входные и выходные данные

Пусть имеются собранные данные о некоторых событиях / объектах / процессах, сведённые в таблицу. Например, сведения о покупках, совершённых в некотором магазине:

товар	самовывоз	страна	скидка	цена
велосипед	да	Россия	0	20000
дрель	нет	Россия	10%	8000
канат	да	Китай	0	1000
...	...	...	...	

Сведения в каждой строке описывают один объект.

Вся таблица целиком — **выборка**. Одна строка — **прецедент** либо **объект**. Один столбец — **признак**.

Не обязательно во всех прецедентах известны все признаки.

Виды признаков

Признаки делятся на группы по типу допустимых данных:

- 0, 1 — бинарные или логические. Пример: был ли самовывоз;
- конечное множество — номинальные или категориальные. Пример: страна-производитель;
- действительное число — количественные. Пример: скидка, цена.

Терминология (2)

Если привести признаки к числовому виду, все возможные их значения образуют **пространство признаков**; все прецеденты являются точками этого пространства.

Алгоритм обучения ищет параметры некоторой **модели**, которая описывает закономерности в прецедентах. Выявленные закономерности могут описывать имеющиеся прецеденты не точно, а с некоторой ошибкой, которая численно характеризуется **функцией потерь** (loss).

Под моделью понимается **формальное математическое описание связей прецедентов и параметров**: формулы взаимозависимостей, вероятности, правила и т.п. Модель выбирается разработчиком, исходя из специфики задачи. Выбор должен быть обоснован; неверно выбранная модель обычно работает неправильно.

Одна из типичных задач

Неформально: если для всякого элемента выборки известен правильный ответ на некоторый вопрос, создать метод для вычисления этого правильного ответа для любых объектов —в том числе тех, которых в выборке нет.

Более формально: пусть имеются

- множество X;
- множество допустимых ответов Y;
- **целевая функция** $f : X \to Y$, значения f известны только на выборке $Z \subset X$ (т.е. на подмножестве X).

Требуется найти такую **решающую функцию, или модель** $g : X \to Y$, чтобы она хорошо приближала f на всём множестве X.

От того, что математически означает «хорошо приближала», зависит используемый аппарат.

Типичный вид решения задачи

Обычно решающую функцию не строят произвольно с нуля; вместо этого выбирают её желаемый вид и настраивают параметры, подгоняя её под нужные ответы.

Более формально: обычно решающая функция зависит не только от входного элемента $g(x) : X \to Y$, но и от значений параметров $w \in W$:
$g(x, w) : (X, W) \to Y$
Обучение T — процесс подбора параметров w по выборке Z и правильным ответам $Y(Z)$ для неё:
$T : (Z, Y(Z)) \to w$

Если метод не имеет таких параметров, он называется непараметрическим. Он просто выдаёт некоторую $g(x)$ без подбора параметров.

Качество решения

Чтобы понять, насколько хорошо g приближает f для конкретного $x \in X$, можно задать некоторую функцию ошибки L (loss function). Чем больше L, тем хуже решена задача.

Вопрос: какую характеристику удобно взять в качестве ошибки?

Качество решения

Чтобы понять, насколько хорошо g приближает f для конкретного $x \in X$, можно задать некоторую функцию ошибки L (loss function). Чем больше L, тем хуже решена задача.

Вопрос: какую характеристику удобно взять в качестве ошибки?

Ответ: некоторую функцию расстояния на множестве ответов Y, например:

- модуль ошибки $L = |g(x) - f(x)|$;
- квадрат ошибки $L = (g(x) - f(x))^2$;
- бинарный признак ошибки: $L = \begin{cases} 1, g(x) \neq f(x) \\ 0, g(x) = f(x) \end{cases}$

Общей мерой качества могут служить средняя или максимальная ошибка на выборке.

Параметры и гиперпараметры

Процесс обучения — это настройка параметров w функции-модели $g(x, w)$ так, чтобы она была похожа на $f(x)$, т.е. функция ошибки была достаточно малой.

Иногда часть параметров функции g не настраивается в процессе обучения, а выбираются разработчиком из некоторых соображений. Пример: если надо приблизить функцию многочленом, то можно заранее каким-то образом выбрать его степень и затем подгонять только коэффициенты. Такие параметры, не меняющиеся при обучении, называются **гиперпараметрами**.

Примеры гиперпараметров: допустимая ошибка модели, критерий остановки обучения, количество слоёв в нейронной сети.

Важное уточнение

Не совсем точно было говорить про целевую функцию именно как про функцию $X \to Y$, потому что возможны случаи, когда для одного и того же набора признаков $x \in X$ в выборке есть два разных ответа y_1, y_2.

Более строго: существует некоторая вероятность того, что в выборке окажется пара из параметров x_i и ответа y_i; распределение этой вероятности имеет вид $\varphi(x_i, y_i)$. Подобрать надо не функцию $g(x, w) : X \to Y$, а такую форму распределения вероятности $\gamma(x, y, w)$ в пространстве (X, Y, W), что выборка Z будет сгенерирована с большой вероятностью.

Вероятность появления выборки

Пусть для каждого прецедента (x_i, y_i) можно по распределению $\varphi(x, y)$ посчитать вероятность появления в выборке — $p(x_i, y_i)$. Если эти вероятности у разных прецедентов не зависят друг от друга, то можно считать, что общая вероятность появления именно такой выборки $p(Z)$ — их произведение:

$$p(Z) = \prod_{i=1}^{N} p(x_i, y_i)$$

Вопрос: если эта вероятность $p(Z)$ очень мала (практически нулевая), что это значит?

Вероятность появления выборки

Пусть для каждого прецедента (x_i, y_i) можно по распределению $\varphi(x, y)$ посчитать вероятность появления в выборке — $p(x_i, y_i)$. Если эти вероятности у разных прецедентов не зависят друг от друга, то можно считать, что общая вероятность появления именно такой выборки $p(Z)$ — их произведение:

$$p(Z) = \prod_{i=1}^{N} p(x_i, y_i)$$

Вопрос: если эта вероятность $p(Z)$ очень мала (практически нулевая), что это значит?
Ответ: это значит, что выборка могла появиться только при исключительном стечении обстоятельств, то есть она совершенно не характерна для реальных X и Y. На практике будем считать, что это не так (иначе надо просто повторить сбор выборки с учётом допущенных ошибок).

Функция правдоподобия

Если сделать то же самое, но вероятность p считать не для реального распределения $\varphi(x, y)$, а для подобранной нами функции распределения вероятности $\gamma(x, y, w)$, получим:

$$p(Z) = \prod_{i=1}^{N} p(x_i, y_i, w)$$

Вопрос: если эта вероятность $p(Z)$ очень мала (практически нулевая), что это значит?

Функция правдоподобия

Если сделать то же самое, но вероятность p считать не для реального распределения $\varphi(x, y)$, а для подобранной нами функции распределения вероятности $\gamma(x, y, w)$, получим:

$$p(Z) = \prod_{i=1}^{N} p(x_i, y_i, w)$$

Вопрос: если эта вероятность $p(Z)$ очень мала (практически нулевая), что это значит?
Ответ: это значит, что подобранное распределение очень плохо приближает реальное. Т.е. можно использовать эту вероятность для оптимизации решения: чем она больше, тем решение лучше.
Эту вероятность называют **функцией правдоподобия** $L(w, Z)$.

Принцип максимального правдоподобия

Общая идея многих методов машинного обучения: они работают, **максимизируя функцию правдоподобия (likelihood)** $L(w, Z)$ **по переменной** w, т.е. путём подбора оптимальных параметров алгоритма для данной выборки.

Часто при оптимизации бывает удобнее работать не с произведениями, а с суммами. Поэтому можно взять от обеих частей формулы правдободобия логарифм:

$$ln(L(w, Z)) = ln \prod_{i=1}^{N} p(x_i, y_i, w) = \sum_{i=1}^{N} ln(p(x_i, y_i, w))$$

Величина $-ln(L(w, Z))$ — **вероятностная функция потерь**. Её при оптимизации надо снижать.

Смысл введения этой функции

Вопрос: а зачем так делать? Чего мы добьёмся, кроме новых обозначений?

Смысл введения этой функции

Вопрос: а зачем так делать? Чего мы добьёмся, кроме новых обозначений?
Ответ: можно добиться интересных результатов с нормально распределёнными значениями.

Пусть в некоей задаче мы получили решающую функцию $g(x, w)$ и оказалось, что её ошибка $\varepsilon(x, w) = g(x, w) - f(x)$ — нормально распределённая случайная величина с нулевым средним значением. Её распределение имеет вид:

$$\mathcal{N}(\varepsilon, 0, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{\varepsilon^2}{2\sigma^2}}$$

Смысл введения этой функции (2)

Если эту ошибку использовать как $L(w, Z)$, то получим:

$$-ln(L(w,Z)) = -\sum_{i=1}^{N} ln(\mathcal{N}(\varepsilon, 0, \sigma)) = -\sum_{i=1}^{N} ln(\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{\varepsilon^2}{2\sigma^2}})$$

Так как $\varepsilon(x, w) = g(x, w) - f(x)$:

$$-ln(L(w,Z)) = \frac{1}{\sigma\sqrt{2\pi}} \sum_{i=1}^{N} (g(x,w) - f(x))^2 + \frac{Nln(2\pi\sigma^2)}{2}$$

Т.е. функция потерь — сумма квадратов ошибок, умноженная и увеличенная на константы. Благодаря этому можно формально доказать оптимальность метода наименьших квадратов в данном случае.

Всю ли выборку надо использовать для обучения?

Вопрос: правильно ли использовать для обучения системы (снижения функции потерь) все имеющиеся данные, т.е. всю выборку целиком?

Всю ли выборку надо использовать для обучения?

Вопрос: правильно ли использовать для обучения системы (снижения функции потерь) все имеющиеся данные, т.е. всю выборку целиком?
Ответ: неправильно. Надо как-то контролировать, насколько хорошо система обучилась. Самый простой вариант — часть выборки использовать для её обучения, часть — для проверки качества этого обучения.

Вопрос: что будет, если этого не делать?

Всю ли выборку надо использовать для обучения?

Вопрос: правильно ли использовать для обучения системы (снижения функции потерь) все имеющиеся данные, т.е. всю выборку целиком?
Ответ: неправильно. Надо как-то контролировать, насколько хорошо система обучилась. Самый простой вариант — часть выборки использовать для её обучения, часть — для проверки качества этого обучения.

Вопрос: что будет, если этого не делать?
Ответ: система может просто запомнить все примеры из выборки, поэтому на них точность всегда будет высокой, но для не вошедших в выборку прецедентов ничего не гарантируется $\Rightarrow$ **снижается способность к обобщению, т.е. происходит переобучение**.

Части выборки

Обычно собранные данные делят на:

- **обучающую выборку** (training dataset) — примеры, на которых непосредственно минимизируется функция потерь;
- **тестовую выборку** (test dataset) — примеры, служащие для контроля обобщающей способности.

Вопрос: когда можно сказать, что система не переобучилась?

Части выборки

Обычно собранные данные делят на:

- **обучающую выборку** (training dataset) — примеры, на которых непосредственно минимизируется функция потерь;
- **тестовую выборку** (test dataset) — примеры, служащие для контроля обобщающей способности.

Вопрос: когда можно сказать, что система не переобучилась?
Ответ: когда качество примерно совпадает на обучающей и тестовой выборках.

Линейная регрессия

Зачем это нужно?
Наименьшие квадраты
Пример линейной регрессии
Вариации
Минимизация модуля ошибки

Круг решаемых проблем

Вопрос: когда нужно выявить линейную зависимость в данных?

Круг решаемых проблем

Вопрос: когда нужно выявить линейную зависимость в данных?
Ответ: например:

- для обработки результатов измерений: «при росте температуры на 1K сопротивление образца в среднем увеличивается на k Ом»;
- при распознавании образов на изображении: если надо найти квадрат, можно выявить прямые на множествах точек границы и составить квадрат из них.

Как будет показано, зависимости могут быть и не только линейными.

Простейшая постановка задачи

Задано множество прецедентов X, все параметры которых — количественные (т.е. $x_k \in \mathbb{R}$). Ответы y — также количественные. Требуется найти выражение вида

$$\hat{y} = \sum_{k=1}^{N} c_k x_k + c_0,$$

которое достаточно хорошо приближает функцию y во всех точках.

Для начала попробуем получить решение методом наименьших квадратов, т.е. минимизировать сумму квадратов ошибок по всем прецедентам $(y_i - \hat{y})^2$.

Матричное представление

Объединим все параметры прецедентов в матрицу размером N строк на $K+1$ столбцов, где N — число прецедентов, K — число параметров:

$$X = (1, x_{ik}), i \in 1..N, k \in 1..K,$$

Все верные ответы образуют вектор-столбец Y размером $N \times 1$; искомые параметры c_k — вектор-столбец размером $(K+1) \times 1$. Тогда

$$XC = Y + E,$$

где E — вектор-столбец ошибок для каждого прецедента. Нужно найти такой C, чтобы сумма квадратов значений E стала минимальной.

Минимизация ошибки

Минимизируем функцию ошибки, зависящую от переменных $c_k, k = 0..K$:

$$E = ||XC - Y||^2 = (XC - Y)^T(XC - Y)$$

Можно решать эту задачу, расписав градиент этой функции ∇E и приравняв его к нулю (условие экстремума), а потом проверить, что обнаружен минимум.

Сделаем проще: геометрически искомое значение C приближает XC к Y так, что различие между ними минимально. Если рассмотреть подпространство, образованное столбцами X, то вектор $\hat{Y} = XC$ должен быть ближе к Y, чем любой другой элемент этого подпространства. Это значит, что вектор $Y - \hat{Y}$ перпендикулярен этому подпространству, т.е. каждому столбцу матрицы X.

Минимизация ошибки (2)

$$X^T(Y - \hat{Y}) = 0$$

$$X^T(Y - XC) = 0$$

$$X^TY = X^TXC$$

В этом уравнении известно всё, кроме C. Формально можно записать, что

$$C = (X^TX)^{-1}X^TY$$

но на практике обращение больших матриц вызывает проблемы.

Вычислительные проблемы и их решение

Вопрос: а в чём проблемы?

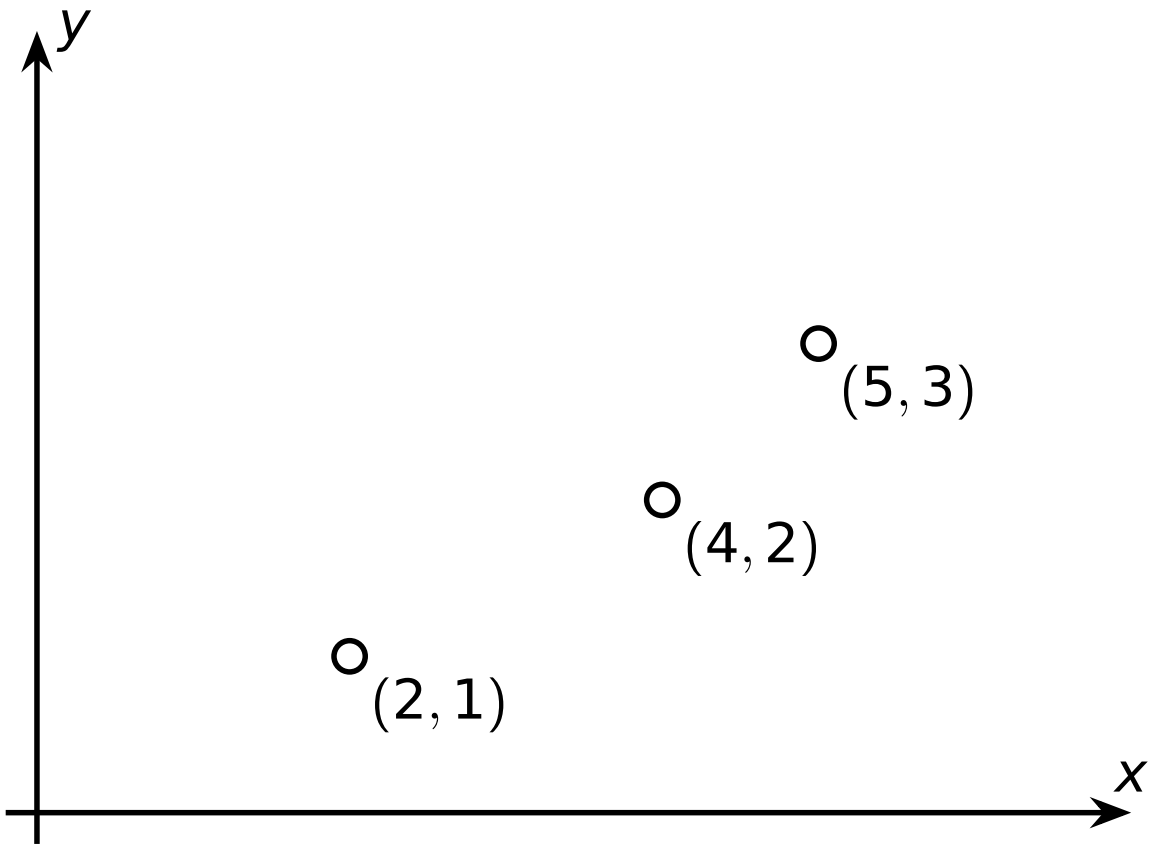
Вычислительные проблемы и их решение

Вопрос: а в чём проблемы?
Ответ: при обращении больших разреженных матриц возникают проблемы вычислительного характера из-за потенциальных сингулярностей.
На практике для решения переопределённых систем уравнений вида $AX = B$ обычно не рассчитывают $A^{-1}B$, а декомпозируют A на произведение матриц, с которыми проще работать:

- сингулярное разложение: $A = USV$, где U и V — унитарные, а S — диагональная;
- QR-разложение: $A = QR$, где Q — унитарная, R — верхняя треугольная.

Пример регрессии

Попытаемся этим методом провести прямую через точки (2,1), (4,2), (5,3)



Уравнение ищем в виде $y = c_0 + c_1 x$

Несовместная система линейных уравнений

Подставляя каждую из точек (2,1), (4,2), (5,3) в уравнение $c_0 + c_1 x = y$, получим систему из трёх линейных уравнений с двумя неизвестными:

$$\begin{cases} c_0 + 2c_1 = 1 \\ c_0 + 4c_1 = 2 \\ c_0 + 5c_1 = 3 \end{cases}$$

Легко показать, что она несовместна, т.е. точного решения нет. Будем искать приближённое решение, т.е. переформулируем задачу как поиск c_0 и c_1 таких, чтобы в системе уравнений

$$\begin{cases} c_0 + 2c_1 = 1 + \varepsilon_1 \\ c_0 + 4c_1 = 2 + \varepsilon_2 \\ c_0 + 5c_1 = 3 + \varepsilon_3 \end{cases}$$

значения ε были достаточно маленькими.

Матричный вид

$$\begin{cases} c_0 + 2c_1 = 1 + \varepsilon_1 \\ c_0 + 4c_1 = 2 + \varepsilon_2 \\ c_0 + 5c_1 = 3 + \varepsilon_3 \end{cases}$$

Запишем условие в матричном виде:

$$\begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \end{pmatrix}$$

Тогда $XC = Y + E$, если $X = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$, $C = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$, $Y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$,

$E = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \end{pmatrix}$.

Геометрическая интерпретация

$XC = Y + E$, если $X = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$, $C = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$, $Y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$

Вопрос: что такое XC и какие значения он может принимать?

Геометрическая интерпретация

$XC = Y + E$, если $X = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$, $C = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$, $Y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$

Вопрос: что такое XC и какие значения он может принимать?

Ответ: $XC = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} c_1 + \begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix} c_2$. Это значит, что XC — любая точка трёхмерного пространства, являющаяся линейной комбинацией векторов $\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ и $\begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix}$ — столбцов матрицы X.

Вопрос: какое подмножество трёхмерных векторов занимают все возможные XC?

Геометрическая интерпретация

$XC = Y + E$, если $X = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$, $C = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$, $Y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$

Вопрос: что такое XC и какие значения он может принимать?

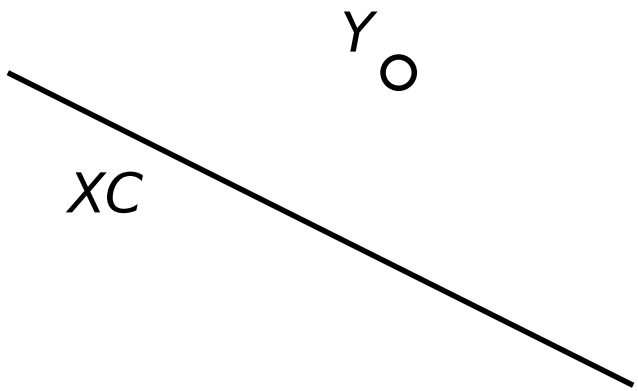
Ответ: $XC = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} c_1 + \begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix} c_2$. Это значит, что XC — любая точка трёхмерного пространства, являющаяся линейной комбинацией векторов $\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ и $\begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix}$ — столбцов матрицы X.

Вопрос: какое подмножество трёхмерных векторов занимают все возможные XC?

Ответ: плоскость, в которой лежат столбцы X — $\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ и $\begin{pmatrix} 2 \\ 4 \\ 5 \end{pmatrix}$.

Геометрическая интерпретация (2)

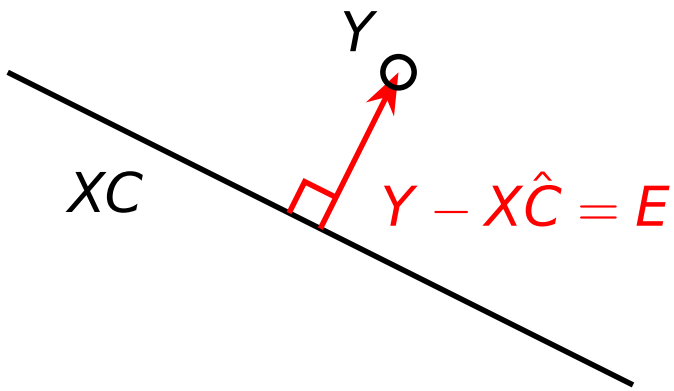
Пусть имеется плоскость, образуемая линейными комбинациями столбцов X; каждая её точка равна XC для некоторого C. Точка Y в общем случае не лежит в этой плоскости, т.е. какое бы C мы ни взяли, XC не совпадёт с Y идеально.



Вопрос: какая точка на XC будет ближе всего к Y? как её найти?

Геометрическая интерпретация (2)

Пусть имеется плоскость, образуемая линейными комбинациями столбцов X; каждая её точка равна XC для некоторого C. Точка Y в общем случае не лежит в этой плоскости, т.е. какое бы C мы ни взяли, XC не совпадёт с Y идеально.



Вопрос: какая точка на XC будет ближе всего к Y? как её найти?

Ответ: если опустить из Y на XC перпендикуляр, его основание будет кратчайшей точкой. В этой точке длина вектора $Y - XC = E$ будет наименьшей.

Решение

Вопрос: как найти нужное значение $C = \hat{C}$?

Решение

Вопрос: как найти нужное значение $C = \hat{C}$?
Ответ: Вектор $E = Y - X\hat{C}$ должен быть перпендикулярен всем векторам, образующим XC, т.е. столбцам X.

Вопрос: как записать условие «вектор V_1 перпендикулярен вектору V_2»?

Решение

Вопрос: как найти нужное значение $C = \hat{C}$?
Ответ: Вектор $E = Y - X\hat{C}$ должен быть перпендикулярен всем векторам, образующим XC, т.е. столбцам X.

Вопрос: как записать условие «вектор V_1 перпендикулярен вектору V_2»?
Ответ: простейший вариант — равенство нулю их скалярного произведения, т.е. $V_1^T V_2 = 0$.

В нашем случае можно сразу записать для всех столбцов X одновременно:

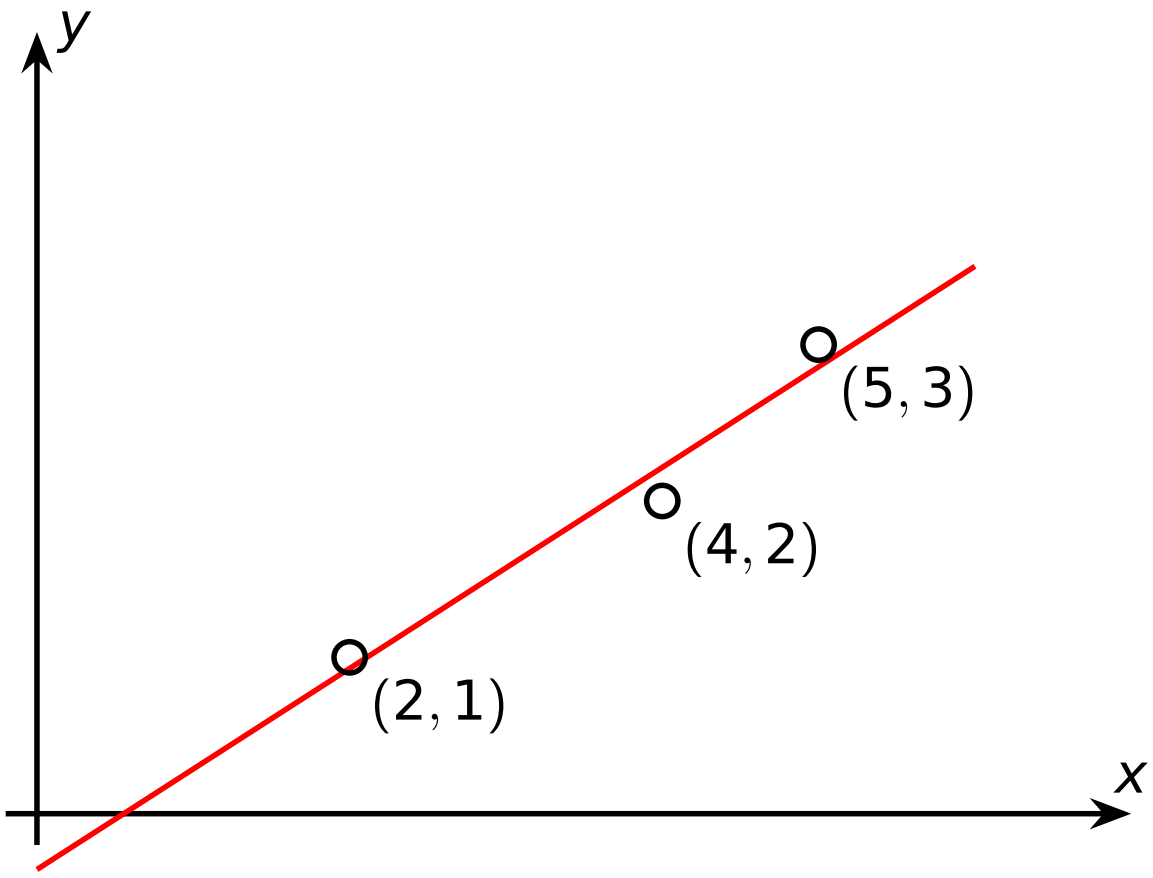
$$X^T(Y - X\hat{C}) = 0$$

и

$$\hat{C} = (X^T X)^{-1} X^T Y$$

Наконец, ответ

Решая уравнения, получим $\hat{C} \approx \begin{pmatrix} -0.357 \\ 0.643 \end{pmatrix}$



Избавление от линейности

Если хочется использовать этот метод для создания нелинейных аппроксимаций, можно искусственно дополнить систему параметров. Например, при наличии параметра x добавить к параметрам x^2, x^3 и т.д. для получения полинома вместо линейной функции. Результат называют **полиномиальной регрессией**.

Можно добавлять в параметры не только степени, но и любые другие их преобразования, которые подобраны из физического смысла задачи. Получится **криволинейная регрессия**.

Можно искусственно придавать разный **вес** разным прецедентам, чтобы по ним отклонения от правильного значения больше влияли на результат.