Практическая работа 1. Простейшие методы регрессии

Введение

Цель работы: освоить базовые приёмы генерации, обработки и вывода данных в выбранном для выполнения работы программном средстве, освоить простейшие методы регрессии (линейную, полиномиальную, лассо-, ридж- и др.).

Задачи: требуется выполнить регрессию двух разных типов на самостоятельно сгенерированных входных данных указанного вида. Номера типов входных данных и алгоритмов регрессии определяются по номеру варианта из таблицы 1. Пронумерованные описания входных данных находятся в таблице 2, пронумерованные описания алгоритмов — в таблице 3. Один из двух алгоритмов по выбору студента должен быть реализован без использования готовых процедур используемой библиотеки машинного обучения (разрешается применять только готовые методы матричной арифметики). Полные коды всех разработанных методов должны быть предоставлены для проверки; требуемые пояснения могут быть даны в виде комментариев к коду или отдельным документом любого нужного формата.

Порядок выполнения работы

Задание 1. По номеру варианта определить из таблицы 1 тип входных данных, которые надо программно сгенерировать для дальнейшей обработки, и номера алгоритмов, которые следует применить к этим данным.

Таблица 1. Варианты задания

Номер варианта	Номер типа входных данных	Номера алгоритмов
1	1	1,4
2	2	1,3
3	3	2,4
4	4	2,6
5	5	1,5
6	6	1,3
7	7	2,5
8	8	2,3
9	9	1,6
10	10	1,3
11	1	2,6
12	2	2,3
13	3	1,5
14	4	1,3
15	5	2,6
16	6	2,3
17	7	1,4
18	8	1,6
19	9	2,4
20	10	2,3

Задание 2. Определить из таблицы 2 вид входных данных, которые должны быть обработаны. Программно сгенерировать эти данные, вывести их в виде графика (диаграммы разброса). Количество прецедентов должно задаваться одной из переменных программы, чтобы допустить лёгкое изменение в процессе тестирования. Регрессионные модели должны предсказывать значения последней из координат точек по остальным.

Таблица 2. Типы входных данных

Номер типа	Описание
1	Точки двумерного пространства вида $(x, sin(x))$, где значения x — случайные числа из отрезка $[-\pi/2, \pi/2]$
2	Точки трёхмерного пространства вида $(x, y, x^2 - y^2)$, где x и y — случайные числа из отрезка $[0, 1]$
3	Случайные точки двумерного пространства, лежащие на верхней правой части полуокружности $x^2 + y^2 = 4$ (т.е. $x \geq 0$, $y \geq 0$) и имеющие на этой кривой равномерную функцию распределения
4	Случайные точки трёхмерного пространства, лежащие на поверхности сегмента сферы $x^2 + y^2 + z^2 = 4, x \geq 0, y \geq 0, z \geq 0$ и имеющие на этой поверхности любое произвольно выбранное распределение
5	Точки двумерного пространства вида (x, x^2), где значения x нормально распределены со средним 3 и среднеквадратическим отклонением 1
6	Точки трехмерного пространства вида $(x, y, x^2 + y)$, где значения x — нормально распределенные случайные числа со средним 1 и среднеквадратическим отклонением 1, значения y — случайные числа, равномерно распределенные по отрезку $[-1, 1]$
7	Точки двумерного пространства вида $(x, 0.01x + \varepsilon)$, где x — нормально распределённые случайные числа со средним 4 и среднеквадратическим отклонением 3, ε — нормально распределённые случайные числа со средним 0 и среднеквадратическим отклонением 0.1
8	Точки трёхмерного пространства вида $(x, y, 0.1y - 2x + \varepsilon)$, где x и y — нормально распределённые случайные числа со средним 1 и среднеквадратическим отклонением 3, ε — равномерно распределённые случайные числа из диапазона $[-0.1, 0.1]$
9	Точки двумерного пространства вида $(x, x^2 + \varepsilon)$, где x — нормально распределённые случайные числа со средним 0 и среднеквадратическим отклонением 2, ε — нормально распределённые случайные числа со средним 0 и среднеквадратическим отклонением 0.1
10	Точки трёхмерного пространства вида $(x, y, e^{x+y} + \varepsilon)$, где x и y — нормально распределённые случайные числа со средним 1 и среднеквадратическим отклонением 3, ε — равномерно распределённые случайные числа из диапазона $[-0.1, 0.1]$

Задание 3. Определить по таблице 3 методы обработки данных. Следует обработать выборку каждым из методов по отдельности и сравнить точности полученных регрессионных моделей (среднеквадратические значения ошибок на использованных выборках). Значения настроечных коэффициентов, если они требуются, следует выбрать самостоятельно; нулевые значения этих коэффициентов не допускаются.

Таблица 3. Типы алгоритмов обработки

Номер типа	Описание алгоритма
1	Линейная регрессия или полиномиальная регрессия (по выбору студента)
2	Ридж-регрессия либо лассо-регрессия (по выбору студента)
3	RANSAC
4	Сплайновая интерполяция кубическими сплайнами
5	Ядерное сглаживание с ядром в форме гауссианы
6	Гауссов процесс

При использовании библиотеки scikit-learn обязательно нужно ознакомиться с реализациями указанных методов по ссылкам:

- sklearn.linear_model.LinearRegression
- sklearn.linear_model.Ridge
- sklearn.linear_model.Lasso
- sklearn.linear_model.RANSACRegressor
- Polynomial and Spline interpolation
- sklearn.kernel_ridge.KernelRidge
- sklearn.gaussian_process.GaussianProcessRegressor

Задание 4. Создать новую выборку данных такого же размера и сравнить точность моделей на старой и новой выборках. Сделать вывод о сохранении точностных характеристик каждой из моделей.

Контрольные вопросы

1. Какие из перечисленных алгоритмов обработки устойчивы к выбросам?
2. Какие из перечисленных алгоритмов обработки удовлетворяют критерию максимального правдоподобия?
3. В каких ситуациях классическая линейная регрессия приводит к худшим результатам, чем лассо- или ридж-регрессии?
4. Как ширина функции ядра влияет на результаты сглаживания? На его устойчивость к выбросам?