Постановка задачи

Задано множество прецедентов X, все параметры которых — количественные (т.е. $x_k \in \mathbb{R}$). Ответы y равны 1 или -1. Требуется найти выражение вида

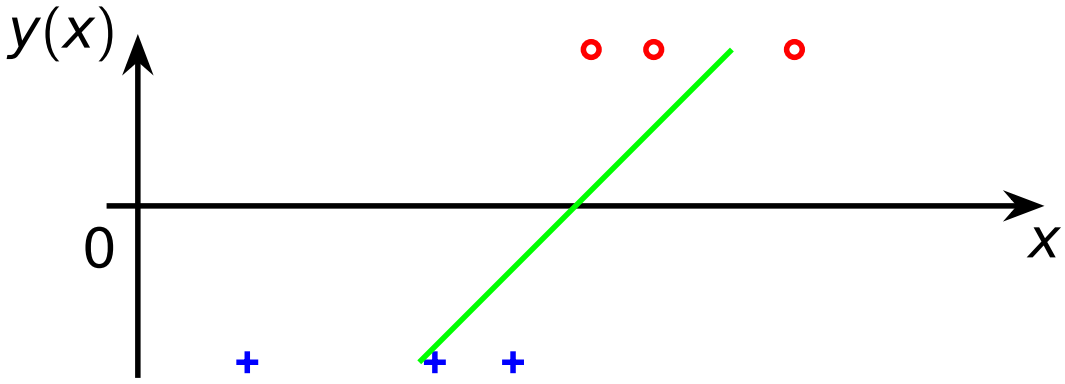
$$\hat{y} = sign(\sum_{k=1}^{N} c_k x_k + c_0),$$

которое достаточно хорошо приближает функцию y во всех точках — **линейный пороговый классификатор**.

$$sign(z) = \begin{cases} z > 0 \Rightarrow 1 \\ z = 0 \Rightarrow 0 \\ z < 0 \Rightarrow -1 \end{cases}$$

Пример для одномерного случая

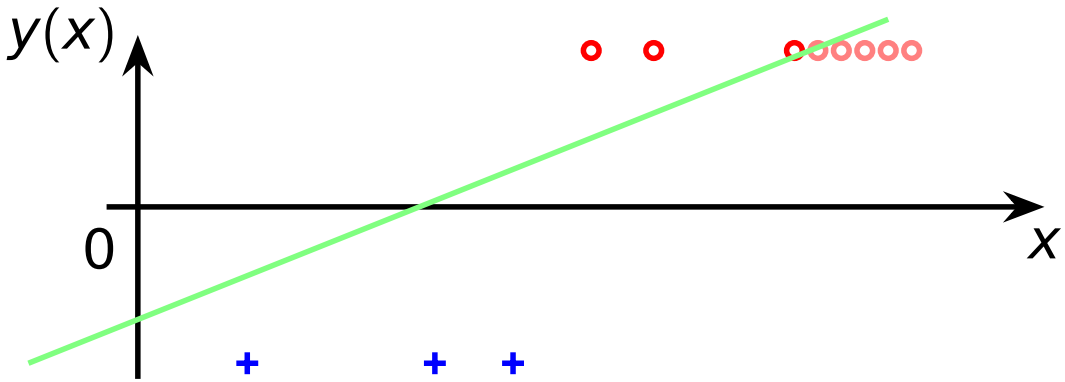
Пусть параметр у точки только один (обозначим его x). Обозначим объекты разных классов крестиками и ноликами. Тогда график функции-классификатора $y(x)$ может выглядеть, например, как эта зелёная линия:



Вопрос: а почему бы не использовать линейную регрессию для построения классификатора? Ведь получаемая ею линия пройдёт через те же точки, что и показанная на рисунке?

Пример для одномерного случая

Пусть параметр у точки только один (обозначим его x). Обозначим объекты разных классов крестиками и ноликами. Тогда график функции-классификатора $y(x)$ может выглядеть, например, как эта зелёная линия:



Вопрос: а почему бы не использовать линейную регрессию для построения классификатора? Ведь получаемая ею линия пройдёт через те же точки, что и показанная на рисунке?

Ответ: она окажется слишком чувствительной к малым изменениям выборки (например, к скоплениям кучи примеров в одном месте), причём результаты будут больше всего меняться в самой интересной пограничной области.

Постановка задачи оптимизации

Вопрос: что нужно, чтобы поставить задачу оптимизации в данном случае?

Постановка задачи оптимизации

Вопрос: что нужно, чтобы поставить задачу оптимизации в данном случае?

Ответ: нужно:

1. ввести функцию потерь $\mathbb{L}$, которая тем больше, чем сильнее отличия предсказаний от реальных результатов на выборке;
2. усреднить потери, получив функцию средних потерь на выборке;
3. возможно, модифицировать полученную функцию для повышения устойчивости;
4. указать полученную функцию E как минимизируемую на некотором множестве.

Вопрос: что будет, если функция потерь будет, как и раньше, квадратом или модулем уклонения?

Постановка задачи оптимизации

Вопрос: что нужно, чтобы поставить задачу оптимизации в данном случае?
Ответ: нужно:

1. ввести функцию потерь $\mathbb{L}$, которая тем больше, чем сильнее отличия предсказаний от реальных результатов на выборке;
2. усреднить потери, получив функцию средних потерь на выборке;
3. возможно, модифицировать полученную функцию для повышения устойчивости;
4. указать полученную функцию E как минимизируемую на некотором множестве.

Вопрос: что будет, если функция потерь будет, как и раньше, квадратом или модулем уклонения?
Ответ: она выродится в признак ошибки (1, если ошибка есть; 0, если нет).

Метод градиентного спуска

Общий подход к решению различных задач оптимизации.
Основная идея:

1. заручиться какой-либо начальной точкой (исходным значением параметров);
2. оценить, в какую сторону сильнее всего падает значение минимизируемой функции в данной точке при малых изменениях параметров;
3. найти новое значение параметров, сдвинутое относительно старого в сторону падения функции;
4. если значение функции после сдвига почти не изменилось (или возросло), минимум достигнут;
5. иначе снова перейти к пункту 2 относительно нового значения параметров.

То же более формально

Надо минимизировать среднее по выборке значение функции потерь $S(w) = \frac{1}{N}\sum_{i=1}^{N}\mathbb{L}(\hat{y}(x_i, w), y_i)$, где N — число элементов в выборке. Для этого:

1. выберем начальное значение параметров w;
2. рассчитаем градиент функции средних потерь на всей выборке $\nabla S = \{\frac{\partial S}{\partial w_i}\}|_{i=1..K}$, где K — число параметров
3. найдём новое значение параметров $w_{new} = w - \lambda\nabla S$, где λ — дополнительный параметр, скорость спуска;
4. проверить условие завершения: либо $S(w_{new}) > S(w)$, либо $|w_{new} - w| < \epsilon$ (есть и иные варианты). Если улучшения не произошло, минимум достигнут;
5. иначе снова перейти к пункту 2.

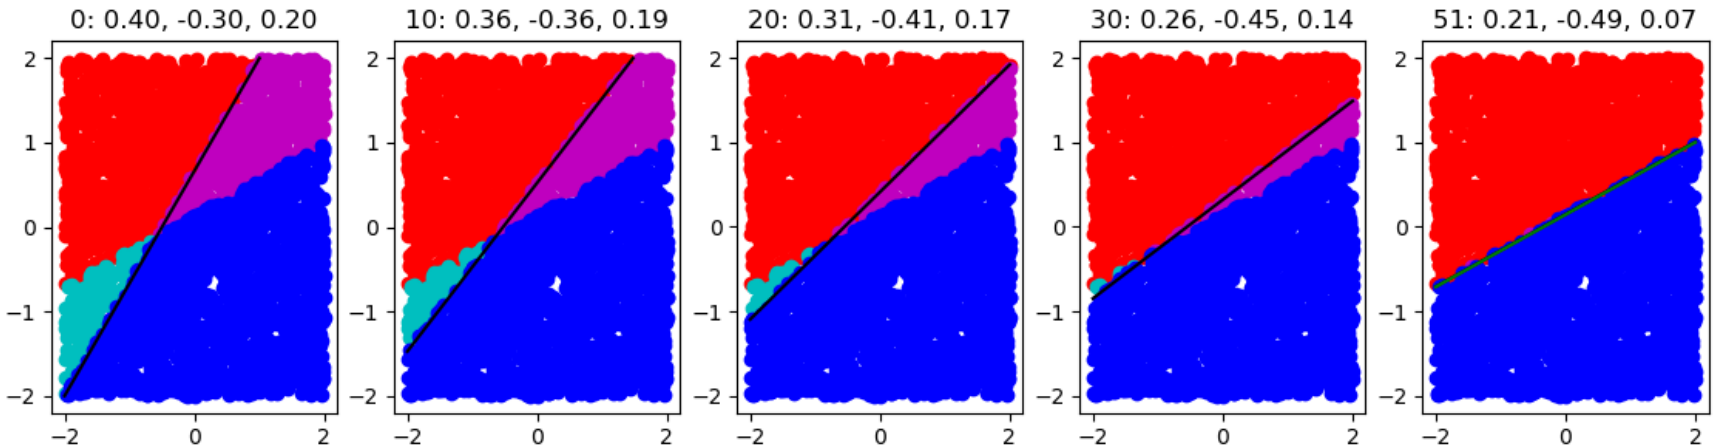
Пример использования

Пусть надо классифицировать точки квадрата на те, которые выше прямой, и те, которые ниже неё. **Вопрос:** как лучше записать уравнение прямой, разделяющей классы?

Пример использования

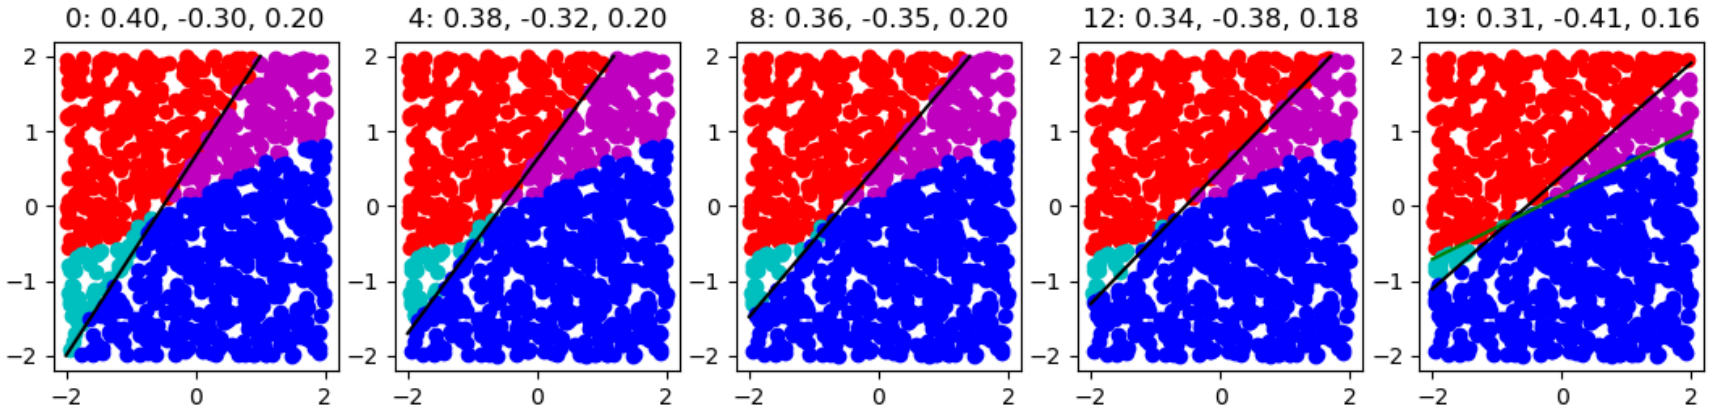
Пусть надо классифицировать точки квадрата на те, которые выше прямой, и те, которые ниже неё. **Вопрос:** как лучше записать уравнение прямой, разделяющей классы?
Ответ: $c_x x + c_y y + c = 0$

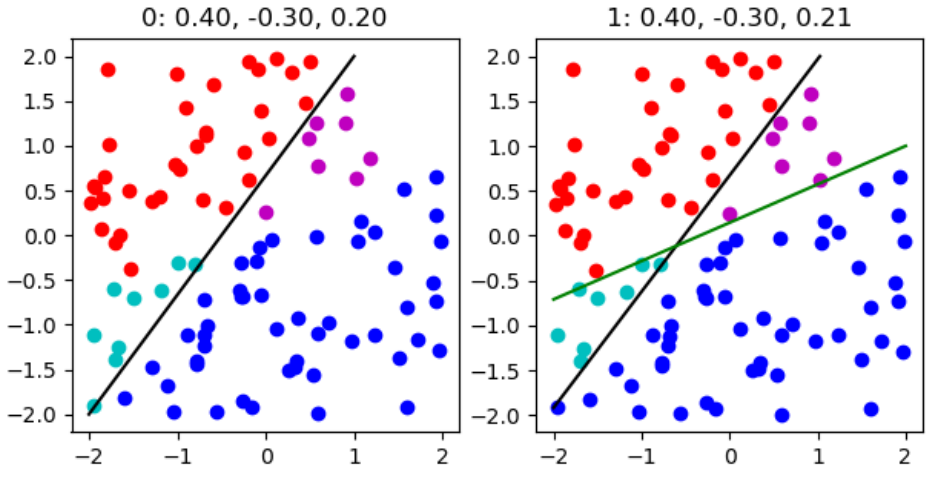
Правильная прямая $0.3x - 0.7y + 0.1 = 0$; пример результатов (красный и синий — верные ответы, остальные — неправильные):



Результаты при других размерах выборки

В прошлом варианте использовано 3000 точек. Если их будет меньше, результат часто оказывается хуже: Accuracy=0.92 для 1000 точек и 0.84 для 100 точек:





Причины проблем

Вопрос: почему результат при малом числе примеров стал хуже?

Причины проблем

Вопрос: почему результат при малом числе примеров стал хуже?
Ответ: если функция потерь — это точность (accuracy), то она теряет непрерывность и гладкость при малом числе примеров. Поэтому не всегда наилучшей функцией потерь при классификации является accuracy.

Вопрос: может ли результат зависеть от начального значения параметров, от небольших изменений входной выборки, от скорости спуска?

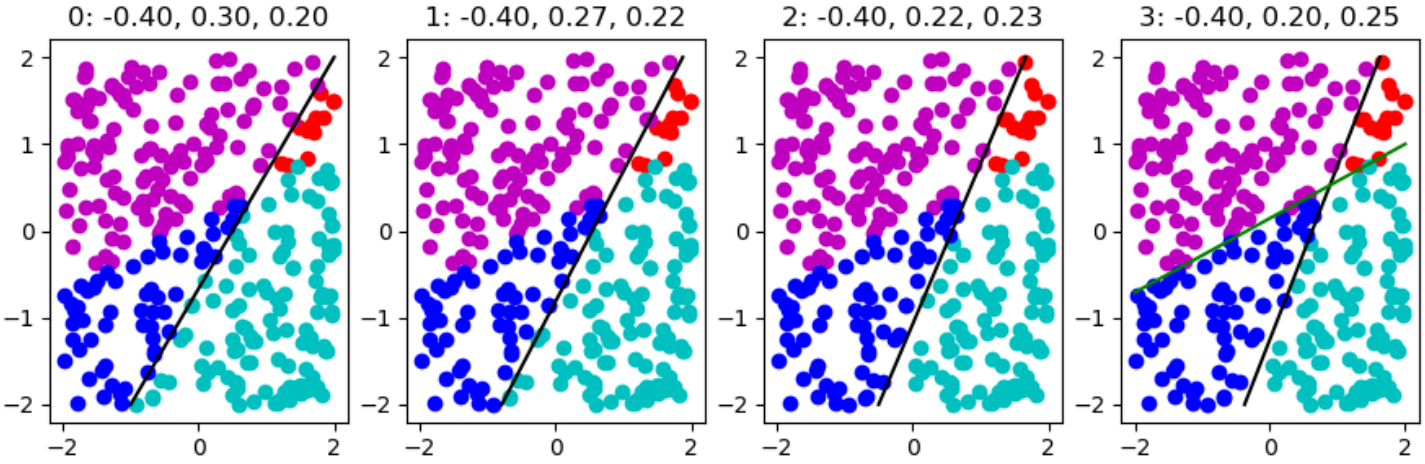
Причины проблем

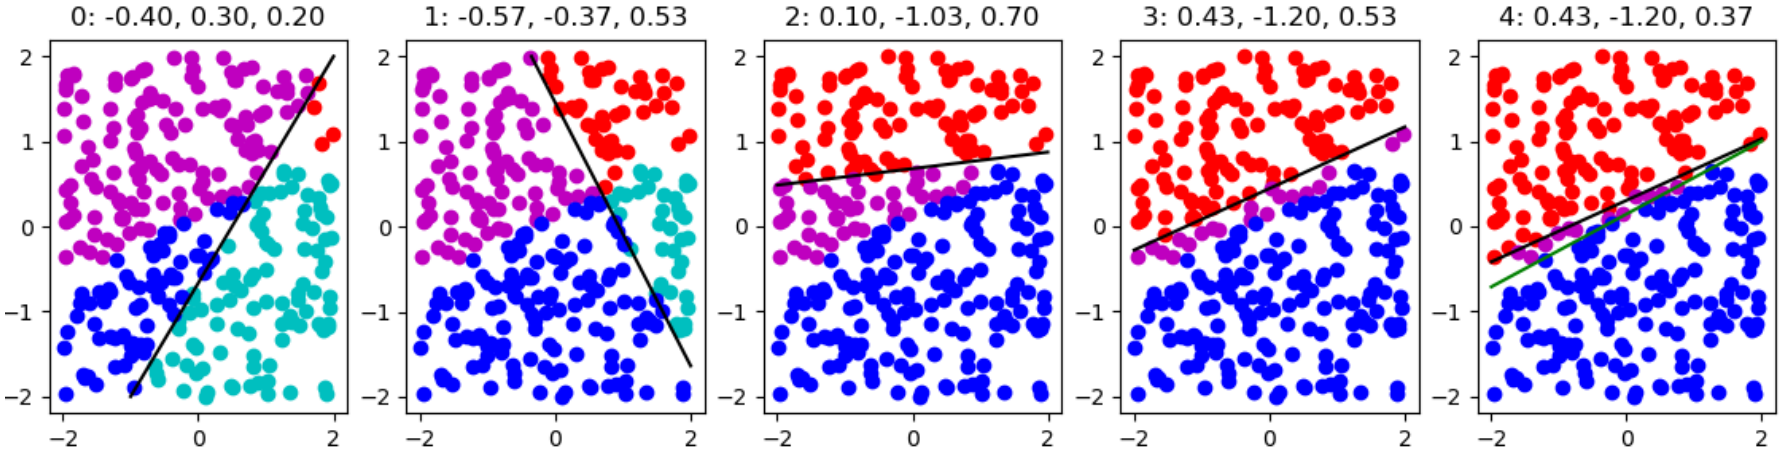
Вопрос: почему результат при малом числе примеров стал хуже?
Ответ: если функция потерь — это точность (accuracy), то она теряет непрерывность и гладкость при малом числе примеров. Поэтому не всегда наилучшей функцией потерь при классификации является accuracy.

Вопрос: может ли результат зависеть от начального значения параметров, от небольших изменений входной выборки, от скорости спуска?
Ответ: да, и сильно. Даже небольшие изменения в них могут приводить к успеху или неуспеху спуска.

Примеры проблем

Для двух выборок с близкими параметрами спуск из одного положения приводит к разным результатам: accuracy=0.29 и 0.96





Каковы слабые места у этого подхода?

Каковы слабые места у этого подхода?

- Начальное значение берётся наугад;
- ищется не глобальный минимум, а первый попавшийся;
- процесс может зациклиться;
- минимума можно не достигнуть из-за маленького градиента;
- на каждом шаге нужно перебрать всю выборку и не единожды.

Преодоление слабых мест

Начальное значение берётся наугад. **Вопрос:** что с этим делать?

Преодоление слабых мест

Начальное значение берётся наугад. **Вопрос:** что с этим делать?
Ответ: брать много разных вариантов и повторять спуск для них, затем выбирать лучший вариант.

Есть проблемы с достижением точного минимума. **Вопрос:** что с этим делать?

Преодоление слабых мест

Начальное значение берётся наугад. **Вопрос:** что с этим делать?
Ответ: брать много разных вариантов и повторять спуск для них, затем выбирать лучший вариант.

Есть проблемы с достижением точного минимума. **Вопрос:** что с этим делать?
Ответ:

- варьировать размеры шага (если не получается улучшить результат с большим шагом, уменьшим его);
- специально добавлять случайные шумы к параметрам на каждом шаге, чтобы выбираться из узких локальных минимумов.

Преодоление слабых мест (2)

На каждом шаге нужно перебрать всю выборку. **Вопрос:** что с этим делать?

Преодоление слабых мест (2)

На каждом шаге нужно перебрать всю выборку. **Вопрос:** что с этим делать?
Ответ: использовать для расчёта градиента на каждом шаге не всю выборку, а её часть (иногда даже один прецедент).

Вопрос: в чём проблема?

Преодоление слабых мест (2)

На каждом шаге нужно перебрать всю выборку. **Вопрос:** что с этим делать?
Ответ: использовать для расчёта градиента на каждом шаге не всю выборку, а её часть (иногда даже один прецедент).

Вопрос: в чём проблема?
Ответ: теперь неизвестно, насколько направление перехода совпадёт с градиентом (оно только его приближает). Если на каждом шаге используется случайная часть выборки, метод называется стохастическим градиентным спуском.

Преодоление слабых мест (3)

Если размах изменений разных параметров сильно отличается (на порядки), полезно нормализовать данные перед классификацией, т.е. линейно отобразить каждое из измерений для снижения этого эффекта. Часто добиваются нулевого среднего по каждому измерению и одинакового размаха или среднеквадратического отклонения.

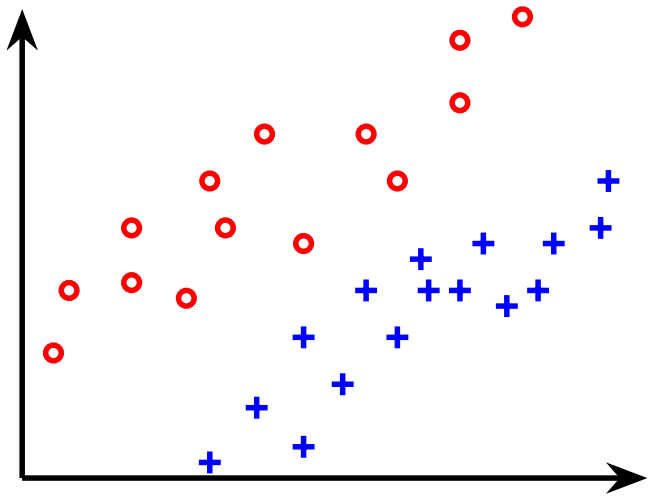
Полезно увеличить вероятность выбора ошибочного примера для очередного изменения градиента по сравнению с правильным примером.

Можно по аналогии с ридж-регрессией добавить в минимизируемую функцию норму вектора параметров, чтобы предотвратить их бесконтрольный рост (регуляризация по Тихонову).

Подробно поговорим об этом позднее, при обсуждении настройки нейронных сетей, т.к. многие из них используют этот подход.

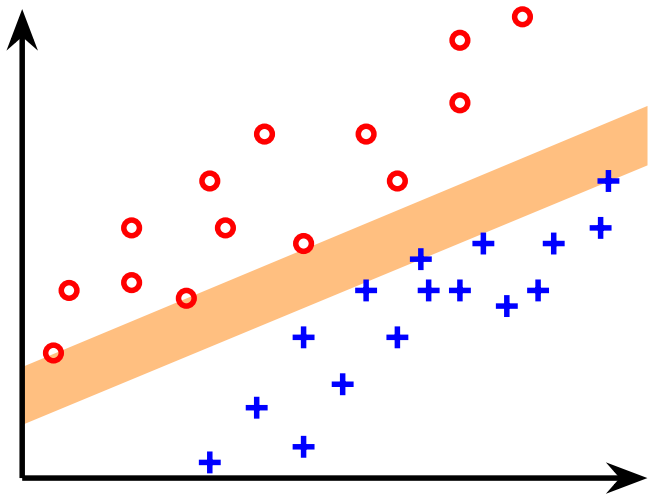
Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:



Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

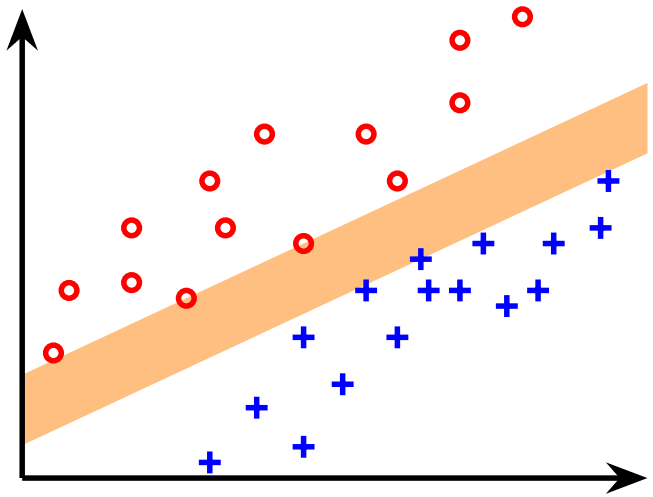


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

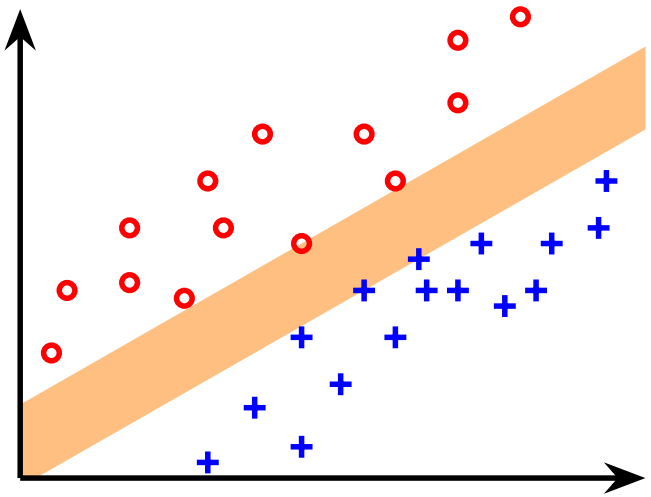


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

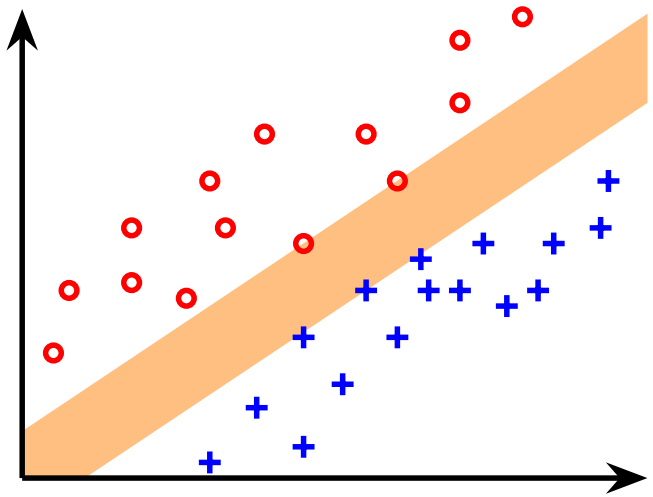


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

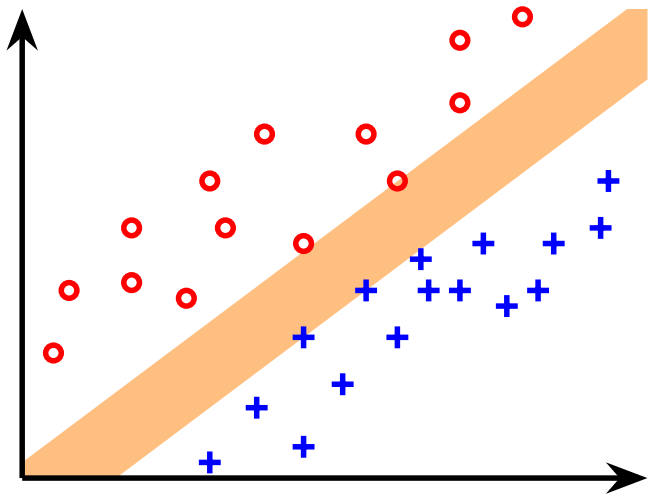


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

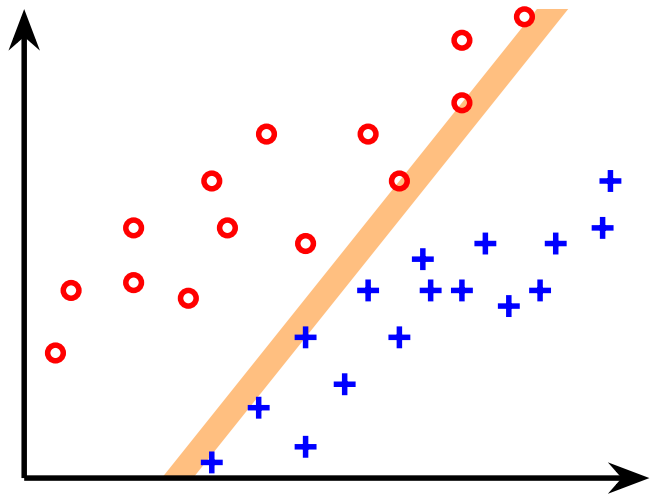


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

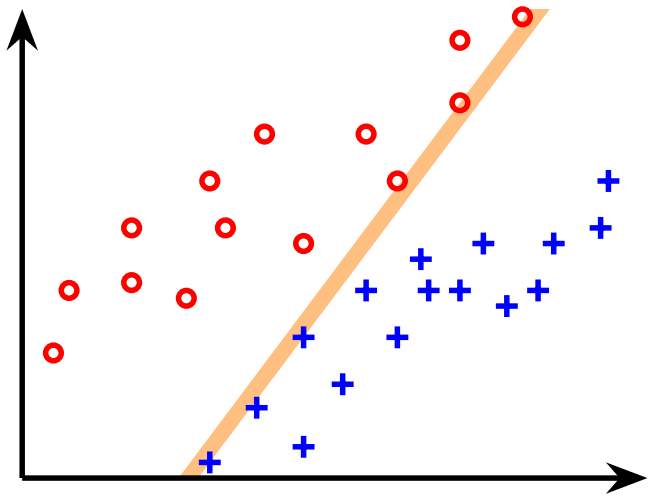


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:

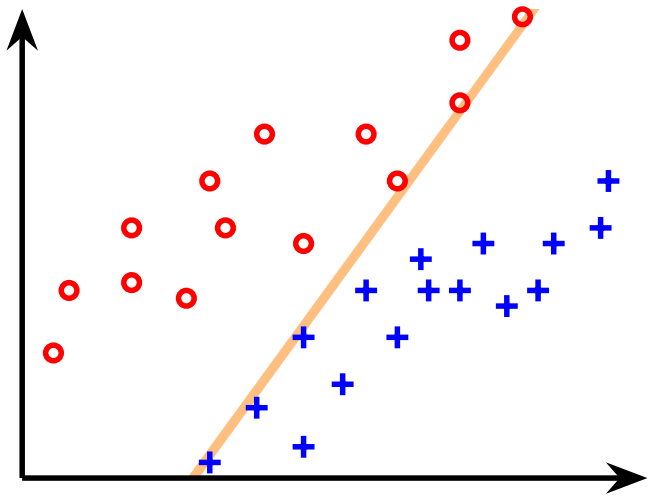


Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Линейная отделимость

Не обязательно искать линейную комбинацию параметров для построения функции-классификатора. Можно пойти другим путём — искать максимально широкую пустую полосу между линейно отделимыми классами:



Чем шире полоса, тем надёжнее классификация.

Очень важно: вид полосы определяет не вся выборка, а только немногие точки, ограничивающие её.

Система опорных векторов

SVM (Support Vector Machine): классификатор, строящий оптимальную разделяющую гиперплоскость.

Пусть классы выборки линейно отделимы. Тогда:

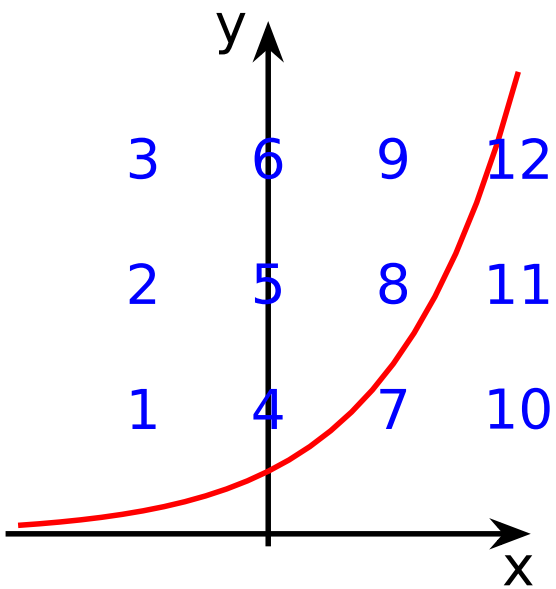
1. возьмём какую-нибудь разделяющую их гиперплоскость;
2. определим ширину полосы между классами, параллельной этой гиперплоскости;
3. оптимизируем положение гиперплоскости, чтобы ширина стала максимальной.

Далее покажем, что можно свести ситуацию к задаче квадратичной оптимизации, которая хорошо изучена и достаточно быстро решается.

Как добиться линейной отделимости?

Иногда можно дополнительно преобразовать данные, чтобы они стали линейно отделимыми.

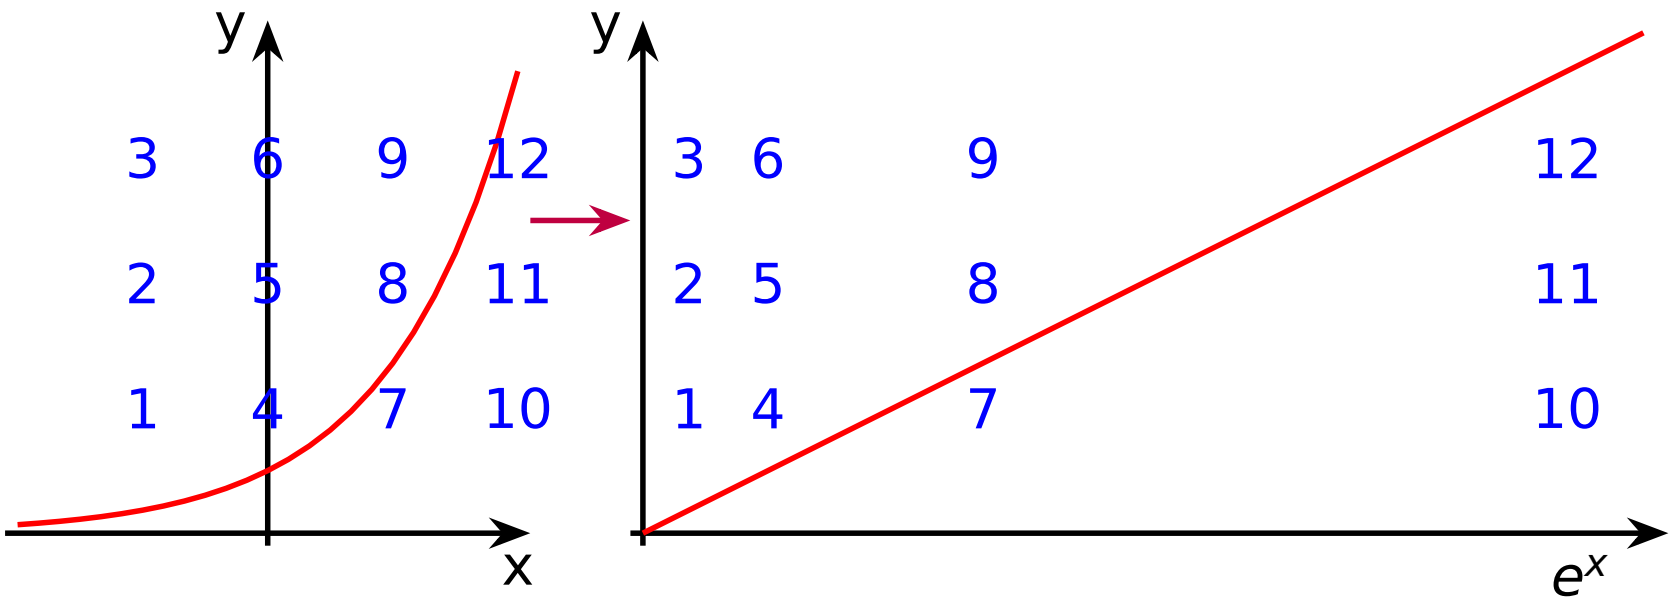
Вопрос: как линейно отделить точки (x, y), находящиеся выше графика $y = e^x$, от точек ниже него?



Как добиться линейной отделимости?

Иногда можно дополнительно преобразовать данные, чтобы они стали линейно отделимыми.

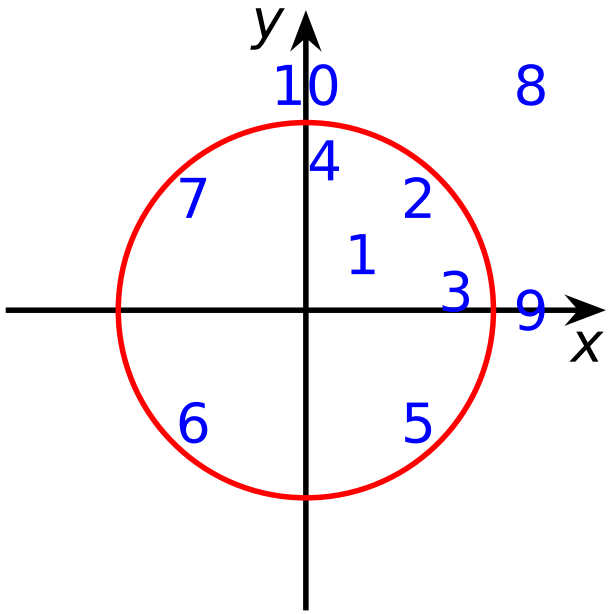
Вопрос: как линейно отделить точки (x, y), находящиеся выше графика $y = e^x$, от точек ниже него?



Ответ: сделать замену переменной $x_1 = e^x$; тогда можно отделить точки выше прямой $y = x_1$ от точек ниже неё.

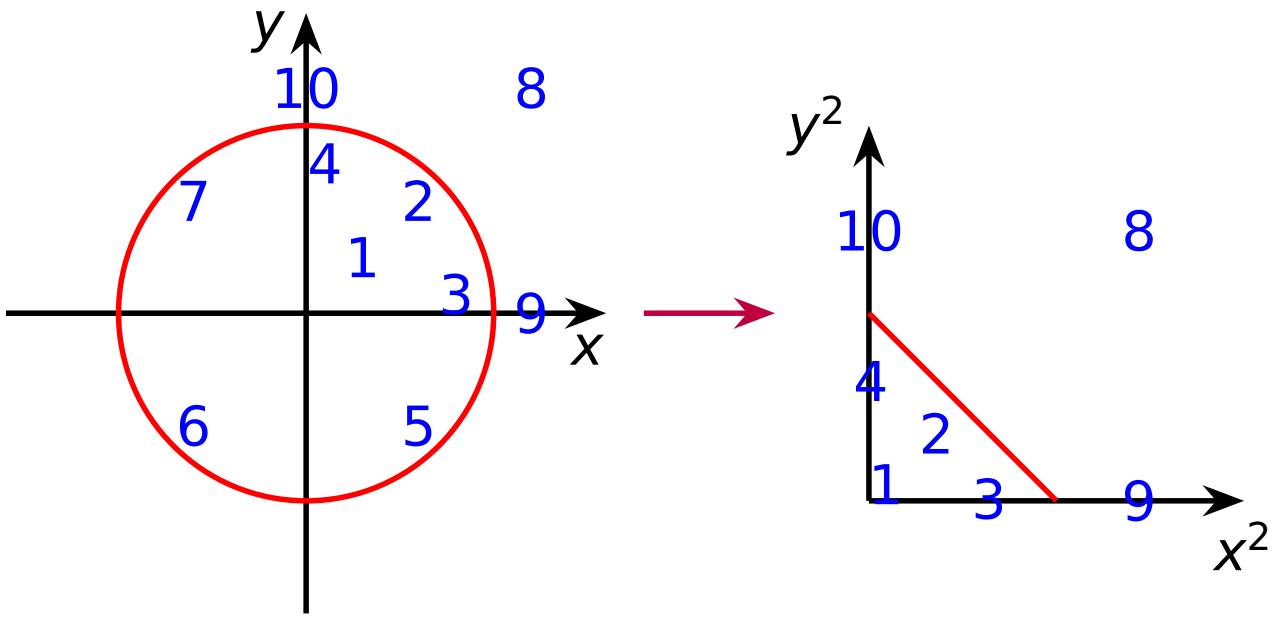
Как добиться линейной отделимости? (2)

Вопрос: а как линейно отделить точки внутри круга радиуса R от точек вне него?



Как добиться линейной отделимости? (2)

Вопрос: а как линейно отделить точки внутри круга радиуса R от точек вне него?



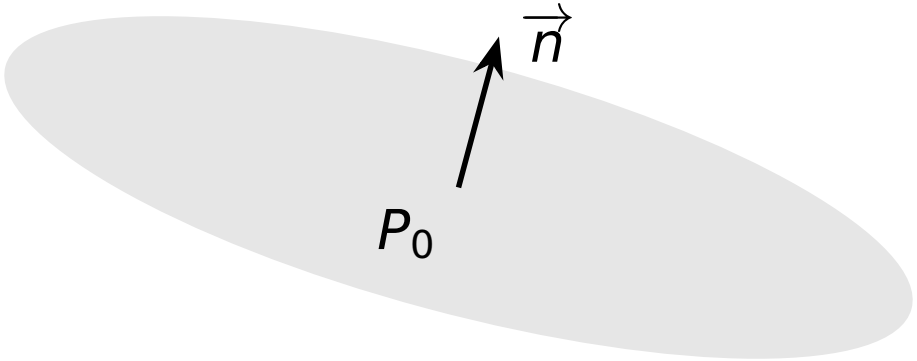
Ответ: уравнение круга: $x^2 + y^2 = R^2$. Заменим переменные $x_1 = x^2$, $y_1 = y^2$, и получим линейную отделимость относительно прямой $y_1 = R^2 - x_1$.
Симметричные точки 2,5,6,7 спроецируются в одну.

Что значит «две гиперплоскости параллельны»?

Что значит «две гиперплоскости параллельны»?

Ответ: векторы, перпендикулярные им, совпадают по направлению.

Выведем уравнение гиперплоскости, зная нормаль к ней $\vec{n}$ и какую-нибудь точку на ней P_0:

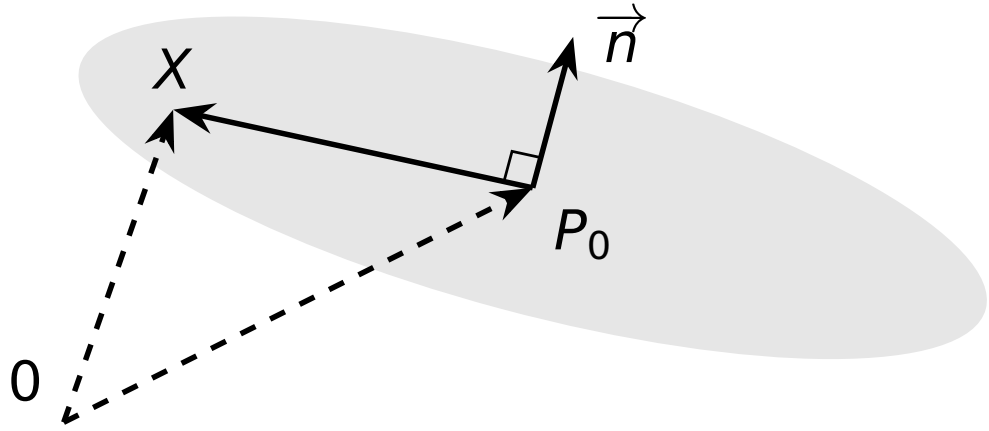


Вопрос: как оно выводится?

Вывод уравнения

Вектор от начала координат в любую точку гиперплоскости X:

$$\overrightarrow{0X} = \overrightarrow{0P_0} + \overrightarrow{P_0X} \Rightarrow \overrightarrow{P_0X} = \overrightarrow{0X} - \overrightarrow{0P_0}$$



Вектор $\overrightarrow{P_0X}$ перпендикулярен нормали $\overrightarrow{n}$, поэтому их скалярное произведение равно нулю:

$$(\overrightarrow{P_0X}, \overrightarrow{n}) = 0 = (\overrightarrow{0X} - \overrightarrow{0P_0}, \overrightarrow{n})$$

Это значит, что:

$$(\overrightarrow{0X}, \overrightarrow{n}) = (\overrightarrow{0P_0}, \overrightarrow{n}) = const$$

Итоговое уравнение гиперплоскости

$$(\overrightarrow{n}, \overrightarrow{X}) = b,$$

где $\overrightarrow{X}$ — вектор координат произвольной точки гиперплоскости, $\overrightarrow{n}$ — вектор нормали к этой гиперплоскости, b — скаляр-константа. С одной стороны от плоскости $(\overrightarrow{n}, \overrightarrow{X}) > b$, с другой $(\overrightarrow{n}, \overrightarrow{X}) < b$.

Классификатором является функция

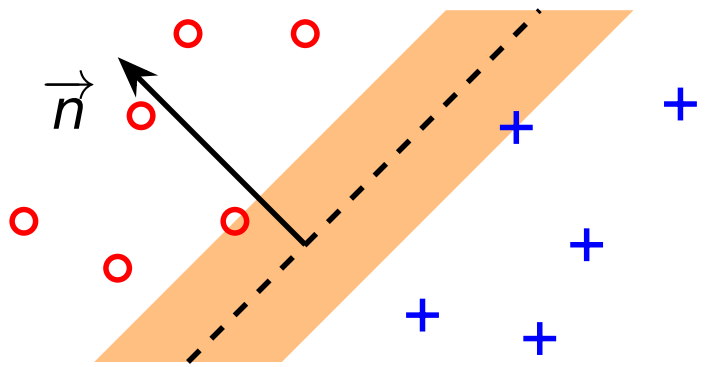
$$g(x) = sign((\overrightarrow{n}, \overrightarrow{X}) - b) = sign(\sum_{i=0}^{K} n_i x_i - b)$$

Задача: построить такой классификатор, ширина разделяющего промежутка у которого максимальна.

Построение границ разделяющего промежутка

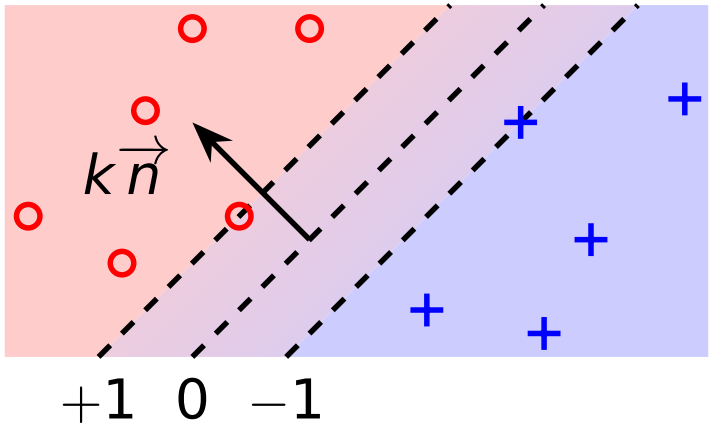
Пусть направление нормали к какой-либо разделяющей плоскости ($\vec{n}$) задано. Можно найти для этой нормали ширину разделяющего промежутка и провести разделяющую плоскость через его середину.

Края промежутка (плоскости, параллельные срединной) будут проходить через какие-либо элементы выборки, иначе можно было бы отодвинуть их дальше:



Нормировка

Домножим нормаль $\overrightarrow{n}$ разделяющей плоскости на постоянное число k так, чтобы $(\overrightarrow{kn}, \overrightarrow{X}) - b$ на одной краевой плоскости стала равна 1, на другой -1.



Ширина разделяющей полосы равна $\frac{2}{k|\overrightarrow{n}|}$, т.е. для получения максимально широкой полосы надо снизить $|\overrightarrow{n}|$.

Задача оптимизации

Надо найти минимальное значение длины вектора $\overrightarrow{n}$, чтобы при этом точки выборки оставались вне разделяющего промежутка, т.е. для каждой из них $(\overrightarrow{n}, \overrightarrow{X_i}) - b$ должно быть больше 1 (для одного класса) или меньше -1 (для другого класса).

Это означает, что надо минимизировать $|\overrightarrow{n}|^2$ при некоторых условиях, т.е. построена задача квадратичной оптимизации, решение которой даст оптимальную разделяющую плоскость.

$$\begin{cases} |n|^2 \to min(n, b) \\ (n, X_i) - b \geq 1, y(X_i) = 1 \\ (n, X_i) - b \leq -1, y(X_i) = -1 \end{cases}$$

Достоинства и недостатки

Достоинства:

- задача оптимизации ставится строго, решается за приемлемое время;
- классификация уверенная, т.к. разделение классов максимально широко.

Недостатки:

- неустойчивость к выбросам;
- нет отбора признаков (неизвестно, значимы они или незначимы).

Если нет линейной отделимости?

Можно внести штраф ξ в оптимизируемую функцию за каждый элемент выборки, классифицированный неправильно.

$$|n|^2 + C\sum_{i=1}^{K}\xi_i \to min,$$

где ξ_i — штраф за неправильную классификацию элемента номер i. При верной классификации $\xi_i = 0$.

$$\begin{cases} |n|^2 + C\sum_{i=1}^{K}\xi_i \to min(n,b) \\ (n,X_i) - b \geq 1 - \xi_i, y(X_i) = 1 \\ (n,X_i) - b \leq -1 + \xi_i, y(X_i) = -1 \\ \xi_i \geq 0, i = 1..K \end{cases}$$

Это сработает, но дополнительный весовой коэффициент $C > 0$ надо будет подбирать отдельно.

Этапы оптимизации в SVM

Для получения классификатора нужно решить задачу квадратичной оптимизации:

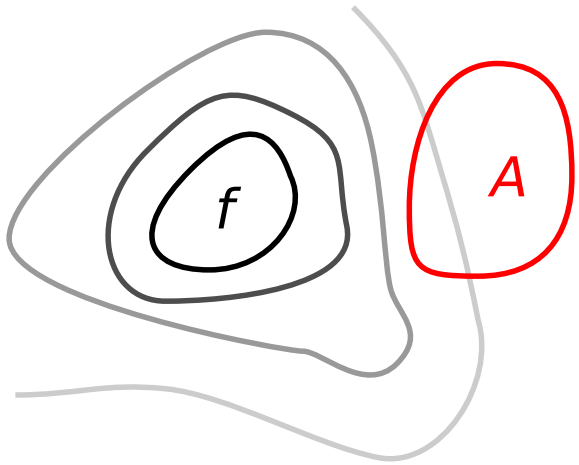
$$\begin{cases} |n|^2 + C\sum_{i=1}^{K}\xi_i \to min(n,b) \\ (n,X_i) - b \geq 1 - \xi_i, y(X_i) = 1 \\ (n,X_i) - b \leq -1 + \xi_i, y(X_i) = -1 \\ \xi_i \geq 0, i = 1..K \end{cases}$$

Основные этапы:

1. включить все ограничения в минимизируемую функцию;
2. найти необходимое условие седловой точки;
3. выразить решение через переменные, определяющие роль точки в выборке.

Включение ограничений в функцию

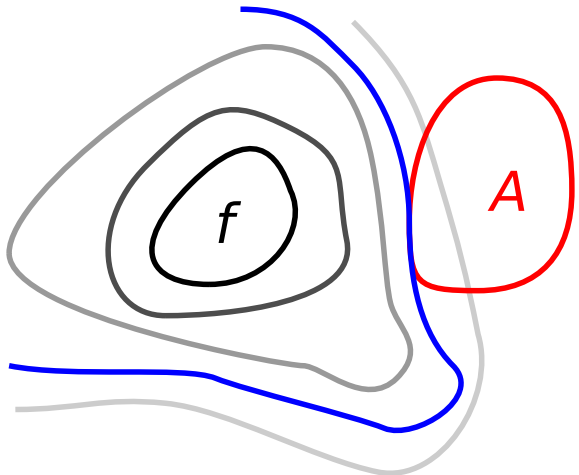
Пусть надо найти экстремум функции f в области A. Если экстремум находится не на границе A, то ограничения, наложенные на область, не влияют на результат. Пусть это не так. Рассмотрим линии уровня функции f (чем они темнее, тем f больше) совместно с границей области A:



Вопрос: если нужное максимальное значение f находится на границе области A, что можно сказать о взаимном расположении границы A и линий уровня f?

Включение ограничений в функцию

Пусть надо найти экстремум функции f в области A.
Если экстремум находится не на границе A, то ограничения, наложенные на область, не влияют на результат. Пусть это не так. Рассмотрим линии уровня функции f (чем они темнее, тем f больше) совместно с границей области A:



Вопрос: если нужное максимальное значение f находится на границе области A, что можно сказать о взаимном расположении границы A и линий уровня f?
Ответ: в точке экстремума A должна касаться линии уровня функции f.

Включение ограничений в функцию (2)

Вопрос: почему граница должна касаться линии экстремума?

Включение ограничений в функцию (2)

Вопрос: почему граница должна касаться линии экстремума?
Ответ: если бы это не было так, можно было бы продвинуться от текущей точки вдоль границы к местам, где функция f больше, т.е. найденная точка не была бы экстремумом.

Всё это значит, что в точке экстремума совпадают по направлению вектор градиента f и вектор нормали $\overrightarrow{n}(A)$ к границе A.

Если граница A имеет уравнение $g(X) = 0$, где g — некоторая функция, то нормаль к ней направлена как градиент ∇g.

Тогда в точке касания $\nabla f = \lambda \nabla g$, где λ — постоянная.

Включение ограничений в функцию (3)

Рассмотрим функцию $f(X) - \lambda g(X)$. Чтобы она достигла экстремума, нужно, чтобы её частные производные по всем составляющим X были равны нулю. Это то же самое, что $\nabla f - \lambda \nabla g = 0$. Тогда можно переписать задачу в виде:

$$|n|^2 + C\sum_{i=1}^{K} \xi_i + \sum_{j=1}^{L_1} \lambda_{1j}((n, X_j) - b - 1 + \xi_i) +$$

$$+ \sum_{j=1}^{L_2} \lambda_{2j}((n, X_j) - b + 1 - \xi_i) \to min(n, b)$$

т.е. занести внутрь функции все компоненты, относящиеся к условиям. То, что относится к ξ, уже занесено внутрь ранее.

Значения λ_{ij} могут быть нулевыми (когда условия, налагаемые ими, не имеют значения, т.е. соответствующая точка не влияет на классификацию) либо ненулевыми (когда точка является граничной или нарушает правила классификации).

Седловая точка

Чтобы точка была экстремумом функции, она должна быть седловой, т.е. все частные производные по n и b должны быть нулевыми. Частная производная от минимизируемой функции по каждому компоненту n равна

$$2n_k + \sum_{j=1}^{L_1} \lambda_{1j} X_{jk} + \sum_{j=1}^{L_2} \lambda_{2j} X_{jk} = 0$$

Это значит, что нормаль n надо искать в виде линейной комбинации тех точек выборки, для которых $\lambda \neq 0$. Такие точки называются опорными векторами.

Поиск нормали

Кстати, при взятии частной производной по b получаем

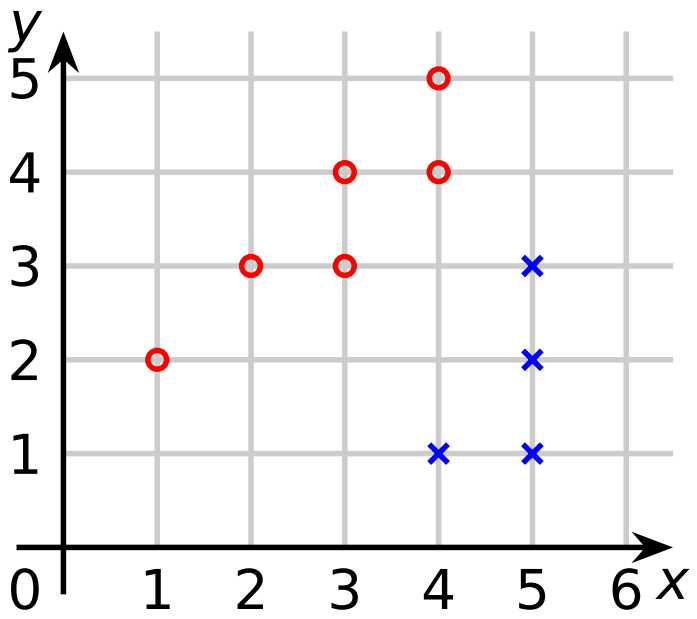
$$2n_0 + \sum_{j=1}^{L_1} \lambda_{1j} + \sum_{j=1}^{L_2} \lambda_{2j} = 0,$$

т.е. сумма значений λ с учётом классов нулевая.

Нормаль — линейная комбинация нескольких элементов выборки с коэффициентами λ. После подстановки формулы для неё в минимизируемую функцию получим выражение, квадратично зависящее от λ. При его решении часть λ занулится, потому что соответствующие этим λ точки не влияют на классификацию.

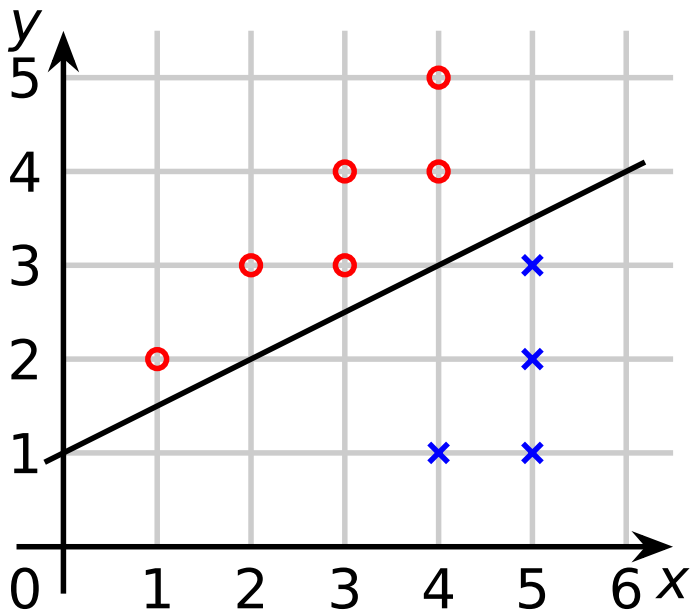
Пример классификации на SVM

Поставим задачу оптимизации для данной линейно отделимой выборки:



Пример классификации на SVM

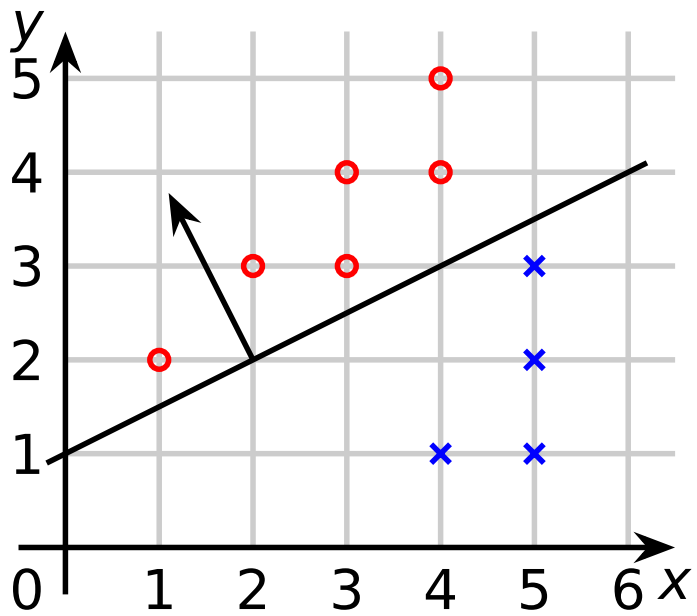
Поставим задачу оптимизации для данной линейно отделимой выборки:



Выберем какую-нибудь прямую, отделяющую один класс от другого — например, прямую $y = 0.5x + 1$.
Вопрос: какая у неё нормаль?

Пример классификации на SVM

Поставим задачу оптимизации для данной линейно отделимой выборки:

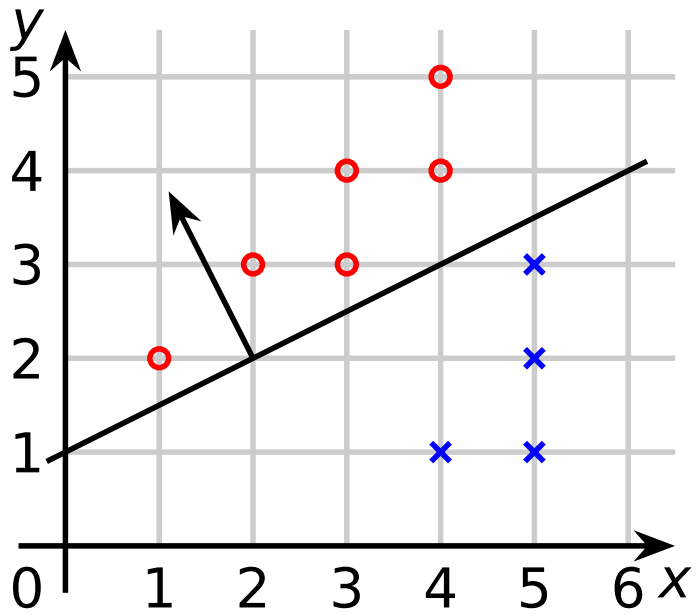


Ответ: любой вектор вида $(-\lambda, 2\lambda), \lambda \in \mathbb{R}\backslash\{0\}$. Возьмём пока наугад $\lambda = 0.9$.

Вопрос: как записать уравнение прямой $y = 0.5x + 1$ в виде $(\vec{n}, \overrightarrow{(x, y)}) = b$?

Пример классификации на SVM

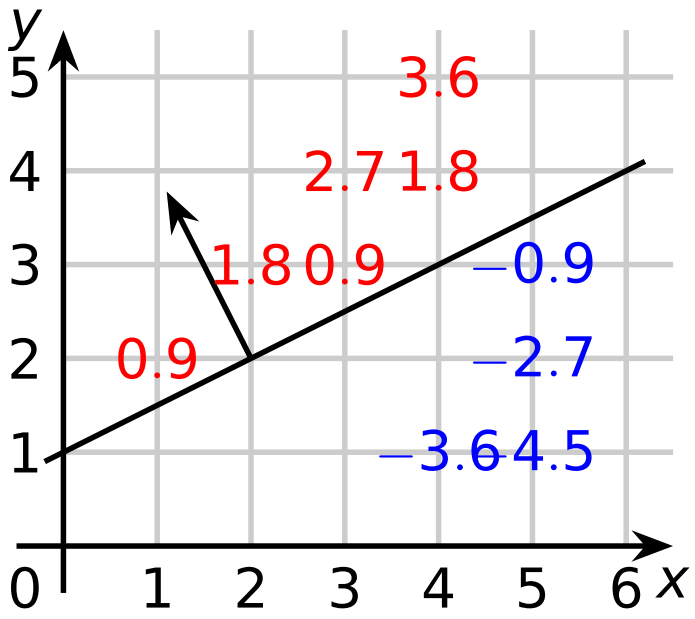
Поставим задачу оптимизации для данной линейно отделимой выборки:



Ответ: как было показано раньше: $(\overrightarrow{n}, \overrightarrow{(x,y)}) = b = (\overrightarrow{n}, \overrightarrow{P})$, где P — какая-нибудь точка на прямой. Если взять точку $P = (0,1)$, то $b = (\overrightarrow{n}, \overrightarrow{P}) = ((-0.9, 1.8), (0,1)) = 1.8$, т.е. $(\overrightarrow{n}, \overrightarrow{(x,y)}) = 1.8$

Пример классификации на SVM

Поставим задачу оптимизации для данной линейно отделимой выборки:

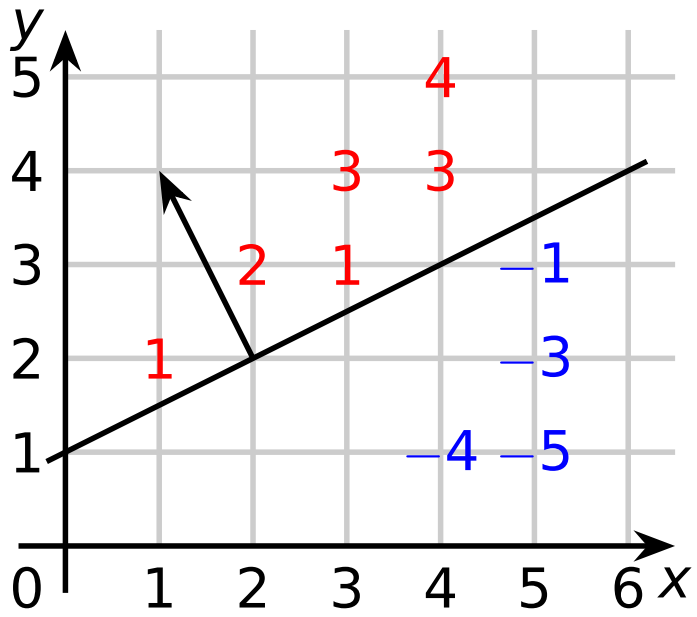


Посчитаем значение функции $f(\overrightarrow{(x,y)}) = (\overrightarrow{n}, \overrightarrow{(x,y)}) - b = -0.9x + 1.8y - 1.8$ для всех точек выборки.

Вопрос: как отмасштабировать f, чтобы её значения на одном классе были не меньше 1, а на другом не больше -1?

Пример классификации на SVM

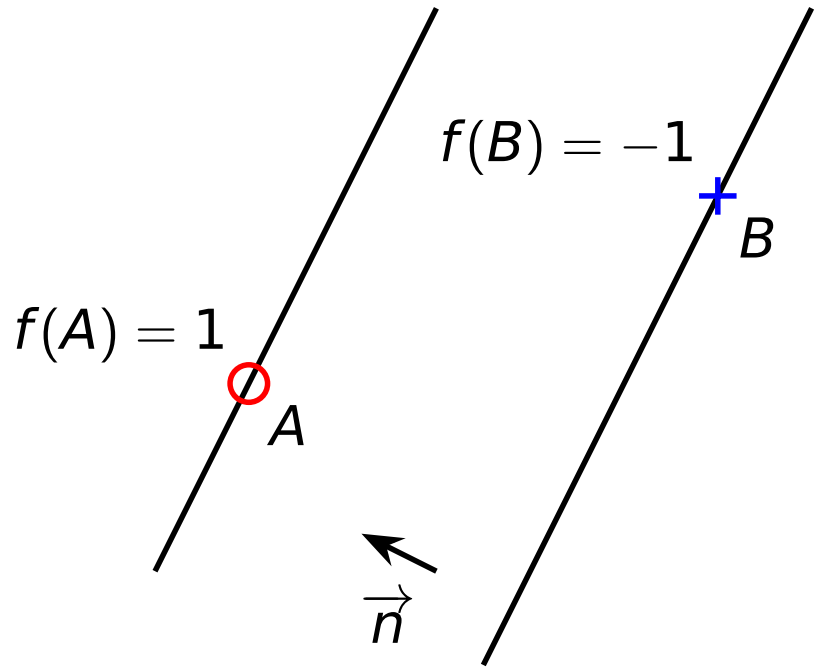
Поставим задачу оптимизации для данной линейно отделимой выборки:



Ответ: надо разделить f на 0.9: $f(x, y) = -x + 2y - 2$; в общем случае может понадобиться сместить её, изменив константу. Тогда **для данного направления нормали** мы получили нужную функцию. Для другого направления она, конечно, будет другой.

Ширина полосы

Пусть функция f подогнана правильно:



$f(P) = (\overrightarrow{n}, \overrightarrow{P}) - b$, при этом $f(A) = (\overrightarrow{n}, \overrightarrow{A}) - b = 1$,
$f(B) = (\overrightarrow{n}, \overrightarrow{B}) - b = -1$

Ширина полосы W — модуль проекции вектора $\overrightarrow{AB}$ на направление нормали.

$$W = |(\overrightarrow{AB}, \frac{\overrightarrow{n}}{|n|})| = \frac{|(\overrightarrow{B} - \overrightarrow{A}, \overrightarrow{n})|}{|n|} = \frac{|(\overrightarrow{B}, \overrightarrow{n}) - (\overrightarrow{A}, \overrightarrow{n})|}{|n|} = \frac{|b - 1 - (1 - b)|}{|n|} = \frac{2}{|n|}$$

Общие указания по задачам оптимизации

Задача оптимизации — поиск такого вектора параметров функции $f(\overrightarrow{X}) : \overrightarrow{X} \to \mathbb{R}$, что f примет минимальное значение.

Очень часто требуется также выполнение множества условий вида $g_i(\overrightarrow{X}) \leq 0, i = 1..M$ и/или $h_j(\overrightarrow{X}) = 0, j = 1..P$, т.е. поиск идёт не при всех возможных значениях $\overrightarrow{X}$, а только при некоторых.

Функция f может неограниченно убывать, тогда решения нет.

Кратко: решить задачу точно в общем случае получается не всегда, но во многих практически важных случаях она решается.

Линейная оптимизация

Самый простой случай: целевая функция f и все условия g и h линейны $\Rightarrow$ всегда можно найти точное решение или доказать, что его нет.

Простейший подход, пригодный даже для вычислений вручную — **симплекс-метод**. Сводится к перемещению по рёбрам выпуклого многогранника, образующего область допустимых значений, в сторону снижения целевой функции.

Более практичные — методы внутренней точки (пример: **алгоритм Кармаркара**): перемещение по внутренней части области допустимых значений с постепенным движением в сторону уменьшения целевой функции, что приводит к решению.

Нелинейная оптимизация

Общего метода решения нет, но есть достаточно хорошие, срабатывающие при допустимых для нашего случая условиях.

Условия Каруша-Куна-Таккера: если задача регулярная, можно вычислить возможные решения по стационарным точкам функции Лагранжа

Один из вариантов регулярной задачи — когда все ограничения линейны, т.е. наш случай.

Постановка задачи и её решение

В нашем примере к классу «1» принадлежат точки (1,2), (2,3), (3,3), (3,4), (4,4), (4,5), а к классу «–1» — точки (4,1), (5,1), (5,2), (5,3). Минимизировать будем длину $\overrightarrow{n}$, т.е. $n_x^2 + n_y^2$, а ограничения будут выглядеть как

$$
\begin{aligned}
(\overrightarrow{n}, (1,2)) - b &\geq 1 \\
(\overrightarrow{n}, (2,3)) - b &\geq 1 \\
(\overrightarrow{n}, (3,3)) - b &\geq 1 \\
&\dots \\
(\overrightarrow{n}, (4,5)) - b &\geq 1 \\
(\overrightarrow{n}, (4,1)) - b &\leq -1 \\
(\overrightarrow{n}, (5,1)) - b &\leq -1 \\
(\overrightarrow{n}, (5,2)) - b &\leq -1 \\
(\overrightarrow{n}, (5,3)) - b &\leq -1
\end{aligned}
$$

Преобразуем ограничения

Поменяем знаки во всех ограничениях на $\leq$, домножив часть из них на -1:

$$
\begin{aligned}
(-\overrightarrow{n}, (1,2)) + b &\leq -1 \\
(-\overrightarrow{n}, (2,3)) + b &\leq -1 \\
(-\overrightarrow{n}, (3,3)) + b &\leq -1 \\
&\dots \\
(-\overrightarrow{n}, (4,5)) + b &\leq -1 \\
(\overrightarrow{n}, (4,1)) - b &\leq -1 \\
(\overrightarrow{n}, (5,1)) - b &\leq -1 \\
(\overrightarrow{n}, (5,2)) - b &\leq -1 \\
(\overrightarrow{n}, (5,3)) - b &\leq -1
\end{aligned}
$$

Внесение ограничений в минимизируемую функцию

Занесём ограничения в функцию:

$$\begin{aligned}\mathbb{L}(n_x, n_y, b, \lambda_i) = \\ n_x^2 + n_y^2 &+ \lambda_1(-n_x - 2n_y + b + 1) + \lambda_2(-2n_x - 3n_y + b + 1) \\ &+ \lambda_3(-3n_x - 3n_y + b + 1) + \lambda_4(-3n_x - 4n_y + b + 1) \\ &+ \lambda_5(-4n_x - 4n_y + b + 1) + \lambda_6(-4n_x - 4n_y + b + 1) \\ &+ \lambda_7(4n_x + n_y - b + 1) + \lambda_8(5n_x + n_y - b + 1) \\ &+ \lambda_9(5n_x + 2n_y - b + 1) + \lambda_{10}(5n_x + 3n_y - b + 1)\end{aligned}$$

Теперь можно искать точки-кандидаты в решение.

Условия Каруша-Куна-Таккера

Чтобы точка $\mathbb{L}(n_x, n_y, b, \lambda_1, ..., \lambda_{10})$ была решением, *необходимо* (но не достаточно), чтобы выполнялись три условия:

1. стационарность: градиент целевой функции должен быть в ней нулевым: $\nabla\mathbb{L} = 0$
2. дополняющая нежёсткость: $\lambda_i g_i = 0$ для всех условий $g_i, i = 1..10$
3. неотрицательность: $\lambda_i \geq 0$

Из условия 2 понятно, что в решении для каждого i от 1 до 10 либо $\lambda_i = 0$ (т.е. соответствующая точка не вносит вклад в функцию), либо $g_i = 0$ (т.е. решение находится на границе условия). Если найти все пересечения условий g_i друг с другом и проверить их на равенство нулю градиентов и на выполнение других условий 2 и 3, можно найти конечное количество допустимых точек.

Проверка допустимости

Если попарно проверять пересечения условий друг с другом и их выполнение, можно определить, что ненулевыми будут только коэффициенты λ при точках (3,3), (4,4) и (5,3). Легко находим соответствующие λ, n_x, n_y, b.

Надо проверить для решения достаточное условие: если исходная задача выпуклая, то найденная точка — решение задачи оптимизации. У нас задача выпуклая. Решение найдено.

Как измерять близость векторов

В методе SVM классификатор включает величину $(\overrightarrow{n}, \overrightarrow{x})$.
Вопрос: каким должно быть направление $\overrightarrow{x}$ при фиксированном $\overrightarrow{n}$, чтобы $(\overrightarrow{n}, \overrightarrow{x})$ было максимальным? минимальным? нулевым?

Как измерять близость векторов

В методе SVM классификатор включает величину $(\overrightarrow{n}, \overrightarrow{x})$.
Вопрос: каким должно быть направление $\overrightarrow{x}$ при фиксированном $\overrightarrow{n}$, чтобы $(\overrightarrow{n}, \overrightarrow{x})$ было максимальным? минимальным? нулевым?
Ответ: при совпадении направлений произведение максимально, при противоположности — минимально, при ортогональности — нулевое.

Из-за этого можно интерпретировать скалярное произведение как своеобразную меру близости двух векторов. Почему бы не использовать вместо него какую-нибудь другую меру близости?

Мы уже знакомы с регрессией методом ядерного сглаживания: в функцию ядра $K(x_1, x_2)$ подставлялись две точки, и результат говорил о степени их близости. Что, если заменить скалярное произведение на ядро?

Kernel trick

Замена $(\overrightarrow{n}, \overrightarrow{x})$ на некоторую функцию $K(\overrightarrow{n}, \overrightarrow{x})$ называется **kernel trick**.
Вообще говоря, функция $K(\overrightarrow{n}, \overrightarrow{x})$ может быть произвольной, но на практике используют ядра со свойствами:

- симметричности: $K(x_1, x_2) = K(x_2, x_1)$;
- неотрицательной определённости:
  $\forall g : X \to \mathbb{R} : \int_X \int_X K(x_1, x_2) g(x_1) g(x_2) dx_1 dx_2 \geq 0$.

Смысл этих свойств — обеспечение достаточного сходства свойств ядра и скалярного произведения.

Математически использование ядра в SVM — попытка отобразить входные данные в такое пространство, где классы будут лучше линейно отделяться.

Примеры ядер

Чаще других применяются:

- Полиномиальное: $K(x_1, x_2) = ((x_1, x_2) + R)^d$;
- гауссово (часто называется RBF — radial basis function): $K(x_1, x_2) = exp[-\frac{||x_1 - x_2||}{2\sigma^2}]$;
- сигмоидальное: $K(x_1, x_2) = tanh(\gamma(x_1, x_2) + r)$;
- линейное — само скалярное произведение, если его понимать как ядро: $K(x_1, x_2) = (x_1, x_2)$.

Достоинство подхода: можно попытаться классифицировать линейно неотделимые данные более качественно; недостаток — непредсказуемость результата.

Тема 4

Вероятностные методы

Метрические методы

Вероятностные методы

Байесовская классификация
Наивный байесовский классификатор
Логистическая регрессия
Варианты оценки плотности
Нормальный дискриминантный анализ
Линейный дискриминант Фишера
Смеси распределений
EM-алгоритм
Смеси нормальных распределений

Задача классификации: повторение

Пусть имеется выборка — набор прецедентов $Z \subset X$, каждый из которых состоит из набора параметров $(x_1, x_2, ..., x_K)$ и правильного ответа (класса) $y \in Y$. $\varphi(Z, Y)$ — истинное совместное распределение значений $(x_1, x_2, ..., x_K, y)$, из которого получена выборка Z.

Требуется найти распределение вероятности γ, которое достаточно хорошо приближает φ.

Вопрос: а почему используются распределения вероятности φ и γ, а не целевая функция $f : X \to Y$ и решающая функция $g : X \to Y$?

Задача классификации: повторение

Пусть имеется выборка — набор прецедентов $Z \subset X$, каждый из которых состоит из набора параметров $(x_1, x_2, ..., x_K)$ и правильного ответа (класса) $y \in Y$. $\varphi(Z, Y)$ — истинное совместное распределение значений $(x_1, x_2, ..., x_K, y)$, из которого получена выборка Z.

Требуется найти распределение вероятности γ, которое достаточно хорошо приближает φ.

Вопрос: а почему используются распределения вероятности φ и γ, а не целевая функция $f : X \to Y$ и решающая функция $g : X \to Y$?
Ответ: чтобы учесть случай, когда для одного и того же набора параметров x в выборке может быть два разных ответа $y_1 \neq y_2$.

Вероятности: повторение

Пусть объекты принадлежат к классам c_1 или c_2, т.е. $Y = \{c_1, c_2\}$. **Вопрос:** что такое вероятность появления объекта с классом c_1 $P(c_1)$?

Вероятности: повторение

Пусть объекты принадлежат к классам c_1 или c_2, т.е. $Y = \{c_1, c_2\}$. **Вопрос:** что такое вероятность появления объекта с классом c_1 $P(c_1)$?
Ответ: доля объектов с указанным классом среди всех объектов.
Вопрос: эта вероятность может быть рассчитана по распределению φ (истинному) или γ (модельному)?

Вероятности: повторение

Пусть объекты принадлежат к классам c_1 или c_2, т.е. $Y = \{c_1, c_2\}$. **Вопрос:** что такое вероятность появления объекта с классом c_1 $P(c_1)$?
Ответ: доля объектов с указанным классом среди всех объектов.
Вопрос: эта вероятность может быть рассчитана по распределению φ (истинному) или γ (модельному)?
Ответ: только по истинному; по модельному можно её оценить.

Вопрос: что такое $P(x|c_1)$?

Вероятности: повторение

Пусть объекты принадлежат к классам c_1 или c_2, т.е. $Y = \{c_1, c_2\}$. **Вопрос:** что такое вероятность появления объекта с классом c_1 $P(c_1)$?
Ответ: доля объектов с указанным классом среди всех объектов.
Вопрос: эта вероятность может быть рассчитана по распределению φ (истинному) или γ (модельному)?
Ответ: только по истинному; по модельному можно её оценить.

Вопрос: что такое $P(x|c_1)$?
Ответ: условная вероятность: вероятность того, что конкретный набор параметров x появится у объекта класса c_1.

Вопрос: а что такое $P(c_1|x)$?

Вероятности: повторение

Пусть объекты принадлежат к классам c_1 или c_2, т.е. $Y = \{c_1, c_2\}$. **Вопрос:** что такое вероятность появления объекта с классом c_1 $P(c_1)$?
Ответ: доля объектов с указанным классом среди всех объектов.
Вопрос: эта вероятность может быть рассчитана по распределению φ (истинному) или γ (модельному)?
Ответ: только по истинному; по модельному можно её оценить.

Вопрос: что такое $P(x|c_1)$?
Ответ: условная вероятность: вероятность того, что конкретный набор параметров x появится у объекта класса c_1.

Вопрос: а что такое $P(c_1|x)$?
Ответ: вероятность того, что объект с набором параметров x принадлежит к классу c_1

Пример: вероятность заболевания

Предположим, что существует редкое опасное тропическое заболевание, которым болеют 8 тысяч человек на планете (из 8 миллиардов жителей). Пусть имеется тест, который распознаёт это заболевание, но допускает ошибку в 1%:

- если человек болеет, то с вероятностью 99% тест покажет, что он болеет;
- если человек здоров, то с вероятностью 99% тест покажет, что он здоров.

Пусть для какого-то человека тест показал, что он болеет. **Вопрос:** какова вероятность того, что этот человек на самом деле болеет? Каковы характеристики точности у этого теста — accuracy, precision, recall?

Априорные и апостериорные вероятности

Априорная вероятность некоего события — его вероятность в соответствии с истинным распределением $\varphi(Z, Y)$, т.е. вероятность без всяких дополнительных требований к произошедшим событиям.
Апостериорная вероятность — вероятность, оцененная по результатам некоторых экспериментов с истинным распределением $\varphi(Z, Y)$ (в нашем случае — по выборке Z).

$$P(x, y) = P(y)P(x|y) = P(x)P(y|x)$$

т.е. вероятность того, что в выборке появится конкретный набор значений (x, y), может быть выражена через условные вероятности компонентов этого набора.

Значение $P(x|y)$ — **функция правдоподобия** класса x.

Если бы целевое распределение было бы известно...

Допустим, целевое распределение известно, т.е. известна истинная вероятность каждого сочетания (x, y). Как предсказать y по x так, чтобы вероятность именно такого y была максимальна?

Вероятность того, что объект с параметрами x принадлежит классу y_i:

$$P(y_i|x) = \frac{P(y_i)P(x|y_i)}{P(x)}$$

Тогда нужно выбрать класс y_i, дающий максимальную $P(y_i|x)$.

Средний выигрыш

Допустим, для каждого класса $i, i = 1..K$ известна величина выигрыша при его правильном распознавании q_i, а для каждой пары классов i, j: $i \neq j$ известна величина штрафа $q_{i,j}$, если ошибочно принять i за j. Удобно представить их вместе матрицей выигрышей Q:

$$Q = \begin{pmatrix} q_1 & q_{1,2} & \dots \\ q_{2,1} & q_2 & \dots \\ \dots & \dots & \dots \end{pmatrix}$$

Средний выигрыш для классификатора $C : X \to Y$:

$$\hat{Q} = \sum_{i=1}^{K} q_i P(i) P(x|i)[C(x) = i] - \sum_{i=1}^{K} \sum_{j=1, i \neq j}^{K} q_{i,j} P(i) P(x|i)[C(x) = j]$$

Если все $q_i = 0$, а все $q_{i,j} = 1$, то $-\hat{Q}$ — вероятность ошибки классификатора.

Максимизация выигрыша

Выигрыш будет максимален для классификатора, который для данного x выбирает класс a с наибольшим значением функции

$$q_a P(a)P(x|a) - \sum_{i=1,i\neq a}^{K} q_{i,a} P(i)P(x|i)$$

В частности, для снижения вероятности ошибки надо выбрать класс a с минимальным значением величины

$$\sum_{i=1,i\neq a}^{K} P(i)P(x|i)$$

или, что то же самое, с максимальным значением $P(a)P(x|a)$.

Но ведь целевое распределение неизвестно?

Если бы оно было известно, по указанным формулам можно было бы всё посчитать. В реальности надо его оценивать и потом применять эти формулы.

Если принять, что все признаки, входящие в x, независимы, решение получается очень простым.
Пусть элемент выборки включает в себя n параметров: $x = (x_1, x_2, ..., x_n)$. Пусть каждый из них — независимая от других случайная величина. Тогда плотность вероятности всего x равна произведению плотностей вероятности каждого из параметров:

$$\gamma((x_1, x_2, ..., x_n), y) = \gamma_1(x_1, y)\gamma_2(x_2, y)...\gamma_n(x_n, y)$$

Оценка плотностей по выборке

Вопрос: как оценить плотности распределений вероятности для каждого из параметров по имеющейся выборке Z?

Оценка плотностей по выборке

Вопрос: как оценить плотности распределений вероятности для каждого из параметров по имеющейся выборке Z?
Ответ: есть разные варианты. Если и параметр, и ответ категориальные (т.е. имеется конечное множество их значений), то всё просто: в таблицу со всеми возможными сочетаниями параметра и ответа заносятся численности каждой пары, после чего они нормируются на общее число элементов в выборке.

Если параметр или ответ численные, придётся использовать отдельные методы, некоторые из которых рассмотрим позже (линейный дискриминант Фишера, нормальный дискриминантный анализ, радиальные базисные функции).

Наивный байесовский классификатор

Пусть оценки плотности распределений $\hat{\gamma_1}(x_1, y)$, $\hat{\gamma_2}(x_2, y)$ и т.п. известны. Тогда

$$\hat{\gamma}((x_1, x_2, ..., x_n), y) = \hat{\gamma_1}(x_1, y)\hat{\gamma_2}(x_2, y)...\hat{\gamma_n}(x_n, y)$$

и можно выбирать класс, максимизирующий выигрыш (при данных коэффициентах-выигрышах либо штрафах) или минимизирующий шанс ошибок указанным выше способом.

Байесовский классификатор, предполагающий независимость признаков друг от друга, называется **наивным** (т.к. это предположение обычно неверно). Он используется только благодаря простоте реализации.

Пример байесовского классификатора

Пусть для некоторых объектов надо научиться предсказывать их класс y, который может быть равен $e0$ или $e1$, по двум параметрам $x_1 \in \{c0, c1\}$ и $x_2 \in \{d0, d1\}$. Выборка включает следующие прецеденты:

x_1	x_2	y
$c0$	$d1$	$e0$
$c0$	$d0$	$e1$
$c1$	$d1$	$e0$
$c1$	$d0$	$e0$
$c1$	$d1$	$e1$

Проведём наивную байесовскую классификацию. Для этого составим распределения вероятностей отдельно по каждому из параметров и предсказываемому классу $\hat{\gamma}(x_1, y)$ и $\hat{\gamma}(x_2, y)$.

Пример байесовского классификатора (2)

Посчитаем число случаев, когда каждая из пар появилась в выборке:

x_1 и y:

	$e0$	$e1$
$c0$	1	1
$c1$	2	1

x_2 и y:

	$e0$	$e1$
$d0$	1	1
$d1$	2	1

Тогда распределения вероятностей будут такими:

$\hat{\gamma_1}(x_1, y)$:

	$e0$	$e1$
$c0$	1/5	1/5
$c1$	2/5	1/5

$\hat{\gamma_2}(x_2, y)$:

	$e0$	$e1$
$d0$	1/5	1/5
$d1$	2/5	1/5

Пример байесовского классификатора (3)

По ним можно оценить, например

$$\hat{\gamma}((c0, d1), e0) = \hat{\gamma_1}(c0, e0)\hat{\gamma_2}(d1, e0) = \frac{1}{5}\frac{2}{5} = \frac{2}{25}$$

В каждом возможном случае предсказания наивного классификатора $\hat{y}$ будут равны:

x_1	x_2	$\gamma(e0)$	$\gamma(e1)$	$\hat{y}$
$c0$	$d0$	1/25	1/25	неопределённость
$c0$	$d1$	2/25	1/25	$e0$
$c1$	$d0$	2/25	1/25	$e0$
$c1$	$d1$	4/25	1/25	$e0$