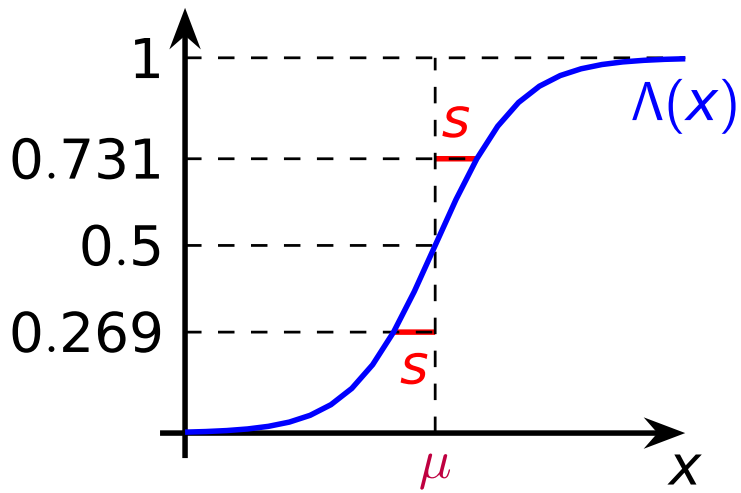
Логистическая регрессия

Метод классификации (не регрессии!), использующий байесовский подход для поиска линейного классификатора.

Для определённости задачи: пусть классов два: 0 и 1; все признаки — только численные.

Идея: попытаться подогнать к имеющимся данным логистическую функцию (сигмоиду):

$$\Lambda(x) = \frac{1}{1 + e^{-(x-\mu)/s}}$$



выровняв её по направлению и размаху так, чтобы она предсказывала вероятность принадлежности прецедента к одному из классов.

Более точный вид уравнения

Вопрос: что значит «выровнять сигмоиду по направлению и размаху»?

Более точный вид уравнения

Вопрос: что значит «выровнять сигмоиду по направлению и размаху»?
Ответ: линейно преобразовать параметры к требуемому для подстановки в неё виду, т.е.

$$\Lambda(\vec{X}) = \frac{1}{1 + e^{-((\vec{w}, \vec{X}) + b)}},$$

где $\vec{X}$ — вектор элемента выборки, $\vec{w}$ и b — подбираемые значения. По ним можно рассчитать коэффициенты сигмоиды μ и s.

Т.е. необходимо организовать подбор так, чтобы значение сигмоиды действительно соответствовало вероятности (а не некоей абстрактной характеристике, имеющей диапазон [0, 1]). Чтобы это было возможно, придётся ограничить допустимые распределения входных данных φ.

Формализация: требования к функциям распределения

Функция плотности распределения $p(\overrightarrow{X})$ называется **экспонентной**, если её можно выразить как:

$$p(\overrightarrow{X}) = exp[(\theta, \overrightarrow{X})a(\delta) + b(\delta, \theta) + c(\overrightarrow{X}, \delta)],$$

где θ и δ — постоянные значения (вектор сдвига и разброс); $a(\delta)$, $b(\delta, \theta)$ и $d(\overrightarrow{X}, \delta)$ — произвольные функции указанных одного или двух параметров.

Требования:

1. все функции правдоподобия $p(X|y)$ являются экспонентными;
2. у них у всех один разброс (δ);
3. среди признаков вектора X есть константа (если её нет, просто добавим к каждому вектору число «-1»).

Оптимальный классификатор (1)

Для двух классов оптимальный байесовский классификатор можно представить в виде

$$c(\overrightarrow{X}) = sign[q_1 P(class1|\overrightarrow{X}) - q_2 P(class2|\overrightarrow{X})],$$

т.е. то, к какому классу относится $\overrightarrow{X}$, определяется вероятностями каждого класса при условии $\overrightarrow{X}$ и выигрышами. Разделим правую часть на $q_1 P(class2|\overrightarrow{X})$ и получим

$$c(\overrightarrow{X}) = sign(\frac{P(class1|\overrightarrow{X})}{P(class2|\overrightarrow{X})} - \frac{q_2}{q_1})$$

Отношение вероятностей можно расписать как

$$\frac{P(class1|\overrightarrow{X})}{P(class2|\overrightarrow{X})} = \frac{P(class1)P(\overrightarrow{X}|class1)}{P(class2)P(\overrightarrow{X}|class2)}$$

Оптимальный классификатор (2)

Воспользуемся требованием 1 (экспонентностью распределений вероятностей):

$$\frac{P(class1)P(\overrightarrow{X}|class1)}{P(class2)P(\overrightarrow{X}|class2)} = exp[((a_1(\delta)\theta_1 - a_2(\delta)\theta_2), \overrightarrow{X})+$$

$$+b_1(\delta,\theta_1) - b_2(\delta,\theta_2) + ln\frac{P(class1)}{P(class2)}]$$

Под экспонентой получилось два слагаемых: скалярное произведение $\overrightarrow{X}$ с чем-то, не зависящим от $\overrightarrow{X}$, и некоторая величина, не зависящая от $\overrightarrow{X}$. Для простоты можно домножить постоянный признак «-1» на некоторое значение так, чтобы второе слагаемое занулилось. Т.е. можно записать:

$$\frac{P(class1)P(\overrightarrow{X}|class1)}{P(class2)P(\overrightarrow{X}|class2)} = e^{(w,\overrightarrow{X})}$$

Разделяющая поверхность

Это значит, что

$$c(\overrightarrow{X}) = sign[e^{(w,\overrightarrow{X})} - \frac{q_2}{q_1}]$$

Разделяющая поверхность — это все $\overrightarrow{X}$, в которых $c(\overrightarrow{X}) = 0$. Её уравнение:

$$e^{(w,\overrightarrow{X})} - \frac{q_2}{q_1} = 0,$$

т.е.

$$(w, \overrightarrow{X}) = ln\frac{q_2}{q_1}$$

Это значит, что разделяющая поверхность — гиперплоскость с указанным уравнением.

Точный вид функции распределения

Так как классов всего два, то $P(class1|\overrightarrow{X}) + P(class2|\overrightarrow{X}) = 1$. Кроме того,

$$\frac{P(class1|\overrightarrow{X})}{P(class2|\overrightarrow{X})} = e^{(w,\overrightarrow{X})},$$

откуда легко убедиться, что $P(class1|\overrightarrow{X})$ и $P(class2|\overrightarrow{X})$ — логистические функции:

$$P(class1|\overrightarrow{X}) = P(class2|\overrightarrow{X})e^{(w,\overrightarrow{X})}$$

$$P(class2|\overrightarrow{X})e^{(w,\overrightarrow{X})} + P(class2|\overrightarrow{X}) = 1$$

$$P(class2|\overrightarrow{X}) = \frac{1}{1+e^{(w,\overrightarrow{X})}}, P(class1|\overrightarrow{X}) = \frac{e^{(w,\overrightarrow{X})}}{1+e^{(w,\overrightarrow{X})}} = \frac{1}{1+e^{-(w,\overrightarrow{X}}}$$

Вопрос: как их получить в явном виде?

Точный вид функции распределения

Так как классов всего два, то $P(class1|\overrightarrow{X}) + P(class2|\overrightarrow{X}) = 1$. Кроме того,

$$\frac{P(class1|\overrightarrow{X})}{P(class2|\overrightarrow{X})} = e^{(w,\overrightarrow{X})},$$

откуда легко убедиться, что $P(class1|\overrightarrow{X})$ и $P(class2|\overrightarrow{X})$ — логистические функции:

$$P(class1|\overrightarrow{X}) = P(class2|\overrightarrow{X})e^{(w,\overrightarrow{X})}$$

$$P(class2|\overrightarrow{X})e^{(w,\overrightarrow{X})} + P(class2|\overrightarrow{X}) = 1$$

$$P(class2|\overrightarrow{X}) = \frac{1}{1+e^{(w,\overrightarrow{X})}}, P(class1|\overrightarrow{X}) = \frac{e^{(w,\overrightarrow{X})}}{1+e^{(w,\overrightarrow{X})}} = \frac{1}{1+e^{-(w,\overrightarrow{X}}}$$

Вопрос: как их получить в явном виде?

Ответ: так же, как и линейный классификатор — градиентным спуском. Все соображения по регуляризации формул и проведению процесса остаются в силе.

Как оценить плотность?

Пусть имеется выборка — набор прецедентов $Z \subset X$, каждый из которых состоит из набора параметров $(x_1, x_2, ..., x_K)$ и правильного ответа (класса) $y \in Y$. $\phi(Z, Y)$ — истинное совместное распределение значений $(x_1, x_2, ..., x_K, y)$, из которого получена выборка Z.

Требуется как-то построить оценку этого распределения на основе данной выборки.

Если она уже построена, то выбрать класс просто. Например, для снижения вероятности ошибки при заданном наборе параметров $x = (x_1, x_2, ..., x_K)$ надо найти такой класс a, что величина $P(a)P(x|a)$ максимальна. Если нужно, следует учитывать выигрыши и штрафы (метод — см. предыдущую лекцию).

Основные подходы

Как можно оценить плотности распределений классов?

1. с помощью регрессии, не делая предположений о форме распределения: сделать **гистограмму** или **ядерное сглаживание** каждого класса;
2. посчитать их какими-то заранее известными распределениями, например нормальными: можно каждый класс считать отдельной гауссианой (**нормальный дискриминаторный анализ**), можно — гауссианой одной и той же формы (**линейный дискриминант Фишера**);
3. посчитать каждый класс смесью нескольких распределений: **EM-алгоритм** для общего случая, **радиальные базисные функции** для смесей гауссиан.

Далее рассмотрим эти подходы детально.

Оценка гистограммой

Если число сочетаний параметров конечно (т.е. все они логические или категориальные) и количество прецедентов в выборке намного больше этого числа, то можно оценивать вероятность прямо по этому количеству (по сути, отнормировать количества так, чтобы их сумма была единицей):

$$\hat{p}(x,y) = \frac{N(x,y)}{\sum\limits_{(\chi,\upsilon)\in(X,Y)} N(\chi,\upsilon)}$$

Проблема: в практически значимых ситуациях требуется очень большая выборка.

Ядерная оценка плотности

Этот же метод в экономике известен как окно Парзена-Розенблатта.

Для оценки плотности распределения числовых параметров можно использовать ядро K с теми же свойствами, что и при регрессии, но оно должно быть нормированным:

$$\int_{-\infty}^{\infty} K(t)dt = 1$$

Формула для одномерного случая:

$$\hat{p}(x) = \frac{1}{Nh}\sum_{i=1}^{N} K(\frac{x - x_i}{h}),$$

где в пределы ненулевой части ядра попало N прецедентов x_1, x_2, ..., x_N. h, как и раньше, ширина ядра.

Многомерный случай

Так как нас интересует совместное распределение нескольких признаков, то можно сначала по каждому прецеденту получить его вклад в общую вероятность, а потом сложить эти вклады.

Для одного прецедента x_i, состоящего из M признаков $x_i = (x_i^1, x_i^2, ..., x_i^K)$:

$$\Delta_i(x) = \prod_{j=1}^{M} \frac{1}{h_j} K(\frac{x^j - x_i^j}{h_j})$$

Для всех N прецедентов:

$$\hat{p}(x) = \sum_{i=1}^{N} \Delta_i(x)$$

Вопрос: как настраивать этот метод?

Многомерный случай

Так как нас интересует совместное распределение нескольких признаков, то можно сначала по каждому прецеденту получить его вклад в общую вероятность, а потом сложить эти вклады.

Для одного прецедента x_i, состоящего из M признаков $x_i = (x_i^1, x_i^2, ..., x_i^K)$:

$$\Delta_i(x) = \prod_{j=1}^{M} \frac{1}{h_j} K(\frac{x^j - x_i^j}{h_j})$$

Для всех N прецедентов:

$$\hat{p}(x) = \sum_{i=1}^{N} \Delta_i(x)$$

Вопрос: как настраивать этот метод?
Ответ: подбирать h (это очень важно) и K (важно только для обеспечения нужной гладкости распределения).

Качество подбора

Средний накопленный квадрат ошибки (Mean Integrated Squared Error, MISE) — среднее по выборке значение квадрата ошибки:

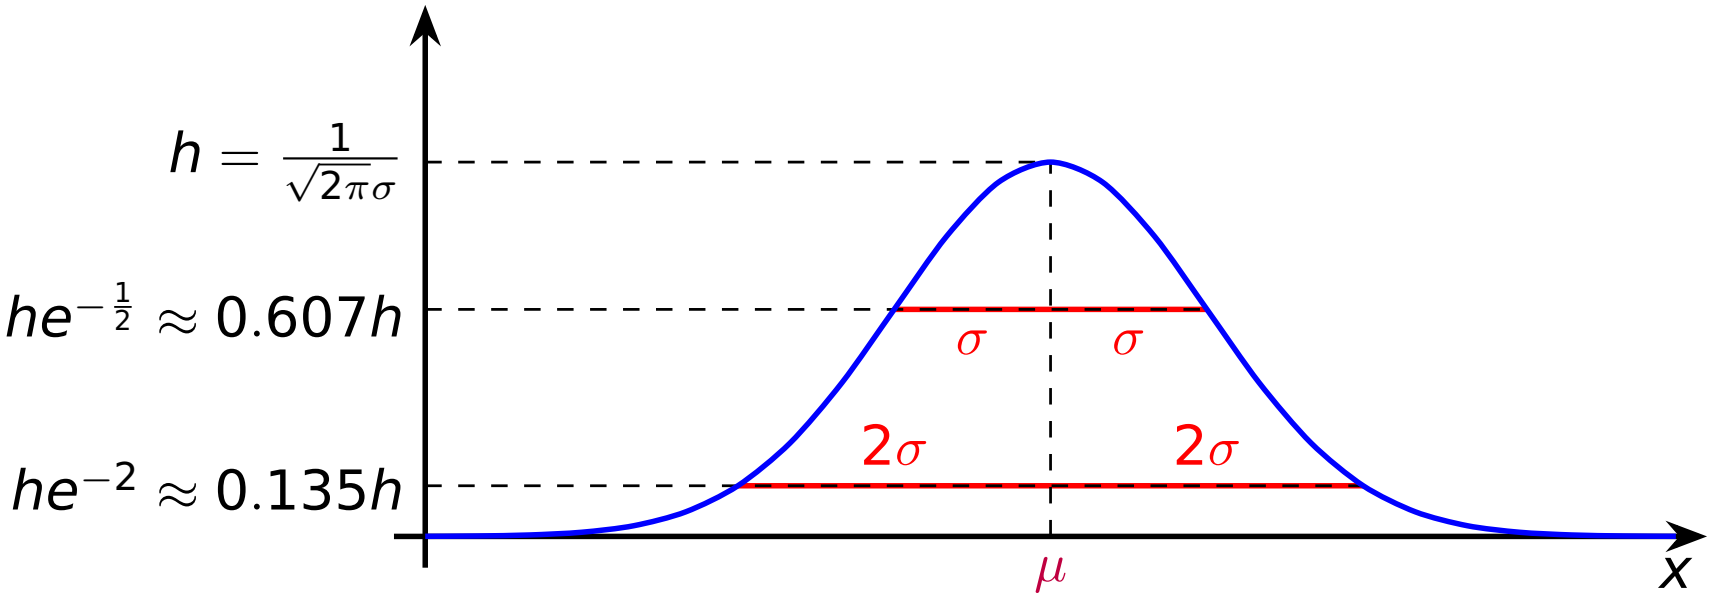
$$MISE(h) = E[\int_{x \in Z} (\hat{p}(x) - p(x))^2]$$

Проблема в том, что истинное значение плотности вероятности $p(x)$ неизвестно. Из-за этого чаще используется перекрестная валидация (cross-validation): разделение выборки на части, одна из которых используется для построения модели, другая — для оценки качества модели по совпадению результатов.

Особенность изложенных методов: не делается предположений о форме распределения плотности вероятности. Иногда их можно обосновать, получив более качественные результаты.

Нормальный дискриминантный анализ

Общее предположение: пусть форма истинных функций плотности распределения — гауссиана:

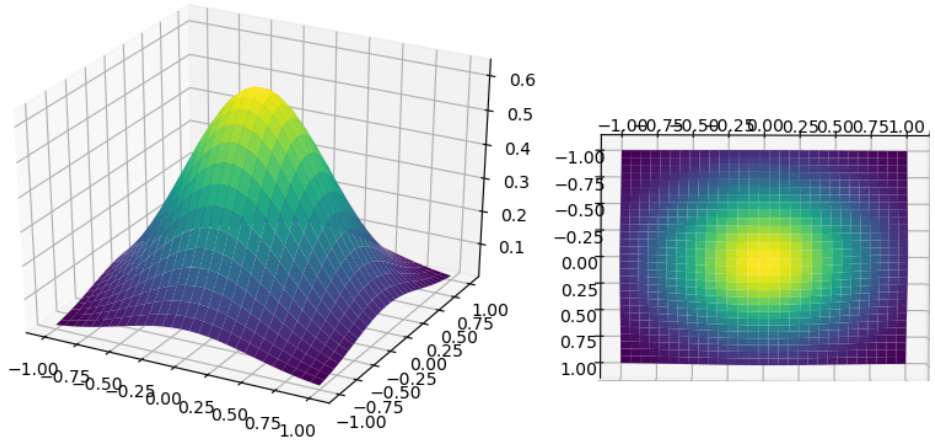


$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$

Многомерные гауссианы?

На практике интересен многомерный случай. Можно вместо одномерного x просто подставить вектор $\overrightarrow{X}$:

$$p(\overrightarrow{X}) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{(\overrightarrow{X}-\overrightarrow{M},\overrightarrow{X}-\overrightarrow{M})}{\sigma^2}}$$



Тогда гауссиана будет 1) симметричной по каждой координате (σ одинакова по всем направлениям) и 2) не повёрнутой относительно осей. Нужно научиться сильнее искажать $\overrightarrow{X}$.

Как повернуть и растянуть гауссиану

Возьмём квадратную матрицу вещественных чисел Σ, которая:

- симметрична: $\Sigma = \Sigma^T$; более того,
- положительно определена: все её собственные значения положительны;
- невырожденная, т.е. её определитель не равен нулю: $|\Sigma| \neq 0$.

Рассмотрим функцию от n-мерного вектора $\vec{X}$:

$$p(\vec{X}) = \frac{1}{\sqrt[n]{2\pi}|\Sigma|} e^{-\frac{1}{2}(\vec{X}-\vec{M})^T \Sigma^{-1}(\vec{X}-\vec{M})}$$

Отличается она от прошлой в основном тем, что в показателе разность $\vec{X} - \vec{M}$ дополнительно линейно преобразуется.

Свойства построенной функции

Можно убедиться, что:

$$\int\limits_{\overrightarrow{X} \in \mathbb{R}^n} p(\overrightarrow{X}) d\overrightarrow{X} = 1$$

Если посчитать $p(\overrightarrow{X})$ функцией плотности распределения вектора $\overrightarrow{X}$, то среднее значение будет равно:

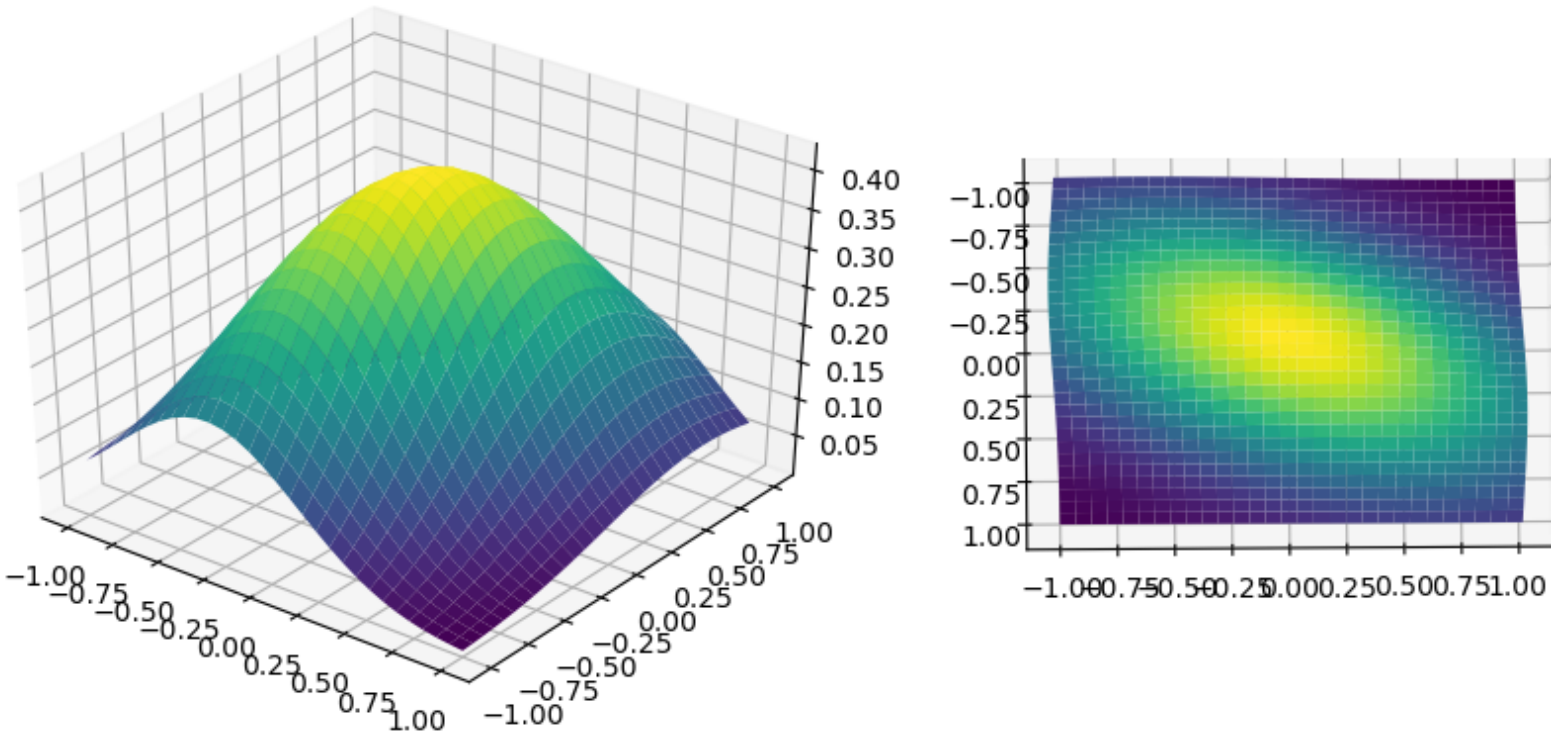
$$E[\overrightarrow{X}]|_{\overrightarrow{X} \in \mathbb{R}^n} = \overrightarrow{M},$$

а матрица ковариации:

$$E[(\overrightarrow{X} - \overrightarrow{M})^T (\overrightarrow{X} - \overrightarrow{M})]|_{\overrightarrow{X} \in \mathbb{R}^n} = \Sigma$$

Это значит, что такая формула описывает многомерное гауссово распределение, в котором можно задать средние значения каждой координаты, дисперсии каждой координаты и их взаимозависимость (ковариацию).

Пример полученной гауссианы



Свойства распределения

Вопрос: если матрица Σ диагональна, как это отразится на распределении?

Свойства распределения

Вопрос: если матрица Σ диагональна, как это отразится на распределении?
Ответ: Это значит, что разные координаты не зависят друг от друга. Распределение симметрично по каждой из осей и представляет собой по каждой из них при фиксированных других отмасштабированную гауссиану.
Вопрос: если матрица Σ не диагональна, как это отразится на распределении?

Свойства распределения

Вопрос: если матрица Σ диагональна, как это отразится на распределении?
Ответ: Это значит, что разные координаты не зависят друг от друга. Распределение симметрично по каждой из осей и представляет собой по каждой из них при фиксированных других отмасштабированную гауссиану.
Вопрос: если матрица Σ не диагональна, как это отразится на распределении?
Ответ: гауссиана будет повёрнута относительно осей. Если эта матрица — не матрица поворота, то гауссиана будет ещё и растянута в разной степени по разным осям.

Причина поворота

Пояснение: матрицу Σ можно разложить спектрально в произведение $U\Lambda U^T$, где U — матрица из ортогональных собственных векторов, Λ — диагональная матрица из собственных чисел. Тогда

$$\Sigma^{-1} = U\Lambda^{-1}U^T$$

и

$$(\overrightarrow{X} - \overrightarrow{M})^T\Sigma^{-1}(\overrightarrow{X} - \overrightarrow{M}) = (\overrightarrow{X} - \overrightarrow{M})^T U\Lambda^{-1}U^T(\overrightarrow{X} - \overrightarrow{M})$$

После замены переменной $\overrightarrow{X'} = U^T\overrightarrow{X}$ и $\overrightarrow{M'} = U^T\overrightarrow{M}$ получаем

$$(\overrightarrow{X} - \overrightarrow{M})^T\Sigma^{-1}(\overrightarrow{X} - \overrightarrow{M}) = (\overrightarrow{X'} - \overrightarrow{M'})^T\Lambda^{-1}(\overrightarrow{X'} - \overrightarrow{M'})$$

т.е. после линейного преобразования $\overrightarrow{X}$ можно выровнять оси гауссианы с осями координат.

Разделяющая поверхность: простейший случай

Если каждый из двух классов равновероятен и распределён по гауссианам с одинаковыми диагональными Σ, причём дисперсии всех признаков равны, то разделяющая поверность — гиперплоскость между центрами классов.

Если ковариационные матрицы не диагональны, то разделяющая поверхность задаётся уравнением:

$$(X - M_1)^T \Sigma^{-1} (X - M_1) = (X - M_2)^T \Sigma^{-1} (X - M_2)$$

Величина $\rho_\Sigma(u, v) = \sqrt{(u - v)^T \Sigma^{-1} (u - v)}$ называется **расстоянием Махаланобиса** между точками с матрицей ковариации Σ. Его физический смысл — «расстояние с учётом неопределённости координат».

Тогда уравнение поверхности:

$$\rho_\Sigma(X, M_1) = \rho_\Sigma(X, M_2)$$

Разделяющая поверхность: общий случай

В общем случае для двух классов для всех точек разделяющей поверхности выполняется равенство:

$$g_1 P(c1) P(X|c1) = g_2 P(c2) P(X|c2)$$

(т.е. на разделяющей поверхности одинаковы вероятности выбора и одного, и другого класса). Тогда после логарифмирования

$$ln(P(X|c1)) - ln(P(X|c2)) = ln(g_2 P(c2)) - ln(g_1 P(c1)) = const$$

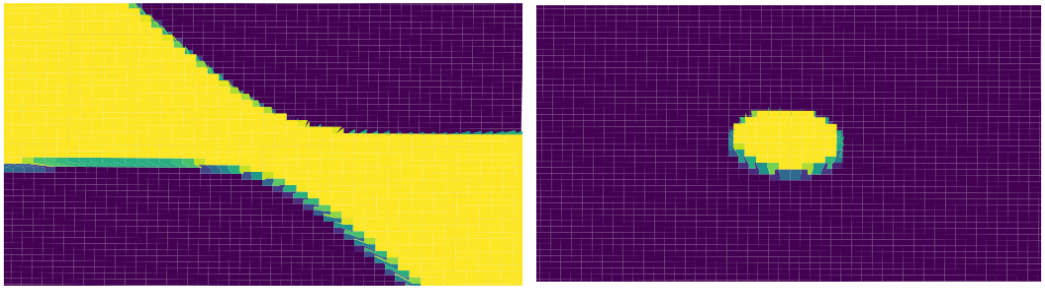
Разделяющая поверхность: общий случай (2)

$$p(X) = \frac{1}{\sqrt[n]{2\pi}|\Sigma|} e^{-\frac{1}{2}(X-M)^T\Sigma^{-1}(X-M)}$$

Логарифмы и одной, и другой функций распределения имеют вид:

$$ln(p(X)) = ln(\frac{1}{\sqrt[n]{2\pi}|\Sigma|}) - \frac{1}{2}(X-M)^T\Sigma^{-1}(X-M)$$

Это значит, что в разность этих логарифмов $ln(P(X|c1)) - ln(P(X|c2)$ координаты точек входят (в составе одночленов) со степенью не выше второй, т.е. разделяющая поверхность задаётся уравнением второго порядка относительно координат.



Оценка гауссова распределения для класса

Пусть откуда-то известно, что прецеденты какого-то класса C распределены по нормальному закону. Тогда можно оценить параметры M и Σ как математическое ожидание и ковариацию параметров всей выборки Z_C длины N:

$$\hat{M} = E(x : x \in Z) = \frac{1}{N}\sum_{i=1}^{N} x_i$$

$$\hat{\Sigma} = E((x - \hat{M})(x - \hat{M})^T : x \in Z) = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \hat{M})(x_i - \hat{M})^T$$

Вопрос: а почему для ковариации делим сумму на $N - 1$, а не на N?

Оценка гауссова распределения для класса

Пусть откуда-то известно, что прецеденты какого-то класса C распределены по нормальному закону. Тогда можно оценить параметры M и Σ как математическое ожидание и ковариацию параметров всей выборки Z_C длины N:

$$\hat{M} = E(x : x \in Z) = \frac{1}{N}\sum_{i=1}^{N} x_i$$

$$\hat{\Sigma} = E((x - \hat{M})(x - \hat{M})^T : x \in Z) = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \hat{M})(x_i - \hat{M})^T$$

Вопрос: а почему для ковариации делим сумму на $N - 1$, а не на N?

Ответ: чтобы использовать несмещённую оценку.

Нормальный байесовский классификатор

Если все классы можно описать как нормально распределённые, то:

1. подбираем для каждого параметры плотности распределения, как описано выше ($\hat{M}$ и $\hat{\Sigma}$);
2. рассчитываем класс по общим правилам байесовской классификации, т.е. учитываем награды и штрафы.

На практике предположение обычно слишком сильное, поэтому метод хорошо работает не всегда.

Упрощение классификации

По общему правилу байесовский классификатор возвращает класс c_i, для которого оценка

$$\hat{P}_i = g_i P(c_i) P(x|c_i)$$

максимальна. Если распределение всех классов нормально, можно подставить в формулу оценки вместо условной вероятности формулу многомерного нормального распределения и прологарифмировать, чтобы избавиться от экспоненты:

$$ln\hat{P}_i = ln(g_i P(c_i)) - \frac{1}{2}(X - \hat{M})^T \hat{\Sigma}^{-1}(X - \hat{M}) - \frac{1}{2} ln(\frac{1}{|\hat{\Sigma}|}) - \frac{n}{2} ln 2\pi$$

Раскроем скобки в скалярном произведении. Если дополнительно посчитать, что все Σ одинаковы у всех классов, и убрать все части выражения, не зависящие от класса, то можно избавиться от части полученных слагаемых.

Линейный дискриминант Фишера

Тогда класс будет определяться величиной

$$ln(g_i P(c_i)) - \frac{1}{2}\hat{M}^T\hat{\Sigma}^{-1}\hat{M} + X^T\hat{\Sigma}^{-1}\hat{M} = \beta_i + X^T\alpha_i$$

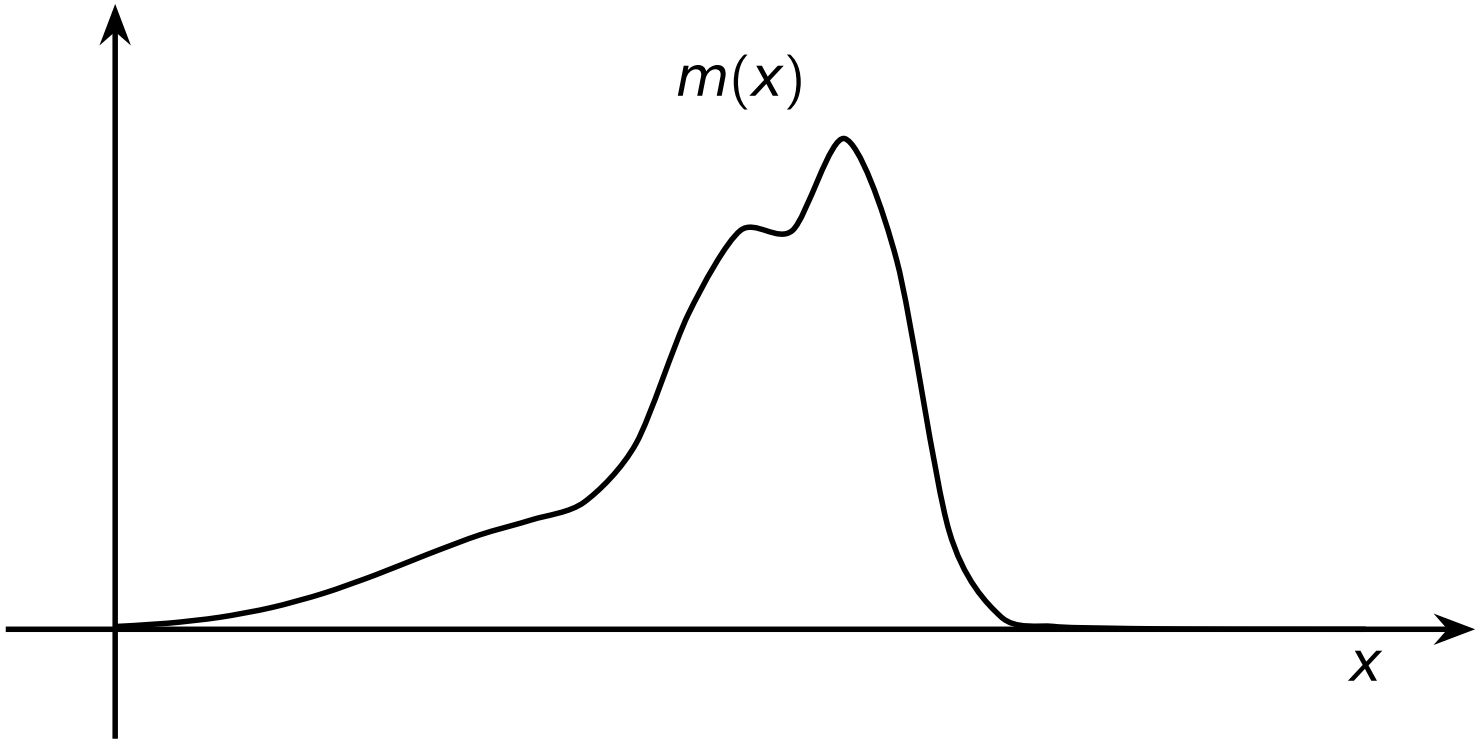
Иначе говоря, можно по статистическим параметрам рассчитать для каждого класса по 2 коэффициента и затем классифицировать объекты, найдя максимальное значение линейной функции на них. Этот метод называется **линейный дискриминант Фишера**

Достоинства: работает очень быстро.
Недостатки: предположения слишком сильные.

Идея смеси распределений

В описанных выше нормальном байесовском классификаторе и линейном дискриминанте Фишера мы пытались представить классы как нормально распределённые случайные величины. Понятно, что далеко не все распределения похожи на нормальные.

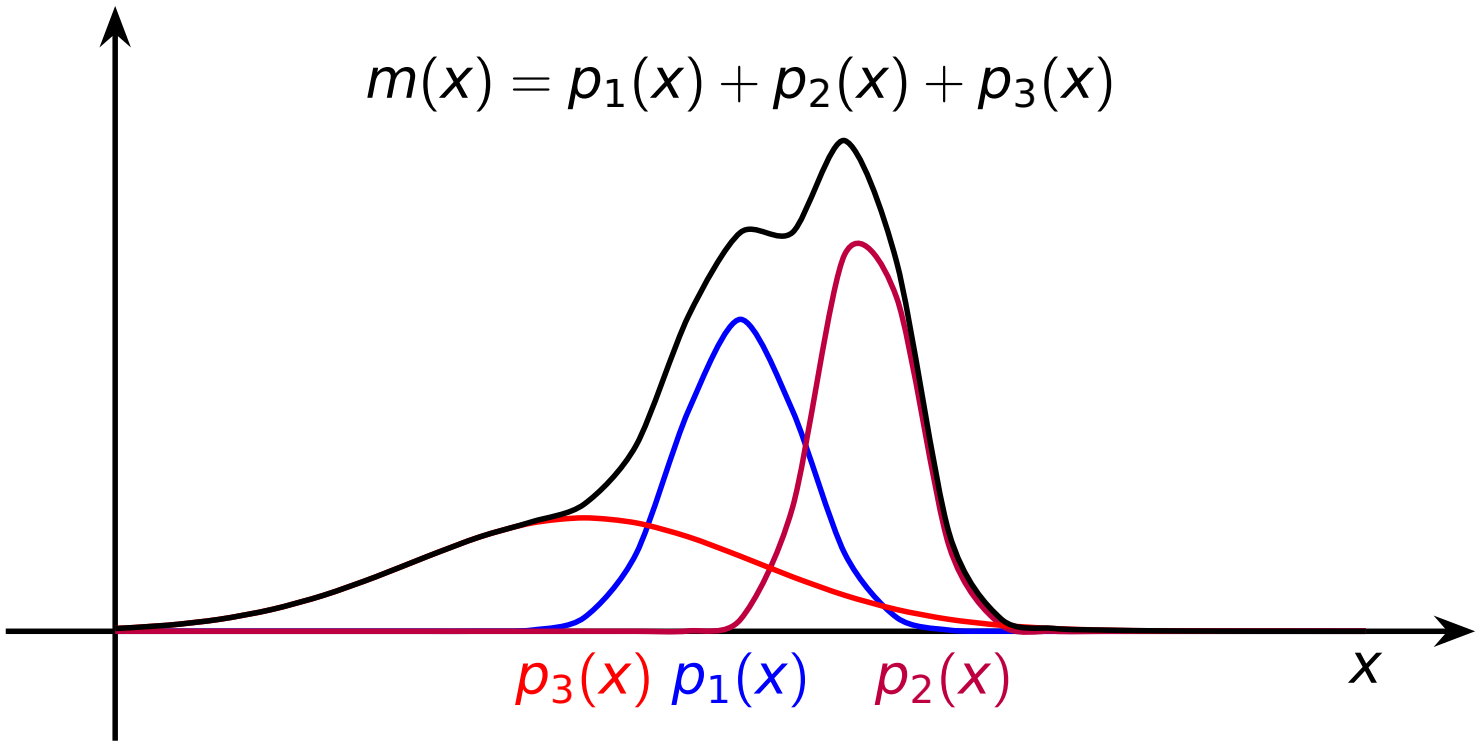
Идея: почему бы не использовать комбинацию нескольких отдельных распределений вместо одного?



Идея смеси распределений

В описанных выше нормальном байесовском классификаторе и линейном дискриминанте Фишера мы пытались представить классы как нормально распределённые случайные величины. Понятно, что далеко не все распределения похожи на нормальные.

Идея: почему бы не использовать комбинацию нескольких отдельных распределений вместо одного?



Определение смеси

Смесью распределений вероятности $p_1(X)$, $p_2(X)$, ..., $p_K(X)$ называется распределение вероятности

$$m(X) = \sum_{i=1}^{K} \omega_i p_i(X),$$

где $\sum_{i=1}^{K} \omega_i = 1$.

Так как на практике смешиваться будут совместные распределения вероятности $\gamma_i(X, y, w)$, параметрами смеси будут параметры каждого отдельного распределения и коэффициенты ω:

$$\mathbb{W} = \{\omega_1, w_1, \omega_2, w_2, ..., \omega_K, w_K\}$$

Итоговая задача: для заданного класса найти оценку совместного распределения вероятности в виде смеси, чтобы далее использовать байесовский подход для классификации.

Метод решения

Напрямую решить задачу оптимизации будет сложно: смешиваемые компоненты могут быть самыми разными, задача ставится в слишком общем виде.

Обычно она решается приближённо, итеративным методом — ЕМ-алгоритмом:

1. возьмём какое-либо начальное значение параметров $\mathbb{W}$;
2. оценка (**Estimation**): оценим для каждого прецедента вероятность того, что он принадлежит к каждому компоненту смеси, и соберём результаты в матрицу $\mathbb{M}$;
3. максимизация (**Maximization**): максимизируем правдоподобие параметров $\mathbb{W}$ при заданных оценках вероятностей $\mathbb{M}$, и заменим старое значение $\mathbb{W}$ оптимизированным;
4. если параметры $\mathbb{W}$ существенно изменились, перейдём к шагу 2, иначе задача решена.

Шаг оценки

Раз имеется текущее значение

$$\mathbb{W} = \{\omega_1, w_1, \omega_2, w_2, ..., \omega_K, w_K\},$$

можно для любого компонента j подставить w_j в формулу $\gamma_j(X, y, w_j)$ и для любого прецедента (X_i, y_i) оценить вероятность принадлежности к этому компоненту $\omega_j \gamma_j(X_i, y_i, w_j)$.

Соберём отнормированные вероятности в матрицу $\mathbb{M}$, число столбцов которой равно числу компонент смеси ($j = 1..K$), число строк — числу прецедентов ($i = 1..N$):

$$\mathbb{M} = \{m_{ij} = \frac{\omega_j \gamma_j(X_i, y_i, w_j)}{\sum_{s=1}^{K} \omega_s \gamma_s(X_i, y_i, w_s)}\}$$

Вопрос: зачем надо нормировать?

Шаг оценки

Раз имеется текущее значение

$$\mathbb{W} = \{\omega_1, w_1, \omega_2, w_2, ..., \omega_K, w_K\},$$

можно для любого компонента j подставить w_j в формулу $\gamma_j(X, y, w_j)$ и для любого прецедента (X_i, y_i) оценить вероятность принадлежности к этому компоненту $\omega_j \gamma_j(X_i, y_i, w_j)$.

Соберём отнормированные вероятности в матрицу $\mathbb{M}$, число столбцов которой равно числу компонент смеси ($j = 1..K$), число строк — числу прецедентов ($i = 1..N$):

$$\mathbb{M} = \{m_{ij} = \frac{\omega_j \gamma_j(X_i, y_i, w_j)}{\sum_{s=1}^{K} \omega_s \gamma_s(X_i, y_i, w_s)}\}$$

Вопрос: зачем надо нормировать?
Ответ: чтобы сумма вероятностей принадлежности ко всем компонентам была единицей.

Шаг максимизации

Задача этого шага: пусть имеются вероятности принадлежности каждого прецедента к каждому компоненту смеси $\mathbb{M}$. Надо как-то поменять $\mathbb{W}$, чтобы сделать оценку $\mathbb{M}$ максимально правдоподобной.

Идея (как и в других байесовских подходах): метод максимального правдоподобия. Добъёмся того, чтобы вероятность генерации именно такой выборки из смеси была максимальной. Это значит, что надо повысить произведение вероятностей появления каждого из N прецедентов $\prod_{i=1}^{N} p(X_i, y_i)$ или, что то же самое, его логарифм:

$$ln(\prod_{i=1}^{N} p(X_i, y_i)) = \sum_{i=1}^{N} ln(p(X_i, y_i)) = \sum_{i=1}^{N} ln(\sum_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j))$$

При этом $\sum_{j=1}^{K} \omega_j = 1$.

Задача оптимизации для M-шага

Надо, как и для системы опорных векторов, решать задачу оптимизации по $\mathbb{W}$ с одним ограничением. Будем действовать так же: дополним оптимизируемую функцию полиномом Лагранжа и вычислим оптимум как седловую точку.

Новая оптимизируемая функция с учётом ограничений:

$$L(X, \mathbb{W}) = \sum_{i=1}^{N} ln(\sum_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j)) - \lambda(\sum_{j=1}^{K} \omega_j - 1)$$

Её производные по каждой ω_j должны быть равны нулю:

$$\frac{\partial L}{\partial \omega_j} = \sum_{i=1}^{N} \frac{\gamma_j(X_i, y_i, w_j)}{\sum\limits_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j)} - \lambda = 0$$

Задача оптимизации для M-шага (2)

Для каждого $j = 1..K$

$$\sum_{i=1}^{N} \frac{\gamma_j(X_i, y_i, w_j)}{\sum_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j)} = \lambda$$

Если домножить каждое уравнение на ω_j и сложить, получим

$$\sum_{i=1}^{N} \sum_{j=1}^{K} \frac{\omega_j \gamma_j(X_i, y_i, w_j)}{\sum_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j)} = \lambda \sum_{j=1}^{K} \omega_j,$$

т.е. $\lambda = N$.

Если опять домножить те же уравнения для частных производных на ω_j, получим для каждого $j = 1..K$

$$\sum_{i=1}^{N} \frac{\omega_j \gamma_j(X_i, y_i, w_j)}{\sum_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j)} = N\omega_j$$

Задача оптимизации для M-шага (3)

Выражаем ω_j и замечаем сходство с формулой для m_{ij}:

$$\omega_j = \frac{1}{N}\sum_{i=1}^{N}\frac{\omega_j\gamma_j(X_i, y_i, w_j)}{\sum\limits_{j=1}^{K}\omega_j\gamma_j(X_i, y_i, w_j)} = \frac{1}{N}\sum_{i=1}^{N} m_{ij}$$

Это значит, что такие значения $\omega_j, j = 1..K$, могут принадлежать экстремуму.
Проверим, что при этих ω равны нулю и частные производные той же L по w_j:

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^{N}\frac{\omega_j}{\sum\limits_{j=1}^{K}\omega_j\gamma_j(X_i, y_i, w_j)}\frac{\partial\gamma_j(X_i, y_i, w_j)}{\partial w_j}$$

Заметим, что

$$\frac{\partial ln(\gamma_j(X_i, y_i, w_j))}{\partial w_j} = \frac{1}{\gamma_j(X_i, y_i, w_j)}\frac{\partial\gamma_j(X_i, y_i, w_j)}{\partial w_j}$$

Задача оптимизации для M-шага (4)

Подставив выражение для частной производной, получим ту же формулу, но с логарифмом:

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^{N} \frac{\omega_j \gamma_j(X_i, y_i, w_j)}{\sum\limits_{j=1}^{K} \omega_j \gamma_j(X_i, y_i, w_j)} \frac{\partial ln(\gamma_j(X_i, y_i, w_j))}{\partial w_j}$$

Видно, что в ней опять появляется m_{ij}:

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^{N} m_{ij} \frac{\partial ln(\gamma_j(X_i, y_i, w_j))}{\partial w_j} = \frac{\partial}{\partial w_j} \sum_{i=1}^{N} m_{ij} ln(\gamma_j(X_i, y_i, w_j))$$

Так как в экстремуме $\frac{\partial L}{\partial w_j} = 0$, поиск нужных значений w_j сводится к поиску максимума функции

$$\sum_{i=1}^{N} m_{ij} ln(\gamma_j(X_i, y_i, w_j))$$

Последовательность действий в EM-алгоритме

1. задаться каким-либо начальным $\mathbb{W}$;
2. E: рассчитать матрицу $\mathbb{M} : m_{ij} = \frac{\omega_j \gamma_j(X_i, y_i, w_j)}{\sum\limits_{s=1}^{K} \omega_s \gamma_s(X_i, y_i, w_s)}$;
3. M: рассчитать $\omega_j = \frac{1}{N} \sum\limits_{i=1}^{N} m_{ij}$; для каждого j решить задачу максимизации $\sum\limits_{i=1}^{N} m_{ij} ln(\gamma_j(X_i, y_i, w_j))$ по w_j. Это приведёт к появлению нового $\mathbb{W}$ из новых ω и w;
4. если значение $\mathbb{W}$ мало отличается от прежнего, завершить работу, иначе перейти снова к шагу 2.

Проблемы EM-алгоритма

На каждом шаге надо решать K задач оптимизации, т.е. обучение долгое.

Непонятно, как выбирать начальное $\mathbb{W}$.

Непонятно, откуда брать число компонентов смеси K. Часто их пытаются добавлять по одному (начав с двух) и проверяют после каждого добавления качество классификации.

Упрощение задачи

EM работает с любыми функциями распределения. Можно ограничиться гауссовыми функциями (получив т.н. **гауссову смесь**).

Пусть все γ_j — гауссианы. Тогда в задаче оптимизации при поиске $w_j = \{M_j, \Sigma_j\}$ ответ можно выписать сразу:

$$M_j = \frac{\sum_{i=1}^{N} m_{ij} X_i}{N\omega_j}$$

$$\Sigma_j = \frac{\sum_{i=1}^{N} m_{ij}(X_i - M_j)(X_i - M_j)^T}{N\omega_j}$$

Дальнейшее упрощение задачи

Если гауссианы имеют оси, параллельные осям координат (т.е. их Σ диагональны), можно ещё упростить эти выражения. Каждая многомерная гауссиана при этом вырождается в произведение одномерных гауссиан со своими средними μ_{ij} и среднеквадратическими отклонениями σ_{ij}, $i = 1..L$ — число координат (значений в одном прецеденте X), $j = 1..N$ — как и раньше, число компонентов смеси.

$$\mu_{ij} = \frac{\sum\limits_{i=1}^{N} m_{ij} x_{ij}}{N\omega_j}$$

$$\sigma_{ij} = \frac{\sum\limits_{i=1}^{N} m_{ij}(x_{ij} - \mu_{ij})^2}{N\omega_j}$$

Физический смысл упрощённой задачи

Функция от переменной X, значение которой зависит только от расстояния X до некоторой фиксированной точки, называется радиальной.

Многомерная гауссиана с диагональной матрицей ковариации является радиальной, если сжать каждую из осей до достижения всеми σ одинакового значения.

Классификатор на основе гауссовой смеси из радиальных функций — **сеть радиальных базисных функций**. Класс прецедента определяется, по сути, его «расстояниями» до центров компонентов, взвешенными значениями ω.

Метрические методы

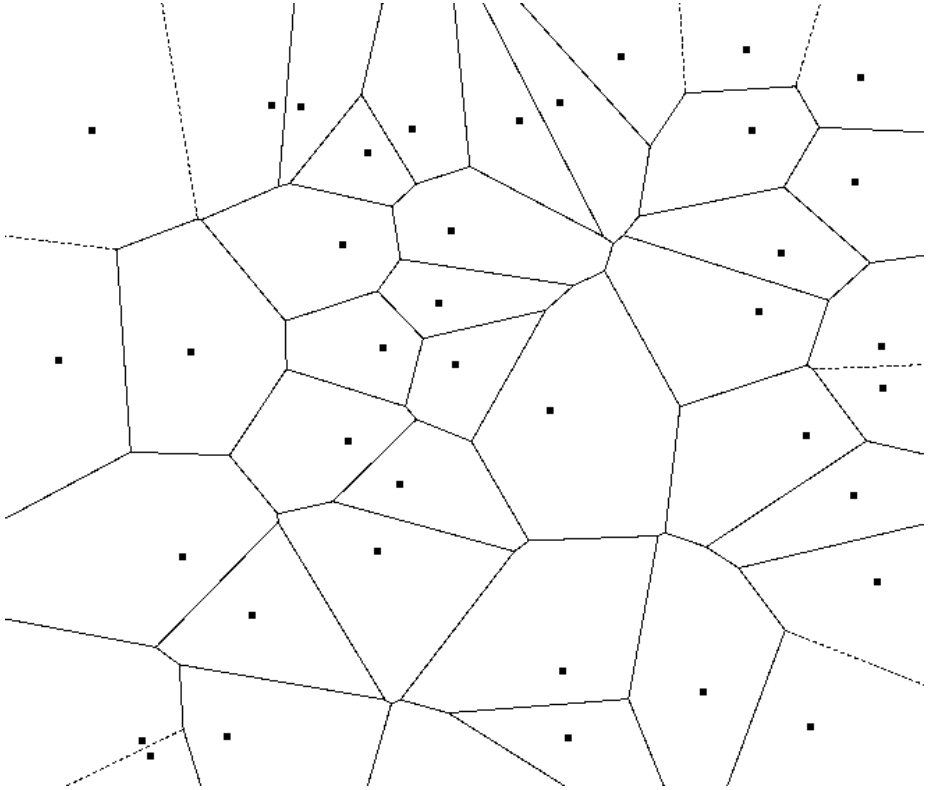
Классификация по прецедентам

Рассмотрим очень похожий по смыслу, но исходящий из других допущений подход к классификации: попробуем считать класс прецедента таким же, как класс ближайших к нему прецедентов из обучающей выборки. Для этого при обучении запомним всю обучающую выборку; кроме того, понадобится некоторая метрика пространства признаков. Поэтому методы такого рода называются **метрическими**.

Простейший вариант — **метод ближайшего соседа**: класс любого прецедента равен классу ближайшего к нему примера из обучающей выборки.

Разделение пространства на области

Области, которые принадлежат каждому из прецедентов обучающей выборки, образуют замощение пространства, называемое диаграммой Вороного.



Достоинства и недостатки

Вопрос: ?

Достоинства и недостатки

Вопрос: ?
Ответ:

- хорошая интерпретация результатов классификации: «класс этого объекта такой, потому что он больше всего похож на представителя именно этого класса»;
- полная неустойчивость к выбросам;
- необходимость хранения всей выборки;
- необходимость сравнения со всей выборкой.

Вопрос: что можно сделать, чтобы исправить недостатки?

Вариации

По количеству соседей:

- проверять несколько ближайших соседей (**алгоритм k-ближайших соседей**); класс совпадает с классом большинства из них;
- то же, но со взвешиванием по расстоянию от них;
- использование функции ядра некоторого размера для взвешивания соседей;

По хранению выборки: часто можно выбросить и не хранить те прецеденты, которые мало влияют на классификацию. Типичный метод: проверим каждый прецедент, отбрасывая его и классифицируя все остальные прецеденты как новые объекты; если без текущего прецедента результат не изменится, можно от него избавиться.

По сравнению со всей выборкой: можно использовать контейнеры для многомерных данных, облегчающие поиск соседей, например дерево квадрантов или k-дерево.