Практическая работа 2. Простейшие виды классификации

Введение

Цель работы: освоить приемы генерации тестовых выборок и базовые линейные и вероятностные подходы к классификации.

Задачи: требуется выполнить классификацию тремя разными методами на самостоятельно сгенерированных входных данных указанного вида. Номера типов входных данных и алгоритмов классификации определяются по номеру варианта из таблицы 1. Пронумерованные описания входных данных находятся в таблице 2, пронумерованные описания алгоритмов — в таблице 3. Полные коды всех разработанных методов должны быть предоставлены для проверки; требуемые пояснения могут быть даны в виде комментариев к коду или отдельным документом любого нужного формата.

Порядок выполнения работы

Задание 1. По номеру варианта определить из таблицы 1 типы входных данных, которые надо программно сгенерировать для дальнейшей обработки, и номера алгоритмов, которые следует применить к этим данным.

Таблица 1. Варианты задания

Номер варианта	Номер типа входных данных	Номера алгоритмов
1	1,4,8	1,2,4
2	2,5,7	1,3,5
3	3,5,6	2,3,6
4	3,4,7	1,2,7
5	2,5,8	1,3,4
6	1,6,9	2,3,5
7	2,7,10	1,2,6
8	1,3,8	1,3,7
9	2,4,9	2,3,4
10	3,5,10	1,2,5
11	4,6,10	1,3,6
12	5,7,9	2,3,7
13	6,8,9	1,4,5
14	7,8,10	3,5,6
15	1,6,9	2,6,7
16	2,5,10	1,5,7
17	1,3,4	4,5,6
18	2,3,4	3,5,7
19	2,3,5	1,6,7
20	1,4,6	3,6,7

Задание 2. Определить из таблицы 2 виды входных данных, которые должны быть обработаны, и сгенерировать их. В обучающую выборку включаются три указанные группы точек трехмерного пространства; каждую из классификаций следует провести три раза:

1. включив в один класс первую группу точек, в другой — вторую и третью;
2. включив в один класс первую и вторую группы точек, в другой — третью;
3. включив каждую группу точек в свой отдельный класс.

Если выбранная библиотека алгоритмов не поддерживает классификацию с числом классов больше двух, дополнительное разбиение следует организовать вручную.

Количество прецедентов должно задаваться одной из переменных программы, чтобы допустить лёгкое изменение в процессе тестирования; требуемое число прецедентов каждого типа совпадает.

Таблица 2. Типы входных данных

Номер типа	Описание
1	Точки вида $(a - 0.5, b, 0.5 + a + b + \varepsilon)$, где значения a, b, ε — независимые случайные числа, равномерно распределённые на отрезке $[-1, 1]$
2	Точки вида $(a, b - 0.5, a\varepsilon)$, где значения a, b, ε — независимые случайные числа, равномерно распределённые на отрезке $[-1, 1]$
3	Точки вида $(a, b + \varepsilon, 0.5 + a + \varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
4	Точки вида $(a, b, -0.5+b\varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
5	Точки вида $(0.1a - 1, 3b, \varepsilon - 1)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
6	Точки вида $(a, 0.1b, 0.1a + 0.2b + 0.1\varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
7	Случайные точки трехмерного пространства, распределённые по поверхности нижней полусферы с уравнением $x^2 + y^2 + (z + 0.5)^2 = 1, z \leq 0$ (способ распределения произвольный)
8	Случайные точки трёхмерного пространства, лежащие внутри полушария $x^2 + y^2 + z^2 = 1, z \geq 0$; способ распределения произвольный
9	Точки трехмерного пространства вида $(x, y, x^2 + y)$, где значения x — нормально распределенные случайные числа со средним 1 и среднеквадратическим отклонением 1, значения y — случайные числа, равномерно распределенные по отрезку $[-1, 1]$
10	Точки трёхмерного пространства вида $(x, y, e^{x-y} + \varepsilon)$, где x и y — нормально распределённые случайные числа со средним 1 и среднеквадратическим отклонением 3, ε — равномерно распределённые случайные числа из диапазона $[-0.1, 0.1]$

Задание 3. Определить по таблице 3 методы обработки данных. Следует обработать каждую из выборок двумя указанными методами и сравнить качество полученных моделей (как минимум, precision и recall для каждого из классов). Значения настроечных коэффициентов,

если они требуются, следует выбрать самостоятельно; нулевые значения этих коэффициентов не допускаются.

При использовании библиотеки scikit-learn рекомендуется ознакомиться с документацией по разделам:

- sklearn.linear_model.SGDClassifier
- sklearn.svm.LinearSVC
- sklearn.linear_model.LogisticRegression
- sklearn.naive_bayes
- sklearn.discriminant_analysis.LinearDiscriminantAnalysis
- sklearn.mixture.GaussianMixture
- sklearn.gaussian_process.GaussianProcessClassifier
- sklearn.gaussian_process.kernels.RBF

Таблица 3. Типы алгоритмов обработки

Номер типа	Описание алгоритма
1	Линейная пороговая классификация
2	Метод опорных векторов
3	Логистическая регрессия
4	Наивный байесовский классификатор (любого подходящего к условиям задачи подтипа)
5	Линейный дискриминант Фишера
6	Гауссова смесь (число компонентов для каждого класса может быть определено вручную)
7	Классификатор на основе гауссова процесса с ядром в виде сети радиальных базисных функций

Задание 4. Сгенерировать новую выборку данных такого же размера, включив в один класс первую группу прецедентов, в другой — вторую и третью (так, как в задании 2 была получена первая из тестовых выборок). Послее этого сравнить точность всех моделей на новой выборке и первой из прежних. Сделать вывод о сохранении точностных характеристик каждой из моделей.

Контрольные вопросы

1. Какие из перечисленных алгоритмов обработки устойчивы к выбросам?
2. Какие из перечисленных алгоритмов обработки удовлетворяют критерию максимального правдоподобия?
3. Какие из созданных выборок линейно отделимы?
4. Существуют ли какие-либо приёмы обеспечения линейной отделимости выборок?
5. Как можно оценить требуемое число компонентов в байесовской смеси?