Статистический подход

Очевидно, что задача кластеризации очень похожа на уже рассмотренную задачу построения смеси: если считать, что прецеденты — выбранные значения случайной величины с некоторым распределением, можно оценить это распределение как смесь и считать разные компоненты смеси кластерами.

Особенность: так как функции принадлежности разным компонентам смеси могут одновременно быть ненулевыми, то можно добиться нечёткой кластеризации: каждый элемент принадлежит не какому-то одному, а всем кластерам одновременно, но с разной достоверностью.

Решение задачи в статистическом подходе

Используем EM-алгоритм, описанный ранее:

1. зададимся числом кластеров K. Создадим K компонентов смеси, задав параметры случайным образом;
2. E: оценим для каждого прецедента вероятности того, что он принадлежит к каждому компоненту смеси;
3. M: оптимизируем параметры каждого компонента, подгоняя их под полученную на шаге E оценку;
4. пересчитаем E. Если она существенно изменилась (т.е. кластеры не стабилизировались), переходим к шагу 3, иначе выдаём результат.

Очень часто используются компоненты в виде гауссиан.
Вопрос: а в чём разница между этим подходом и методом формальных элементов? И там, и там подгоняем под данные некоторые шарообразные области?

Решение задачи в статистическом подходе

Используем EM-алгоритм, описанный ранее:

1. зададимся числом кластеров K. Создадим K компонентов смеси, задав параметры случайным образом;
2. E: оценим для каждого прецедента вероятности того, что он принадлежит к каждому компоненту смеси;
3. M: оптимизируем параметры каждого компонента, подгоняя их под полученную на шаге E оценку;
4. пересчитаем E. Если она существенно изменилась (т.е. кластеры не стабилизировались), переходим к шагу 3, иначе выдаём результат.

Очень часто используются компоненты в виде гауссиан.
Вопрос: а в чём разница между этим подходом и методом формальных элементов? И там, и там подгоняем под данные некоторые шарообразные области?
Ответ: в методе формальных элементов радиус задан заранее, в EM-алгоритме он автоматически подгоняется под данные и может варьироваться по разным координатам.

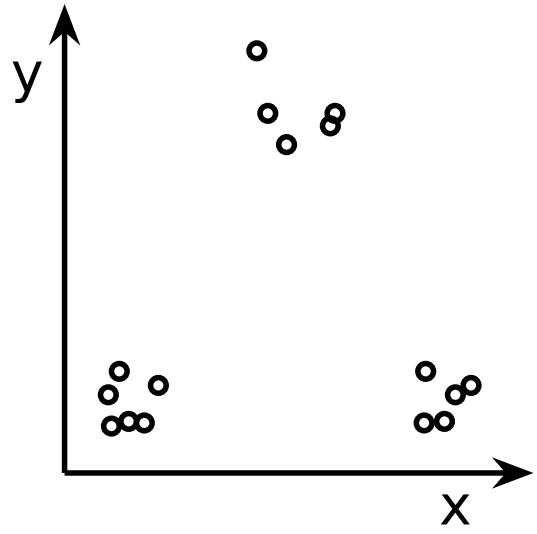
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



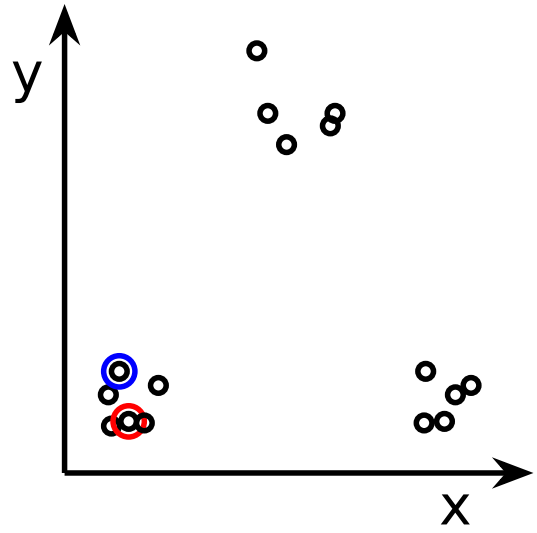
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



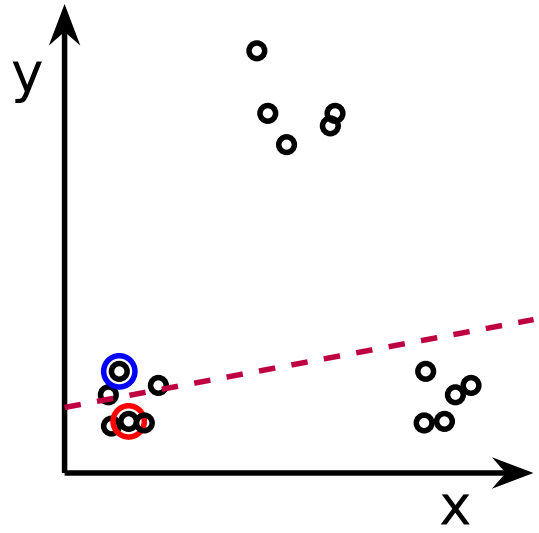
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



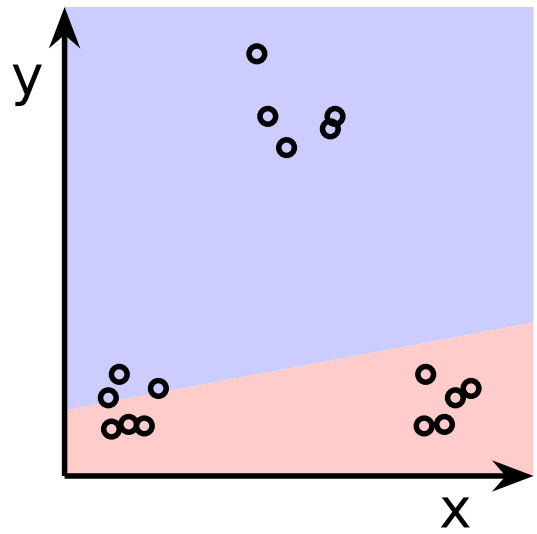
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



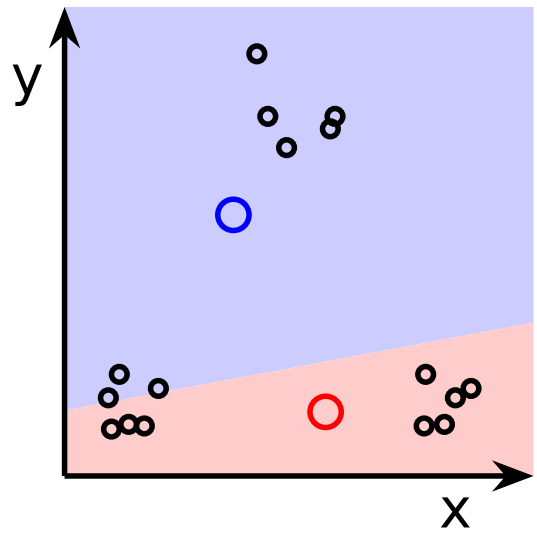
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



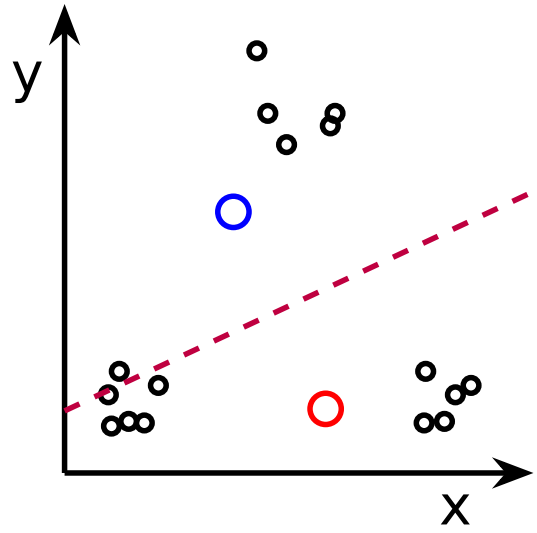
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



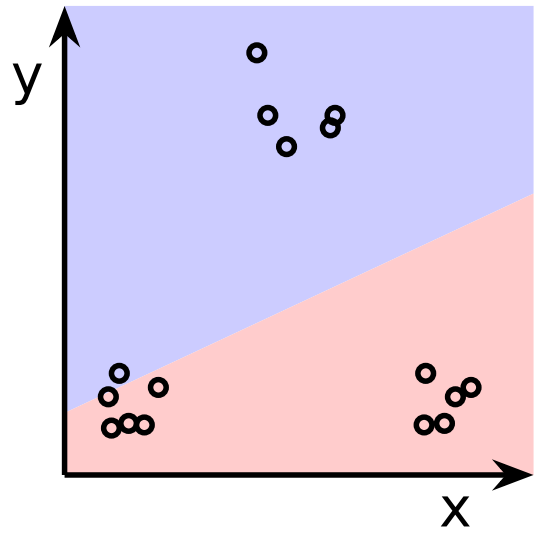
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



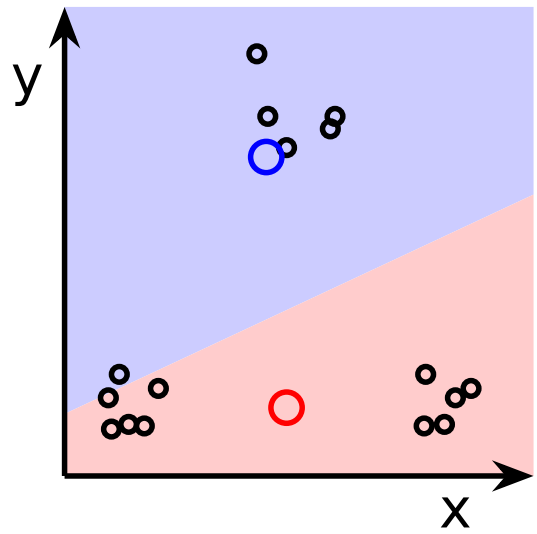
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



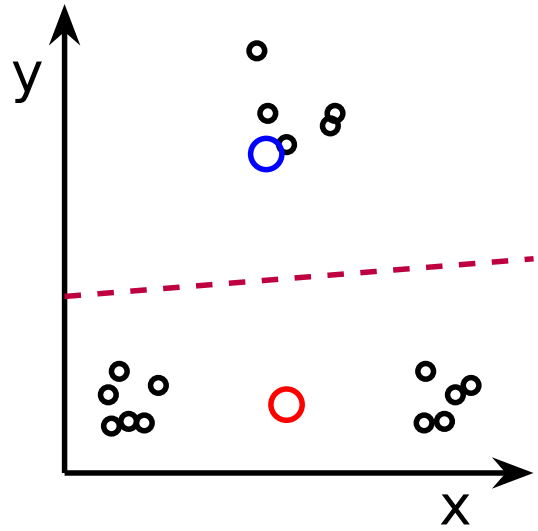
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



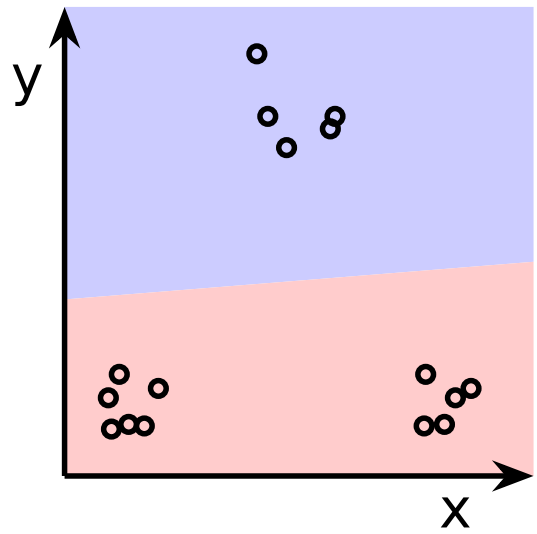
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



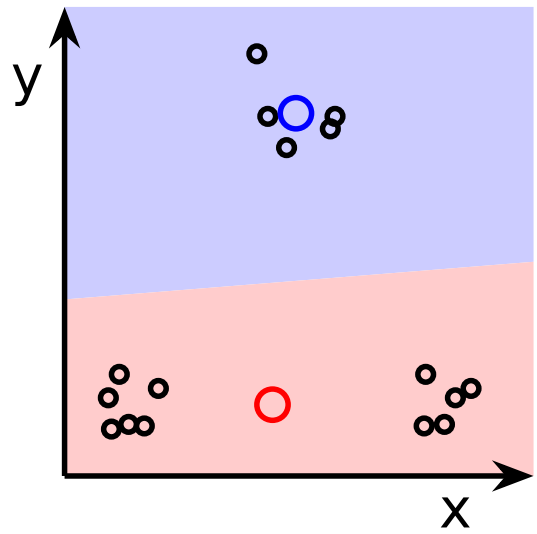
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



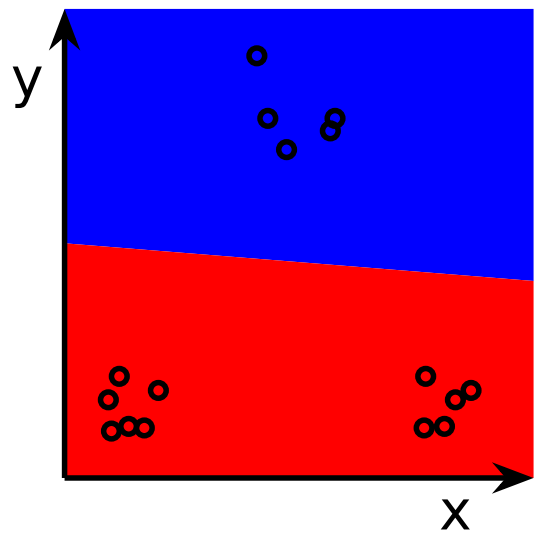
Кластеризация методом k-средних: пример

k-mean clustering

Пусть число кластеров известно заранее и равно k. Выберем k случайных примеров и назначим их центроидами кластеров, после чего итеративно:

1. включим в кластеры те примеры, которые ближе всего к текущим центроидам;
2. пересчитаем центроиды.

Будем продолжать, пока происходят существенные изменения.



Метод k-средних: описание

Можно описать это как частный случай EM-алгоритма, если каждый компонент смеси — нормальное распределение с одинаковыми дисперсиями по каждой координате:

1. зададимся числом кластеров K. Создадим K компонентов смеси, выбрав K прецедентов на роль временных центров кластеров;
2. E: отнесём каждый прецедент к тому кластеру, к центру которого он ближе всего;
3. M: перенесём центры кластеров в средние точки соответствующих им множеств;
4. пересчитаем E. Если кластеры не стабилизировались, переходим к шагу 2, иначе выдаём результат.

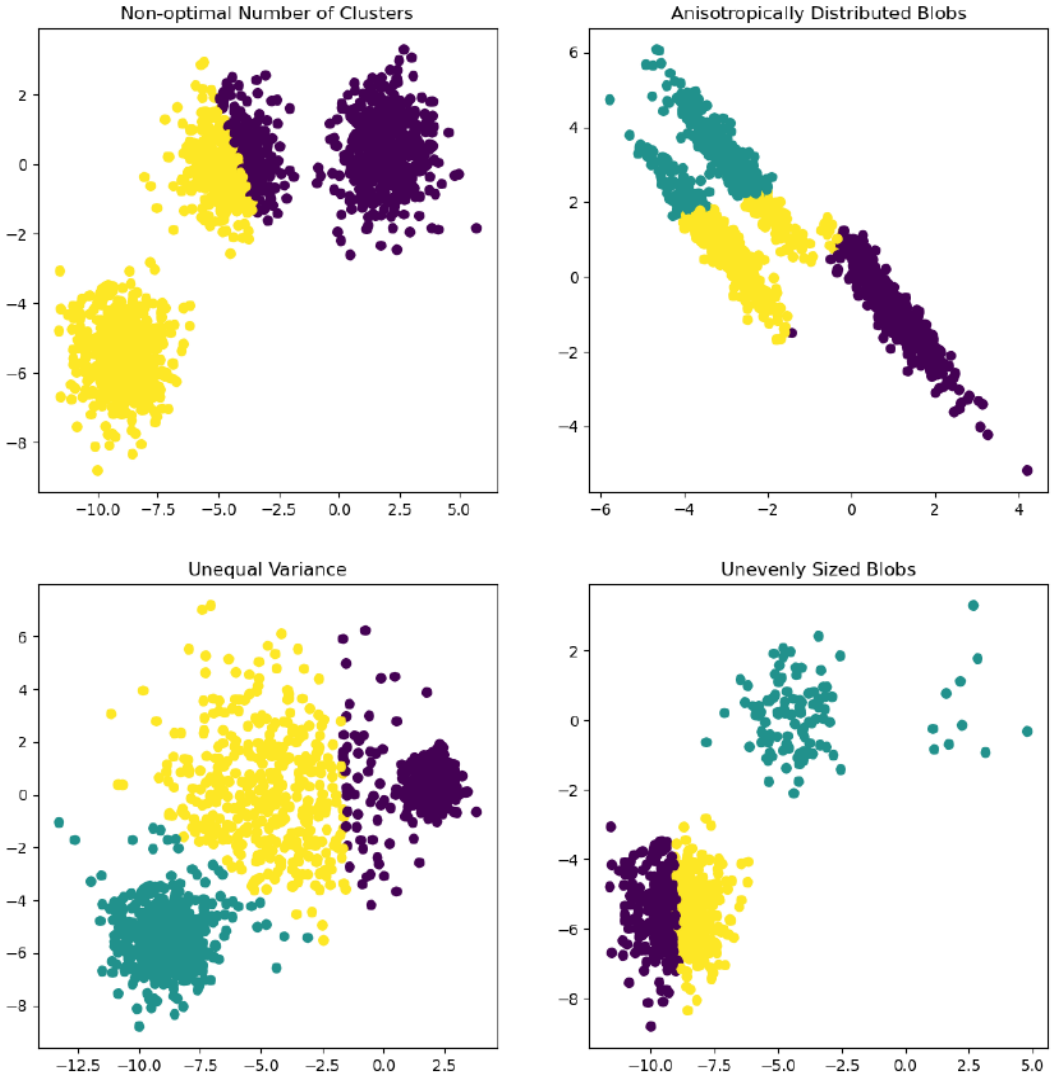
Достоинства и недостатки

Формально этот метод пытается минимизировать т.н. инерцию кластеров: $\sum_{i=1}^{K}(z_i - \mu_i), z_i \in C_i$.

Достоинства: просто реализуется, быстро сходится.

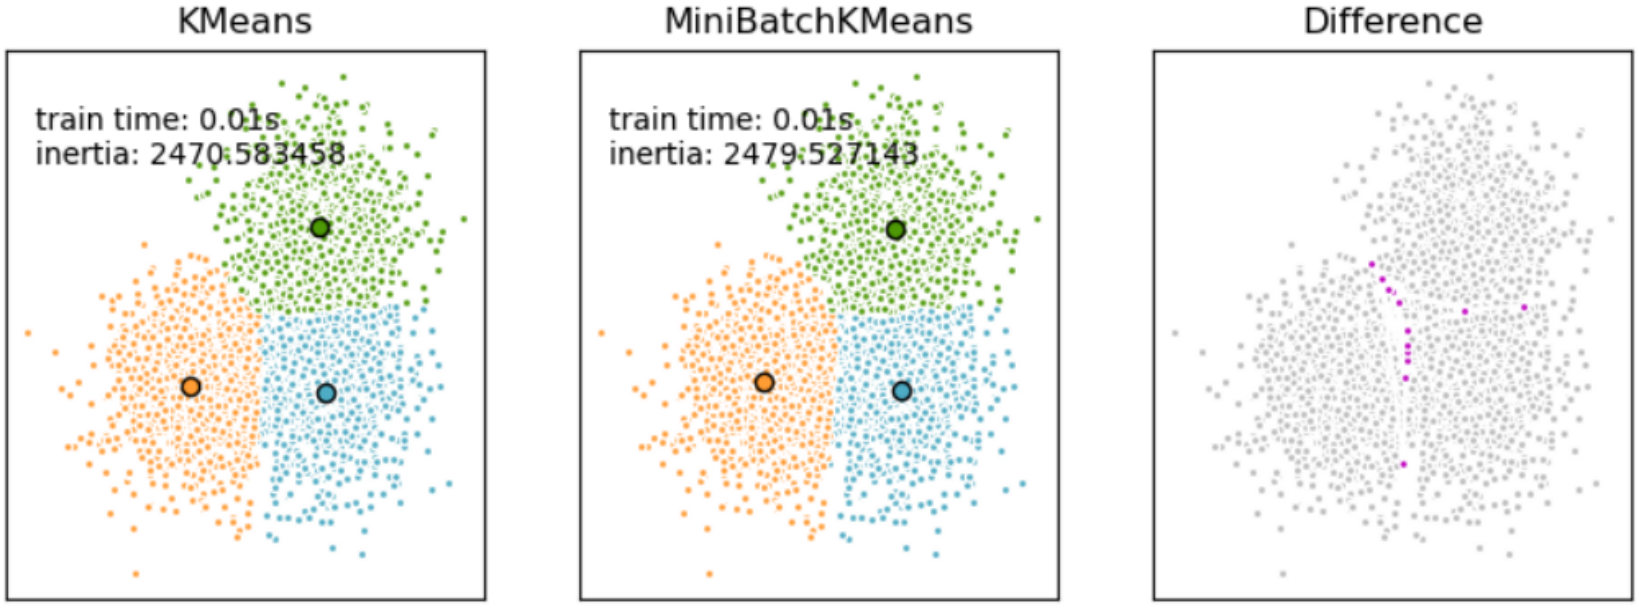
Недостатки: критическая зависимость качества от выбора числа кластеров и начальных прецедентов. Рекомендуется повторять кластеризацию по нескольку раз с разным числом кластеров и разными начальными элементами, выбирая наилучший результат; из-за множества итераций реально работает не очень быстро.

Типичные ошибки метода k-средних



Mini-batch k-means

Вариант предыдущего метода, в котором на каждом шаге распределяется по кластерам не вся выборка, а только небольшое, каждый шаг случайно выбираемое подмножество прецедентов. Результат: ускорение работы, качество обычно не хуже.



Общий иерархический подход

Цель — построить иерархию кластеров.

- **Восходящий подход**: сначала считаем, что каждый прецедент — отдельный кластер, потом начинаем их сливать до получения кластера размером во всю выборку. Используется чаще всего;
- **нисходящий подход**: сначала считаем, что вся выборка — один кластер, и делим её на части до получения кластеров размеров в один элемент.

Можно использовать эти подходы в сочетании с ранее изложенными методами.

Примечание: иерархии можно строить и в других методах — см. выше.

Критерии объединения кластеров

Для выбора кластеров, которые нужно сливать в восходящем методе, нужно понять, близок ли один кластер к другому. Варианты мер близости:

- расстояние ближнего соседа: минимальное расстояние между объектом из одного кластера и объектом из другого. $R(C_1, C_2) = min\rho(z_1, z_2), z_1 \in C_1, z_2 \in C_2$;
- расстояние дальнего соседа: максимальное расстояние между объектом из одного кластера и объектом из другого. $R(C_1, C_2) = min\rho(z_1, z_2), z_1 \in C_1, z_2 \in C_2$;
- среднее расстояние: $R(C_1, C_2) = \frac{1}{len(C_1)len(C_2)} \sum z_1 \in C_1, z_2 \in C_1 \rho(z_1, z_2)$;
- расстояние между центрами: $R(C_1, C_2) = \rho^2(\frac{\sum_{z_1 \in C_1} z_1}{len(C_1)}, \frac{\sum_{z_2 \in C_2} z_2}{len(C_2)})$;
- расстояние Уорда (аналог предыдущего, но с учётом числа элементов в кластерах): $R(C_1, C_2) = \frac{len(C_1)len(C_2)}{len(C_1)+len(C_2)} \rho^2(\frac{\sum_{z_1 \in C_1} z_1}{len(C_1)}, \frac{\sum_{z_2 \in C_2} z_2}{len(C_2)})$.

Выбор меры близости

Интуитивно хотелось бы, чтобы расстояние между близко расположенными по иерархии кластерами было меньше, чем между далеко расположенными. Можно оценить для меры сходства свойства монотонности и растяжения/сжатия, чтобы понять, подходит ли она.

Монотонность: при каждом новом слиянии расстояния между между объединяемыми кластерами увеличиваются. Расстояние между центрами немонотонно, остальные монотонны.
Сжатие: при каждом новом слиянии расстояния от текущего кластера до других уменьшаются. Расстояние ближнего соседа сжимающее.
Растяжение: при каждом новом слиянии расстояния от текущего кластера до других увеличиваются. Расстояние дальнего соседа и расстояние Уорда растягивающие.

Растягивающие расстояния обычно приводят к более чётким границам кластеров, но в целом надо проверять качество экспериментально.

BIRCH

Balanced Iterative Reducing and Clustering using Hierarchies[6]

Метод построения иерархии кластеров в виде дерева специального вида. Применим только для данных с числовыми параметрами (категориальные не подходят).

Преимущества использования дерева, покрывающего пространство:

- локальность: решение о принадлежности точки к кластеру принимается без проверки всех известных точек/кластеров — просматриваются только некоторые, близкие к ней;
- неравномерность покрытия: в облаке точек есть сгущения/разрежения, их можно использовать.

[6] T. Zhang, R. Ramakrishnan, M. Livny. BIRCH: an efficient data clustering method for very large databases // Proceedings of the 1996 ACM SIGMOD international conference on Management of data SIGMOD '96. pp. 103–114. 1996.

Параметры кластера в BIRCH

Если в некотором кластере уже имеются точки $Z_1, Z_2, ..., Z_N$, каждая из которых представляет собой вектор параметров (действительных чисел), то можно ввести для кластера три характеристики:

1. число точек N;
2. сумму точек $LS = \sum_{i=1}^{N} Z_i$;
3. сумму квадратов точек $SS = \sum_{i=1}^{N} Z_i^T Z_i = \sum_{i=1}^{N} |Z_i|^2$ (т.е. сумму квадратов длин соответствующих точкам векторов).

Очень хорошее свойство:
если охарактеризовать кластер этими параметрами (N, LS, SS), то при добавлении новой точки к кластеру параметры будет очень легко обновить — все они аддитивны. Точно так же легко и сливать два кластера — для получения характеристик нового кластера надо просто сложить их параметры попарно.

Напоминание: параметры кластера

Пусть кластер состоит из точек $Z_1, Z_2, ..., Z_N$, тогда:

центроид кластера: $C = \frac{\sum_{i=1}^{N} Z_i}{N} = \frac{LS}{N}$;

радиус, или среднее расстояние от точки до центроида:

$$R = \sqrt{\frac{\sum_{i=1}^{N}(Z_i - C)^2}{N}} = \sqrt{\frac{N \cdot C^2 + SS - 2C \cdot LS}{N}};$$

среднее расстояние между кластерами $\{Z_i\}$ и $\{W_i\}$:

$$D = \sqrt{\frac{\sum_{i=1}^{N_1}\sum_{j=1}^{N_2}(Z_i - W_j)^2}{N_1 \cdot N_2}} = \sqrt{\frac{N_1 \cdot SS_2 + N_2 \cdot SS_1 - 2LS_1 \cdot LS_2}{N_1 \cdot N_2}}.$$

Параметры дерева в BIRCH

Попытаемся построить дерево, содержащее кластеры. В этом дереве каждый лист содержит несколько кластеров низшего уровня, а промежуточная вершина представляет кластер из всех своих поддеревьев. До построения зададимся двумя числами-ограничениями:

1. максимальным количеством поддеревьев у вершины дерева B;
2. максимально допустимый радиус (или диаметр) листа T (т.е. радиус или диаметр объединения всех кластеров этого листа).

Это значит, что в лист можно включать точки, пока они достаточно близки к существующим в нём точкам.

Вставка элемента в BIRCH

Пусть имеется новая точка Z_{N+1}. Вставим её в дерево:

1. найдём лист, в котором находится самый близкий к точке Z_{N+1} кластер;
2. попытаемся вставить в этот кластер точку Z_{N+1} и проверим, не нарушает ли она ограничение T;
3. если не нарушает, вставка сделана, иначе
4. пытаемся по ситуации или вставить новый лист, разделив старый, или перераспределить листья между соседними кластерами, или увеличить высоту дерева;
5. обновляем параметры (N, LS, SS) у затронутых вершин.

Итоговый результат: каждый лист отвечает за пространство достаточно малого размера, но листья могут распределяться по дереву неравномерно, повторяя распределение точек, т.е. используя локальность данных.

Достоинства и недостатки BIRCH

Достоинства:

- легко обрабатывает огромные массивы данных, потому что число элементов в кластерах минимального уровня не ограничено (ограничен только их разброс);
- можно комбинировать с другими алгоритмами на любом иерархическом уровне;
- число уровней иерархии всюду одинаково;
- хорошая локальность данных.

Недостаток: непонятно, как подбирать параметры B и T.

Оценка качества кластеризации

Единственного правильного решения задачи кластеризации нет.

Сложности при оценке качества:

- непонятно, что считать кластером: сплошные плотно заполненные области, невзирая на форму? Области определённой формы, невзирая на плотность заполнения? Что-то ещё?
- если каждый объект включен в какой-то кластер, это хорошо или плохо? Если нет, это хорошо или плохо?
- маленькие кластеры — это хорошо или плохо? Сколько их должно быть вообще?
- непонятно, как учитывать иерархическую кластеризацию: кластеры какого уровня оценивать?

Имеется множество метрик; обычно выбирают какую-либо из соображений пригодности для предметной области, не обосновывая выбор формально.

Подход 1: внешние критерии

Идея: **сравнить результат кластеризации с результатом классификации**, которая выполнена заранее и считается эталонно правильной.

Пусть имеется правильный набор классов и к каждому классу можно привязать ровно один полученный кластер.

Тогда можно считать каждый из кластеров классификатором, относящим объекты к своему классу.

Индекс RAND = accuracy такого классификатора:

$$Rand = \frac{TP + TN}{TP + TN + FP + FN}$$

Индекс Жаккара — похож на RAND, но без TN:

$$Jaccard = \frac{TP}{TP + FP + FN}$$

Индекс Фоулкса-Мэллоуса:

$$FowlkesMallows = \sqrt{\frac{TP}{TP + FP}\frac{TP}{TP + FN}} = \sqrt{Precision \cdot Recall}$$

Подход 2: внутренние критерии

Идея: оценить качество без эталонной классификации, исходя только из самих данных.
Пусть кластеров M штук; каждый обозначим $C_j, j = 1..M$, средняя точка каждого — $\overline{x_j}$.

Компактность: в хорошем кластере низкое внутрикластерное расстояние, т.е. надо минимизировать

$$\sum_{j=1}^{M} \sum_{i=1}^{|C_j|} (x_{ij} - \overline{x_j})^2$$

Отделимость: хорошие кластеры находятся далеко от среднего значения, т.е. надо максимизировать

$$\sum_{j=1}^{M} (x_j - \overline{x})^2$$

Подход 2: внутренние критерии (2)

Индекс Данна: если δ_{ij} — минимальное расстояние между элементами кластеров C_i и C_j, а Δ_i — максимальное расстояние между элементами кластера C_i, то хорошо, когда велико значение

$$\frac{\min \delta_{ij}, i \neq j}{\max \Delta_i}$$

Прочие соображения:

- среднее расстояние внутри одного кластера должно быть как можно меньше;
- среднее расстояние между элементами разных кластеров должно быть как можно больше;
- сумма средних внутрикластерных расстояний, взятая по всем кластерам, должна быть как можно меньше;
- сумма средних межкластерных расстояний, взятая по всем парам разных кластеров, должна быть как можно больше и т.п.

Рекомендации по используемым мерам качества имеются в описании работы 4.

Задача обработки текста

Специфика текста
Простейшие представления текста
Векторы признаков текста

Обработка текста в машинном обучении

Вопрос: пусть требуется решать одну из задач машинного обучения (например, классификацию, кластеризацию и т.п.) для выборки, состоящей из текстов. Как это делать?

Обработка текста в машинном обучении

Вопрос: пусть требуется решать одну из задач машинного обучения (например, классификацию, кластеризацию и т.п.) для выборки, состоящей из текстов. Как это делать?

Ответ: как и для любых объектов, нужно найти некоторое описание обрабатываемого текста, для которого поставленную задачу легко решить. Описанием может быть, например, числовой вектор конечной длины.

Вопрос: а в чём проблема?

Обработка текста в машинном обучении

Вопрос: пусть требуется решать одну из задач машинного обучения (например, классификацию, кластеризацию и т.п.) для выборки, состоящей из текстов. Как это делать?

Ответ: как и для любых объектов, нужно найти некоторое описание обрабатываемого текста, для которого поставленную задачу легко решить. Описанием может быть, например, числовой вектор конечной длины.

Вопрос: а в чём проблема?

Ответ:

- тексты имеют конечную, но произвольную длину $\Rightarrow$ их надо необратимо сжимать для получения вектора фиксированной длины;
- связи внутри текстов могут быть очень сложными, многослойными;
- многие тексты воспринимаются с трудом даже человеком.

Рекомендуемый источник: Jurafsky D., Martin J. Speech and Language Processing. Third Edition draft. https://web.stanford.edu/~jurafsky/slp3/ed3book.pdf

Сложности с текстами

Вопрос: в чём проблема в указанных фрагментах текстов?

«В середине ужина князь Андрей облокотился и, как человек, давно имеющий что-нибудь на сердце и вдруг решающийся высказаться, с выражением нервного раздражения, в каком Пьер никогда еще не видал своего приятеля, начал говорить.»

Толстой Л.Н. Война и мир. т.1, ч.1, гл. VI

«Холодное, как первые осенние заморозки, лицо, окруженные морщинками глаза выражают все переходы от деланной улыбки танцовщицы до зловещей хмурости ростовщика, — словом, её личность предопределяет характер пансиона, как пансион определяет ёе личность.»

Бальзак О. Отец Горио

Сложности с текстами

Вопрос: в чём проблема в указанных фрагментах текстов?
«В середине ужина князь Андрей облокотился и, как человек, давно имеющий что-нибудь на сердце и вдруг решающийся высказаться, с выражением нервного раздражения, в каком Пьер никогда еще не видал своего приятеля, начал говорить.»

Толстой Л.Н. Война и мир. т.1, ч.1, гл. VI

«Холодное, как первые осенние заморозки, лицо, окруженные морщинками глаза выражают все переходы от деланной улыбки танцовщицы до зловещей хмурости ростовщика, — словом, её личность предопределяет характер пансиона, как пансион определяет ёе личность.»

Бальзак О. Отец Горио

Ответ: длинные промежутки между связанными словами; длина ограничена слабо; во многих языках (например, немецком) такие связи — норма. Нужно как-то учитывать их.

Сложности с текстами (2)

Вопрос: а здесь?

«Является ли необходимой связь мышления и языка, подчиняется ли необходимости то, что явление суждения, завершающего познание, из сущностных оснований принимает форму утверждения, или нет, во всяком случае ясно, что суждения, которые принадлежат более высокой интеллектуальной сфере, в особенности, научной, едва ли могут осуществляться без языкового выражения.»

Гуссерль Э. Логические исследования, т. 2, введение

«Говоря об идее, что она госпожа, обеспечивающая непотаённость, Платон отсылает к тому невысказанному, что отныне существо истины не развёртывается как существо непотаённости из его собственной бытийной полноты, а перекладывается на существо идеи.»

Хайдеггер М. Учение Платона об истине

Сложности с текстами (2)

Вопрос: а здесь?

«Является ли необходимой связь мышления и языка, подчиняется ли необходимости то, что явление суждения, завершающего познание, из сущностных оснований принимает форму утверждения, или нет, во всяком случае ясно, что суждения, которые принадлежат более высокой интеллектуальной сфере, в особенности, научной, едва ли могут осуществляться без языкового выражения.»

Гуссерль Э. Логические исследования, т. 2, введение

«Говоря об идее, что она госпожа, обеспечивающая непотаённость, Платон отсылает к тому невысказанному, что отныне существо истины не развёртывается как существо непотаённости из его собственной бытийной полноты, а перекладывается на существо идеи.»

Хайдеггер М. Учение Платона об истине

Ответ: сложности восприятия специального текста.

Вопрос: что обычно пытаются сделать, чтобы облегчить восприятие?

Сложности с текстами (2)

Вопрос: а здесь?

«Является ли необходимой связь мышления и языка, подчиняется ли необходимости то, что явление суждения, завершающего познание, из сущностных оснований принимает форму утверждения, или нет, во всяком случае ясно, что суждения, которые принадлежат более высокой интеллектуальной сфере, в особенности, научной, едва ли могут осуществляться без языкового выражения.»

Гуссерль Э. Логические исследования, т. 2, введение

«Говоря об идее, что она госпожа, обеспечивающая непотаённость, Платон отсылает к тому невысказанному, что отныне существо истины не развёртывается как существо непотаённости из его собственной бытийной полноты, а перекладывается на существо идеи.»

Хайдеггер М. Учение Платона об истине

Ответ: сложности восприятия специального текста.

Вопрос: что обычно пытаются сделать, чтобы облегчить восприятие?

Ответ: используют контекст.

Контекст

Вопрос: что такое контекст?

[7] Лингвистический энциклопедический словарь. — М.: СЭ, 1990.

Контекст

Вопрос: что такое контекст?
Ответ: «фрагмент текста, включающий избранную для анализа единицу, необходимый и достаточный для определения значения этой единицы, являющегося непротиворечивым по отношению к общему смыслу данного текста. Иначе говоря, контекст есть фрагмент текста минус определяемая единица.»[7]

Т.е. для понимания каждой части текста надо обращаться ко всему остальному тексту $\Rightarrow$ надо как-то представлять текст вектором ограниченной длины (embedding).

Простейшие варианты:

- унитарный код;
- N-граммы.

[7] Лингвистический энциклопедический словарь. — М.: СЭ, 1990.

Модель языка

— описание языка в некоторой форме, позволяющее генерировать текст на нём, схожий по свойствам с создаваемыми людьми.

Чтобы учесть неопределённость языка, можно описать её так: пусть имеется последовательность слов, созданных до момента t: $w_1, w_2, ..., w_{t-1}$. Модель задаёт для каждого допустимого слова w вероятность того, что оно будет в этой последовательности следующим: $P(w|w_1, w_2, ..., w_{t-1})$.

Если имеется хорошая модель, можно 1) продолжить текст или 2) сгенерировать новый, чтобы получить результат, мало отличимый от написанного людьми.

Унитарный код

One-hot representation
Идея: создать список всех возможных слов (конечной длины L) и кодировать каждое слово вектором размерности L с единицей в одном разряде и нулями во всех остальных.
Текст можно представить как сумму таких векторов.

Вопрос: каковы достоинства и недостатки подхода?

Унитарный код

One-hot representation
Идея: создать список всех возможных слов (конечной длины L) и кодировать каждое слово вектором размерности L с единицей в одном разряде и нулями во всех остальных.
Текст можно представить как сумму таких векторов.

Вопрос: каковы достоинства и недостатки подхода?
Ответ:

- кодирование и декодирование одного слова проходит легко и за фиксированное время по любому тексту;
- порядок слов и связи между ними не учитываются — только их набор важен;
- представление разреженное (много нулей) $\Rightarrow$ занимает много места;
- сложно генерировать текст по его представлению.

Распространённые виды предобработки

До создания унитарного кода слова часто:

- выделяют **лемму** — «начальную форму» слова (*окна* $\rightarrow$ *окно*, *видишь* $\rightarrow$ *видеть*) и признаки грамматической формы (в русском языке — число, род, падеж и т.п.);
- определяют наличие характерных частей слова (приставок, суффиксов и т.п.);
- выбрасывают слишком распространённые или не имеющие самостоятельного значения слова (артикли, междометия и т.п.).

Унитарные коды признаков можно соединить с унитарным кодом слова, чтобы включить больше информации.

N-граммы

N-grams (bigram, trigram &c).
Идея: создать список всех встречающихся сочетаний N идущих подряд слов (N=2,3, иногда 4); каждое сочетание кодировать унитарно, как было показано выше. Текст тоже можно представить как сумму таких векторов.

Формально это значит, что мы строим языковую модель, отбрасывая старые слова: вместо $P(w|w_1, w_2, ..., w_{t-1})$ используем $P(w|w_{t-N+1}...w_{t-1})$.

Пример для N=2

После обработки текстовой обучающей выборки может быть получена, например, следующая таблица:

	i	want	to	eat	chinese	food	lunch	spend
i	5	827	0	9	0	0	0	2
want	2	0	608	1	6	6	5	1
to	2	0	4	686	2	0	6	211
eat	0	0	2	0	16	2	42	0
chinese	1	0	0	0	0	82	1	0
food	15	0	15	0	1	4	0	0
lunch	2	0	0	0	0	1	0	0
spend	1	0	1	0	0	0	0	0

На пересечении строки *i* и столбца *j* указывается, сколько раз за словом номер *i* следовало слово номер *j*. Всего в этом примере было 1446 слов.

Пример: вероятности

Если разделить каждый элемент на число появлений первого слова, получим вероятность встретить второе слово после первого:

i	want	to	eat	chinese	food	lunch	spend
2533	927	2417	746	158	1093	341	278

	i	want	to	eat	chinese	food	lunch	spend
i	0.002	0.33	0	0.0036	0	0	0	0.00079
want	0.0022	0	0.66	0.0011	0.0065	0.0065	0.0054	0.0011
to	0.00083	0	0.0017	0.28	0.00083	0	0.0025	0.087
eat	0	0	0.0027	0	0.021	0.0027	0.056	0
chinese	0.0063	0	0	0	0	0.52	0.0063	0
food	0.014	0	0.014	0	0.00092	0.0037	0	0
lunch	0.0059	0	0	0	0	0.0029	0	0
spend	0.0036	0	0.0036	0	0	0	0	0

Её можно использовать для генерации.

Сглаживание

Чтобы дать хоть какой-то шанс сочетаниям, не встречавшимся в выборке, часто добавляют небольшое количество ко всем элементам матрицы, например 1:

	i	want	to	eat	chinese	food	lunch	spend
i	6	828	1	10	1	1	1	3
want	3	1	609	2	7	7	6	2
to	3	1	5	687	3	1	7	212
eat	1	1	3	1	17	3	43	1
chinese	2	1	1	1	1	83	2	1
food	16	1	16	1	2	5	1	1
lunch	3	1	1	1	1	2	1	1
spend	2	1	2	1	1	1	1	1

N-граммы: плюсы и минусы

Вопрос: каковы достоинства и недостатки подхода?

N-граммы: плюсы и минусы

Вопрос: каковы достоинства и недостатки подхода?
Ответ:

- учитываются порядок слов и связи между ними длиной до N-1;
- можно сгенерировать текст по его представлению (т.е. это представление — языковая модель);
- представление ещё более разреженное, чем унитарный код $\Rightarrow$ для качественного обучения нужны огромные выборки.

Текст, сгенерированный N-граммами

Вопрос: как сгенерировать текст с помощью N-грамм?

Текст, сгенерированный N-граммами

Вопрос: как сгенерировать текст с помощью N-грамм?
Ответ: взять случайно первые N-1 слов; определить самое вероятное следующее слово и добавить его, потом по последним N-1 словам определить следующее и т.д. до получения нужной длины.

Примеры, полученные из Wall Steet Journal (40 млн. слов; см. книгу Jurafsky,Martin)
N=1: Months the my and issue of year foreign new exchange's september were recession exchange new endorsed a acquire to six executives
N=2: Last December through the way to preserve the Hudson corporation N.B.E.C. Taylor would seem to complete the major central planners one point five percent of U.S.E. has already old M.X. corporation of living on information such as more frequently fishing
N=3: They also point to ninety nine point six billion dollars from two hundred four oh six three percent of the rates of interest stored as Mexico and Brazil on market conditions

Вектор признаков слова

Word embedding
Построение word embedding — представление слова в виде вектора так, чтобы близкие слова имели близкие вектора, далёкие — далёкие вектора.
Методов очень много, их часто комбинируют. Важные аспекты:

- слова с близкими значениями возникают обычно в похожих контекстах, можно это использовать;
- размерность вектора должна быть малой (представление — не разреженное);
- надо как-то ухватить, помимо прочего, семантику слова и контекст;
- нужно обеспечить обобщение слова до синонимов.

Общие подходы к word embedding

Два основных семества методов:

На основе частоты: если слово часто возникает в одной группе документов корпуса и редко — в другой, его вектор надо сблизить с векторами других слов с подобным свойством. Примеры: TF-IDF, PMI.

На основе предсказаний: обучим систему на некотором тексте предсказывать, какие слова должны появляться рядом с текущим обрабатываемым, и будем считать факт появления слова в предсказании признаком близости. Пример: Word2Vec (Google, 2013).

TF-IDF

Term Frequency - Inverse Document Frequency
Базовая идея: разделим обучающую выборку на фрагменты — отдельные части примерно одинаковой длины. Если слова встречаются в одном фрагменте часто, их вектора нужно сблизить; но если какое-то из слов встречается очень часто, то, наоборот, никакие вектора не надо сближать с ним, потому что оно не показательно (слишком общеупотребительно).

TF: в простейшем случае количество появлений C_{ji} слова j в документе i. Чтобы показать, что слишком большого числа появлений не требуется (наступает эффект насыщения), часто используют $TF = 1 + \log_{10} C_{ji}$ при $C_{ji} > 0$ и $TF = 0$ при $C_{ji} = 0$.

IDF: в простейшем случае доля документов, в которых встречается слово j: D_j/N, где N — общее число документов. Обычно используют $IDF = \log_{10}(N/D_j)$.

TF-IDF: взвешивание

Если перемножить TF и IDF для данных документа i и слова j, результат покажет, насколько значимо это слово в этом документе:

$$(1 + \log_{10} C_{ji}) \log_{10}(N/D_j)$$

- редко встречающиеся в документе слова снизят результат из-за маленького TF;
- слова, встречающиеся везде, снизят результат из-за маленького IDF

В результате можно получить вектор признаков для каждого документа (если объединить результаты для каждого слова) или для каждого слова (если объединять результаты для каждого документа).

PMI

Pointwise Mutual Information

Для каждой пары слов можно оценить вероятность, с которой они встречаются в одном документе (т.е. рассчитать долю документов, где они встречаются вместе) $P(w_1, w_2)$.

Можно оценить и вероятности того, что каждое из них встречается в документе $P(w_1)$, $P(w_2)$.

Если эти события независимы, то $P(w_1, w_2) = P(w_1)P(w_2)$; иначе это не так.

Используем как меру сходства двух слов $\log_2 \frac{P(w_1,w_2)}{P(w_1)P(w_2)}$

PMI: уточнение

$$\log_2 \frac{P(w_1, w_2)}{P(w_1)P(w_2)}$$

Технически это выражение может быть сколь угодно малым, но обычно маленькие значения малоинформативны: два слова обычно встречаются вместе очень редко, потому что они специализированные, и отдельно обрабатывать возникающие большие отрицательные величины не хочется. Поэтому часто используют только положительные значения, а остальные зануляют:

$$PMI = max(\log_2 \frac{P(w_1, w_2)}{P(w_1)P(w_2)}, 0)$$

Использование TF-IDF и PMI

Два вектора для документов можно использовать для оценки их сходства, посчитав скалярное произведение.

Два вектора для разных слов можно точно так же использовать для оценки их сходства, посчитав скалярное произведение.

Представить документ можно также средним значением векторов всех его слов.

Недостаток: размерности векторов могут быть большими (число слов или документов)

Тема 8

Многомерное шкалирование

Распознавание выбросов

Многомерное шкалирование

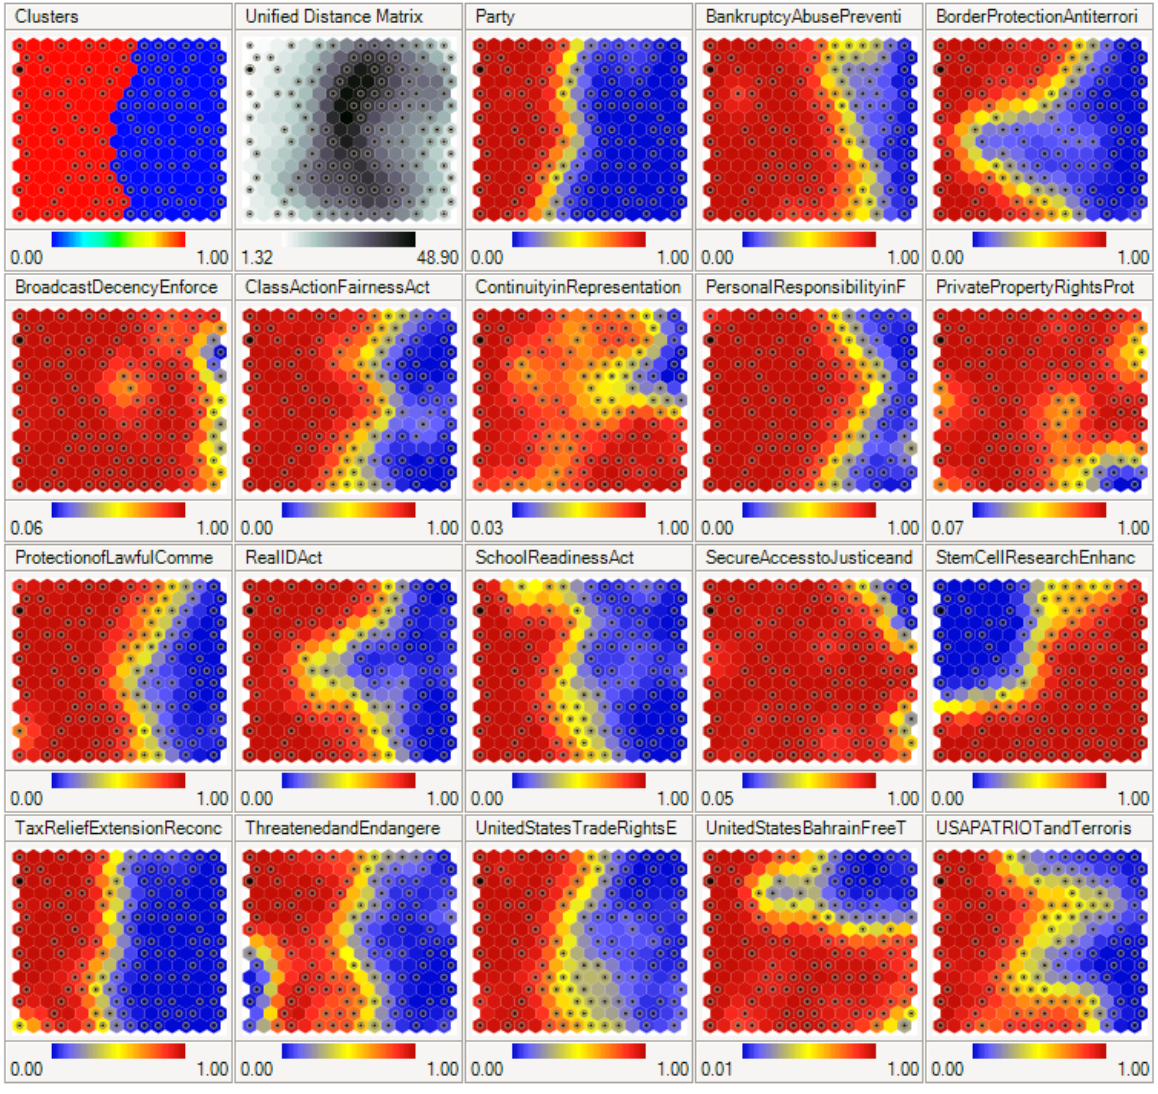
Метод Ньютона-Рафсона
Карта Кохонена

Идея шкалирования

Часто хочется наглядно представить близость/дальность друг к другу точек многомерных данных, но методы, сохраняющие пропорции (анализ главных компонент и т.п.), применимы плохо: слишком велика размерность.

Пример: пусть имеются результаты парламентских голосований по некоторому кругу вопросов (т.е. известно, какие депутаты были «за», какие — «против». Можно ли наглядно представить близость позиций депутатов на одномерном или двумерном графике, т.е. расположить их так, чтобы точки, соответствующие депутатам с близкими позициями, были бы ближе, чем точки депутатов с отличающимися позициями?

Пример результата: карта близости позиций



Неформальное описание задачи шкалирования

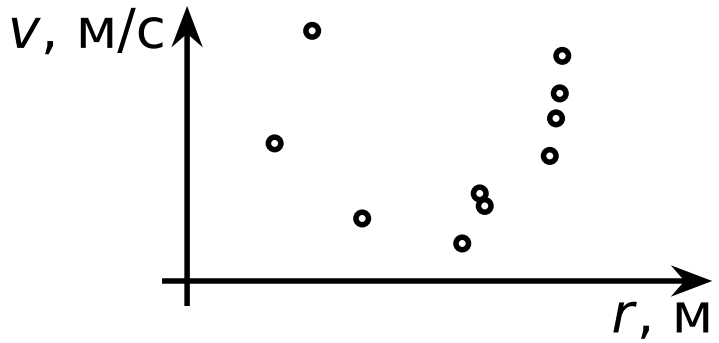
Пусть имеется выборка данных с достаточно большим числом параметров. Требуется расположить их на гиперплоскости малой размерности (обычно двумерной, иногда одномерной) так, чтобы прецеденты с близкими параметрами располагались ближе, с разными — дальше.

Область применения — визуализация многомерных данных для поиска присущей данным структуры: связей между прецедентами, кластеров, выбросов.

Очевидно, что задача поставлена некорректно: точно судить о том, что является решением, а что — нет, нельзя.

Пример одномерной шкалы

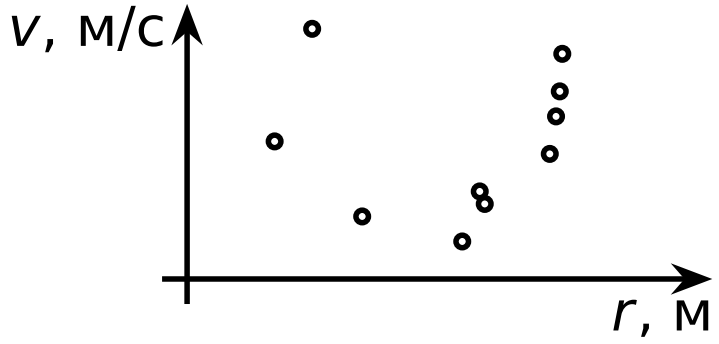
Пусть точки располагаются так:



Вопрос: можно ли их расположить на одномерной шкале? Если да, в каких единицах будет измеряться положение на шкале?

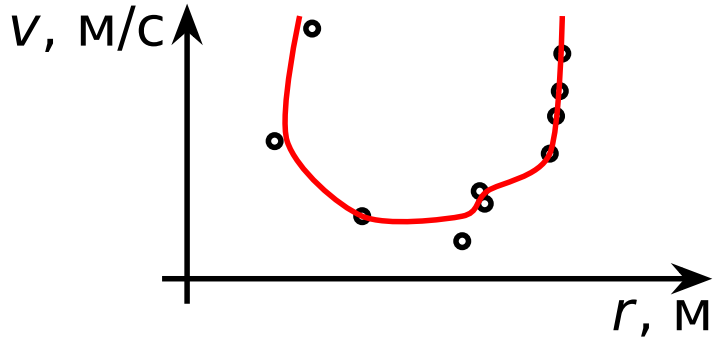
Пример одномерной шкалы

Пусть точки располагаются так:



Вопрос: можно ли их расположить на одномерной шкале? Если да, в каких единицах будет измеряться положение на шкале?

Ответ: расположить можно; единицы не определены.



Постановка задачи шкалирования

Пусть имеется выборка Z из N прецедентов $\{z_1, z_2, ..., z_N\}$. Между некоторыми из них известны расстояния $\rho(z_i, z_j)$. Требуется найти признаковое описание прецедентов, сохраняющее расстояния между ними, т.е. отображение

$$H : Z \to \mathbb{R}^k : \rho(z_i, z_j) \approx d(H(z_i), H(z_j)),$$

где d — евклидово расстояние. Обычно размерность пространства признаков k равна 1 или 2.

Чаще всего для этого минимизируют величину

$$\sum_{z_i, z_j \in Z} w_{ij}(\rho(z_i, z_j) - d(H(z_i), H(z_j)))^2,$$

т.е. некоторую взвешенную сумму квадратов разностей истинных и признаковых расстояний.

Итеративный алгоритм шкалирования

Простейший жадный алгоритм выглядит так:

1. добавим несколько первых точек в произвольные места для задания основы карты;
2. по очереди будем добавлять остальные точки, каждый раз помещая очередную из них в оптимальное с точки зрения расстояний место.

Глобальной оптимальности добиться не удастся, но и локального оптимума может хватить. Если есть сомнения, повторим процесс с другими начальными точками.

Для основы проще всего взять три точки, попарно удалённых друг от друга на максимальные расстояния.

Метод Ньютора-Рафсона для размещения одного прецедента

Попытаемся добавить к некоторому существующему размещению ещё один прецедент z. Его позицию будем строить итеративно, пытаясь минимизировать величину

$$E(H(z)) = \sum_{z_i \in Z} w_i(\rho(z_i) - d(H(z_i)))^2,$$

где ρ — расстояние от прецедента z_i до z, d — аналогичное расстояние между их образами.

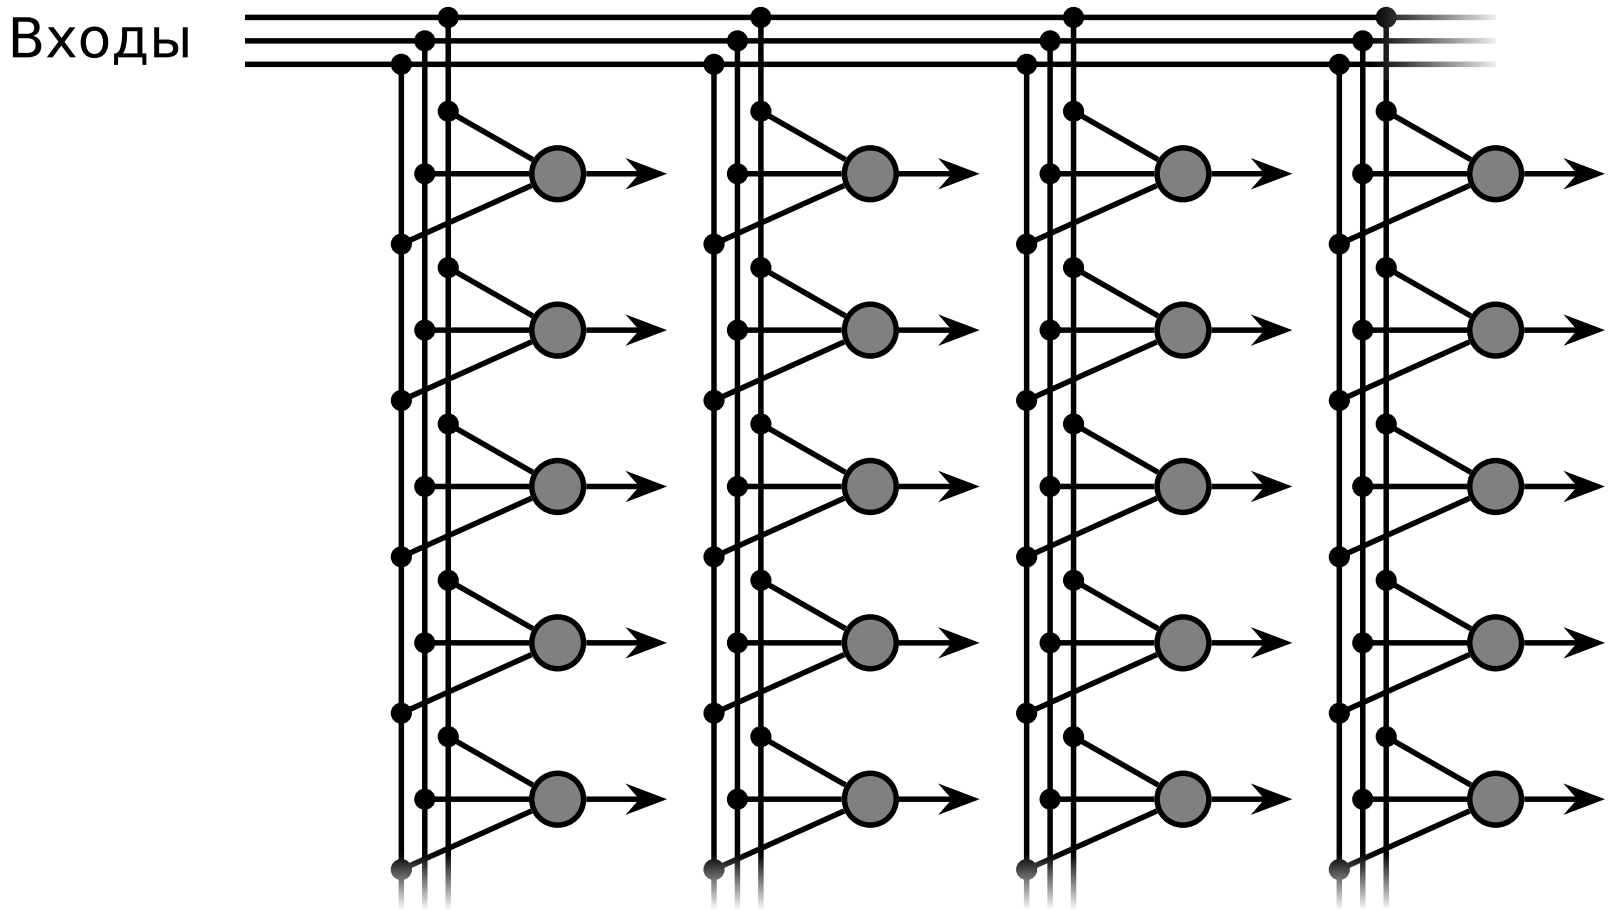
Попытаемся минимизировать функцию по методу Ньютона-Рафсона, меняя $H(z)$ итеративно:

$$H^{(t+1)} = H^{(t)} - \alpha(E''(H^{(t)})^{-1}E'(H^{(t)}),$$

где E' — вектор первых производных E по координатам H (градиент), E'' — матрица вторых производных E по координатам H (гессиан).
Считаем, находим очередное приближение.

Нейронная сеть как карта

Другой подход основан на нейронной сети специальной структуры — карте Кохонена:



Все входы подаются на все нейроны, расположенные в узлах двумерной решётки; обратных связей нет.

Свойства сети

Это сеть прямого распространения с одним слоем

Так как формальные нейроны располагаются в узлах целочисленной решётки, при обучении они считаются пространственно связанными.

Обучение каждому прецеденту проходит в три стадии:

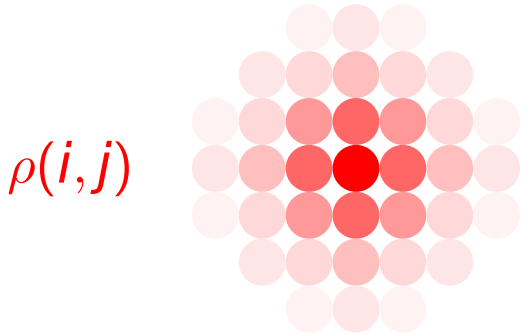
1. Конкуренция: для прецедента вычисляются значения каждого нейрона, определяется победитель — нейрон, сильнее всего среагировавший на прецедент;
2. Кооперация: выбираются нейроны, геометрически близкие к победителю;
3. Адаптация: веса синапсов победителя и его близких меняются так, чтобы повысить их отклик на этот прецедент.

Ход обучения

Конкуренция:
Для формального нейрона номер i с синаптическими коэффициентами w_i считаем величину $w_i x$, где x — входной вектор. После этого находим нейрон, у которого эта величина больше других. Нелинейное преобразование результата не требуется.

Кооперация:
Находим соседей этого нейрона по некоторой мере близости координат в решётке, например по функции

$$\rho(i,j) = e^{-\frac{d_{ij}}{2\sigma^2}}$$



Ход обучения (2)

Адаптация:
Пусть у нейрона j вектор весов равны w_j; вектор входного сигнала равен x, текущее значение выхода y_j. По смыслу требуется:

- нарастить значение нейрона тем больше, чем ближе он к победителю;
- слегка снизить его, чтобы осуществить забывание.

Изменим веса нейрона j на:

$$\delta w_j = \eta \rho(i,j)(x - w_j),$$

где η — скорость обучения.

Общие выводы по шкалированию

Развивается в показанном виде очень слабо, применяется крайне мало:

- интерпретируемость результатов часто плохая;
- общих методов оценки качества, позволяющих итеративное улучшение, нет.

Ограниченно используется для визуализации.

Распознавание выбросов

Минимальный определитель ковариации
Одноклассовый метод опорных векторов
Локальный уровень выброса

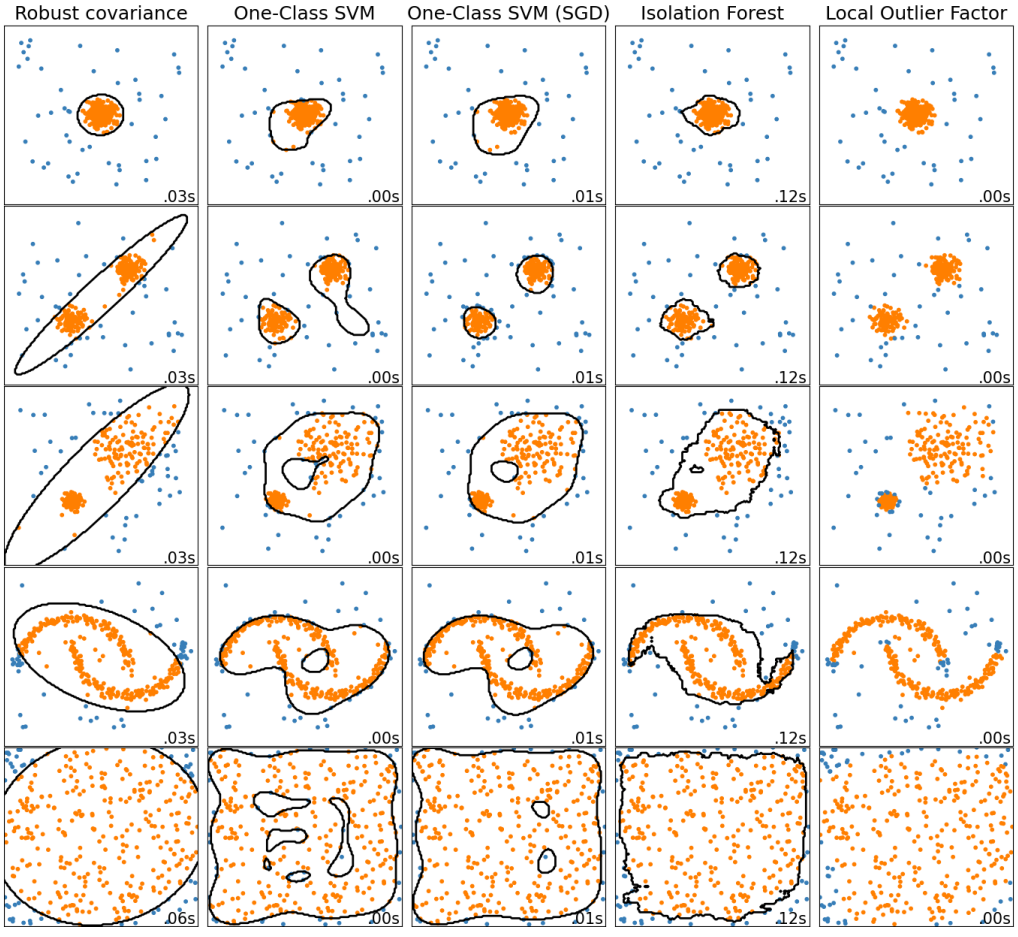
Постановка задачи

Outlier detection
Пусть имеется выборка Z из N прецедентов (описаний объектов), каждый из которых состоит из набора параметров $\{x_1, x_2, ..., x_k\}$. Найти те из них, которые явно выделяются среди других (т.е. не похожи на остальных).

Вариант постановки — распознавание новизны (novelty detection):
Пусть имеется выборка Z_{old} и модель её данных, т.е. некоторое описание: набор кластеров, распределение вероятностей и т.п. Найти элементы в новой выборке Z_{new}, не похожие на элементы Z_{old}, т.е. не подходящие под модель.

Общее название — распознавание аномалий (anomaly detection).

Примеры методов из scikit-learn



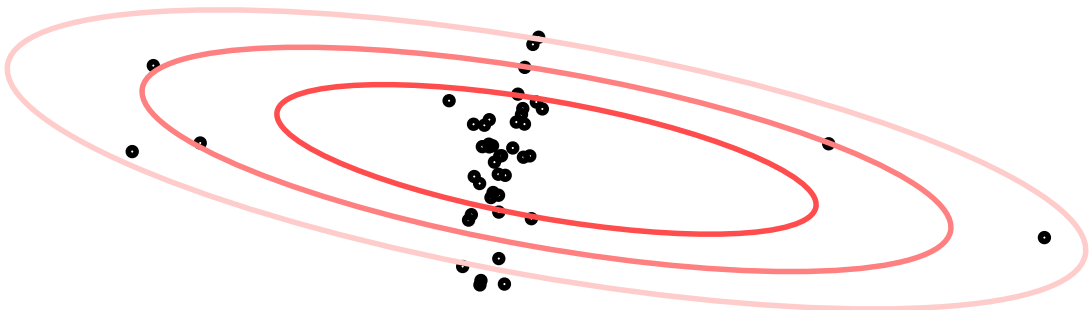
Подробно рассмотрим три подхода: минимальный определитель ковариации, одноклассовый метод опорных векторов, локальный уровень выброса

Метод робастной оценки ковариации

Ранее говорилось, что, если считать плотность вероятности распределения, породившего выборку Z, нормальной, то можно оценить параметры этого нормального распределения по выборке (см. Нормальный дискриминантный анализ, л. 5).

У этого метода есть проблема: выбросы искажают оценку.

Вопрос: как можно это использовать для распознавания выбросов?

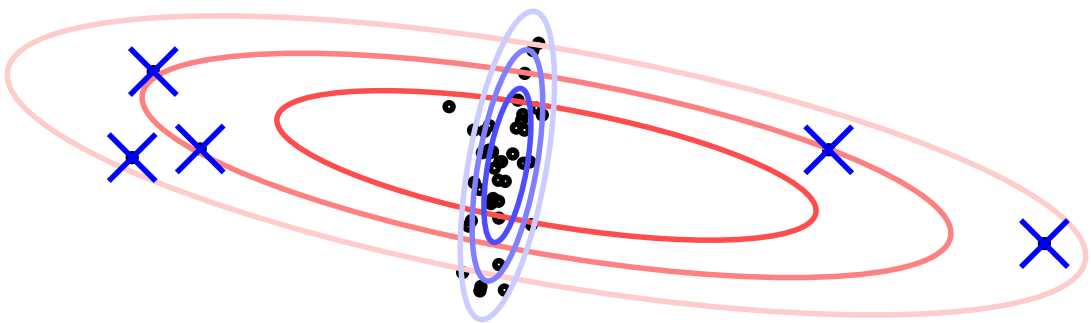


Метод робастной оценки ковариации

Ранее говорилось, что, если считать плотность вероятности распределения, породившего выборку Z, нормальной, то можно оценить параметры этого нормального распределения по выборке (см. Нормальный дискриминантный анализ, л. 5).

У этого метода есть проблема: выбросы искажают оценку.

Вопрос: как можно это использовать для распознавания выбросов?



Ответ: можно как-нибудь попробовать оценить гауссиану, построенную на данных без учёта выбросов (т.е. более робастную), и считать выбросами данные, которые хорошо подходят под обычную гауссиану и плохо — под робастную.

Эллиптическое унимодальное распределение

Пусть все параметры Z численные, их среднее значение по выборке — μ, их ковариация — Σ. Как ранее говорилось, расстояние Махаланобиса от точки x до величины, распределённой таким образом, определяется как:

$$d(x, \mu, \Sigma) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$$

Предположим, что распределение, породившее Z, имеет следующую плотность:

$$f(x, \mu, \Sigma) = \frac{1}{\sqrt{|\Sigma|}} g(d(x, \mu, \Sigma)),$$

где g — убывающая функция. Иначе говоря, распределение, породившее Z, имеет максимум в μ и убывает при удалении от μ в зависимости от расстояния Махаланобиса. Такое распределение называется эллиптическим унимодальным.

Подход к решению

Идея: возьмём не все n, а меньшее число прецедентов h: $n/2 < h < n$; при этом их всё же должно быть больше, чем параметров: $h > k$. Вычислим для них тем же способом, что раньше, среднее значение и ковариацию ($\hat{\mu}$ и $\hat{\Sigma}$).

Если окажется, что $\hat{\Sigma}$ определяет маленький эллипс рассеяния, то можно использовать распределение $\hat{f} = f(x, \hat{\mu}, \hat{\Sigma})$, чтобы отделить выбросы: они будут иметь маленькие $\hat{f}$, но достаточно большие f.

Вопрос: есть ли проблемы у этой идеи?

Подход к решению

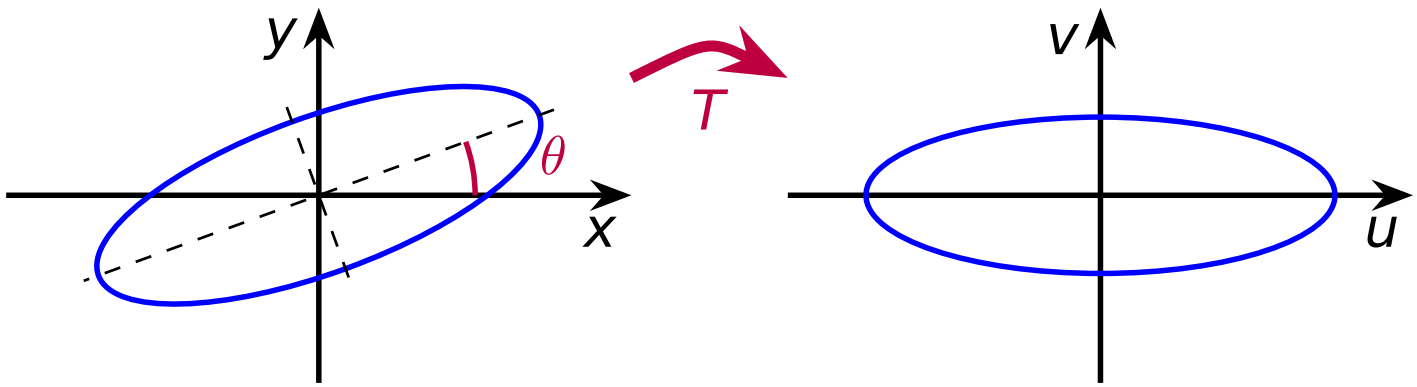
Идея: возьмём не все n, а меньшее число прецедентов h: $n/2 < h < n$; при этом их всё же должно быть больше, чем параметров: $h > k$. Вычислим для них тем же способом, что раньше, среднее значение и ковариацию ($\hat{\mu}$ и $\hat{\Sigma}$).

Если окажется, что $\hat{\Sigma}$ определяет маленький эллипс рассеяния, то можно использовать распределение $\hat{f} = f(x, \hat{\mu}, \hat{\Sigma})$, чтобы отделить выбросы: они будут иметь маленькие $\hat{f}$, но достаточно большие f.

Вопрос: есть ли проблемы у этой идеи?
Ответ:
Проблема 1: что такое «маленький эллипс рассеяния»?
Проблема 2: как подобрать такие элементы выборки, чтобы этот эллипс был маленьким?

Маленький ли эллипс?

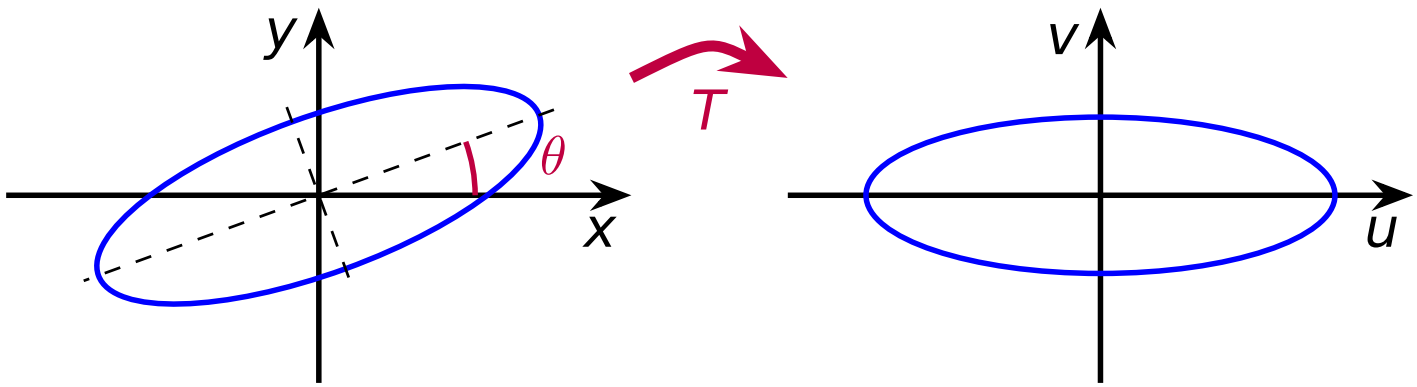
Величина эллипса рассеяния зависит от матрицы $\hat{\Sigma}$. Можно, не меняя объёма эллипса, преобразовать её (повернуть и перекосить) так, чтобы оси эллипса стали параллельны осям координат:



Матрица $\hat{\Sigma}$ при этом станет диагональной; на диагонали будут находиться дисперсии по каждой координате.
Вопрос: что можно взять как меру величины эллипса?

Маленький ли эллипс?

Величина эллипса рассеяния зависит от матрицы $\hat{\Sigma}$. Можно, не меняя объёма эллипса, преобразовать её (повернуть и перекосить) так, чтобы оси эллипса стали параллельны осям координат:



Матрица $\hat{\Sigma}$ при этом станет диагональной; на диагонали будут находиться дисперсии по каждой координате.
Вопрос: что можно взять как меру величины эллипса?
Ответ: произведение дисперсий, т.е. определитель $|\hat{\Sigma}|$.

Минимальный определитель ковариации

MCD (Minimum Covariance Determinant)[8]

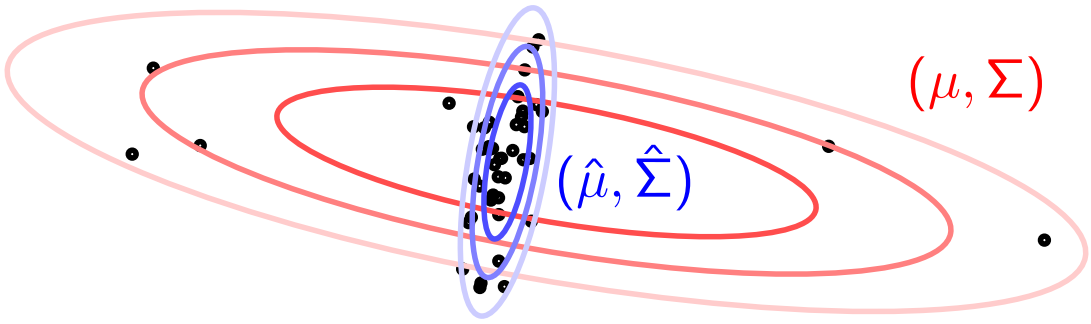
По проблеме 2: в общем виде задача поиска такой подвыборки, чтобы определитель $|\hat{\Sigma}|$ был минимальным, решается только полным перебором. Решим приближённо.

Идея (FastMCD):

1. возьмём на первом шаге любое подмножество Z размера h, назовём его H_1;
2. посчитаем для текущего H_i $\hat{\mu}_i$ и $\hat{\Sigma}_i$;
3. определим расстояния Махаланобиса от распределения $(\hat{\mu}_i, \hat{\Sigma}_i)$ для всех точек выборки, расположим точки по возрастанию этого расстояния: $[z_1, z_2, ..., z_n]$;
4. возьмём первые h точек из полученного списка, построим из них H_{i+1}; Доказано, что после этого определитель матрицы ковариации не увеличится: $|\hat{\Sigma_{i+1}}| \leq |\hat{\Sigma}_i|$
5. если определитель не снизится, завершим подбор. Иначе перейдём к шагу 2.

[8] Обзорная статья с описанием метода и его вариантами

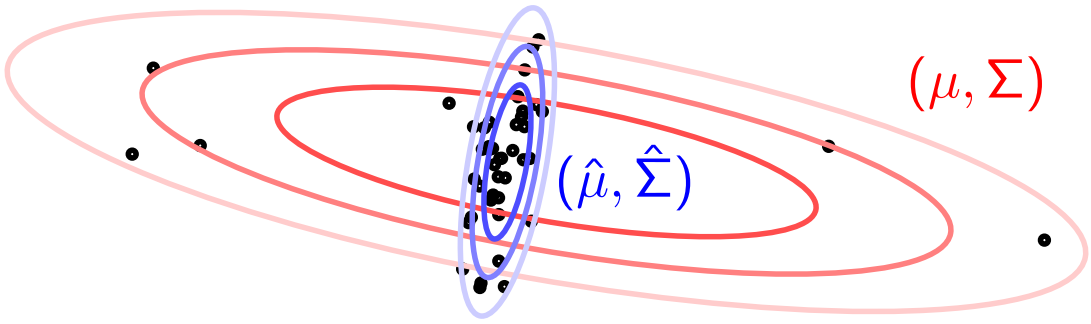
Распознавание выбросов



Имея хорошие $\hat{\mu}$ и $\hat{\Sigma}$, можно отбросить выбросы, задавшись некоторым пороговым расстоянием Махаланобиса до распределения $(\hat{\mu}, \hat{\Sigma})$.
Обычно до отсеивания домножают $\hat{\Sigma}$ на некоторую константу c, чтобы учесть ширину разброса.

Итого у метода два параметра: число точек в подвыборке h и константа увеличения ковариации c.
Вопрос: в чём физический смысл h и c?

Распознавание выбросов

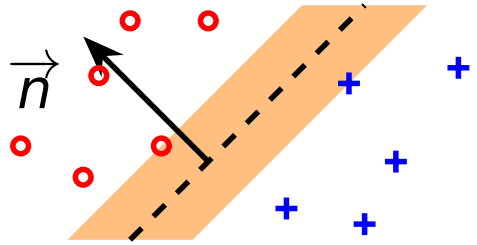


Имея хорошие $\hat{\mu}$ и $\hat{\Sigma}$, можно отбросить выбросы, задавшись некоторым пороговым расстоянием Махаланобиса до распределения $(\hat{\mu}, \hat{\Sigma})$.
Обычно до отсеивания домножают $\hat{\Sigma}$ на некоторую константу c, чтобы учесть ширину разброса.

Итого у метода два параметра: число точек в подвыборке h и константа увеличения ковариации c.
Вопрос: в чём физический смысл h и c?
Ответ: h показывает, насколько много может быть выбросов, c — насколько далёкими должны быть данные, чтобы считаться выбросами.

Одноклассовый метод опорных векторов

Ранее мы использовали метод опорных векторов (SVM) для классификации.



Идея была в том, чтобы максимально нарастить промежуток между линейно отделимыми классами; на случай, если они не отделимы линейно, в оптимизируемую функцию включался штраф.

Идея: максимально снизить размеры сферы, включающей в себя все обычные объекты; вносить штраф в оприимизируемую функцию за каждый выброс (прецедент, не вошедший в сферу); решать так же, как обычный SVM.

Постановка задачи минимизации

Пусть точки выборки $Z = z_1, z_2, ..., z_n$ лежат внутри сферы радиуса R с центром a. Минимизируем величину R^2 при условии, что $|z_i - a|^2 \leq R^2$.

На случай выбросов добавим к минимизируемой функции штраф, как и раньше: $R^2 + C \sum_{i=1}^{n} \xi_i$, $\xi_i \geq 0$

Как и раньше, используем множители Лагранжа, чтобы включить условия в оптимизируемую функцию, и решаем полученную задачу квадратичной минимизации некоторой функции L:

$$L = R^2 + C \sum_{i=1}^{n} \xi_i + \sum_{i=1}^{n} \alpha_i (R^2 + \xi_i - |z_i|^2 + 2 z_i a - |a|^2) + \sum_{i=1}^{n} \gamma_i \xi_i$$

Величину L надо оптимизировать относительно параметров ξ_i, α_i, γ_i. Решаем и получаем поверхность, отделяющую выбросы.

Борьба с нелинейностью

А что делать, если сфера не годится как приближение формы облака точек?

Можно модифицировать SVM использованием ядер. Назовём здесь ядром функцию от двух прецедентов, способную заменить их скалярное произведение:

$$K(z_1, z_2) : (X, X) \to \mathbb{R} : K(z_1, z_2) = (\phi(z_1), \phi(z_2)),$$

Иначе говоря, ядро K можно представить как скалярное произведение в некотором пространстве, перевести прецеденты в которое можно функцией ϕ.

Примеры ядер:

- линейное: $K(z_1, z_2) = (z_1, z_2)$;
- полиномиальное: $K(z_1, z_2) = ((z_1, z_2) + C)^d$;
- гауссово: $K(z_1, z_2) = e^{-\frac{|z_1 - z_2|^2}{2\sigma^2}}$ и др.

Борьба с нелинейностью (2)

Это значит, что можно заменить всюду в формулах SVM скалярное произведение на ядро, что позволит нелинейно перевести задачу в другое пространство, сохранив квадратичность оптимизации. Например, вместо

$$\begin{cases} |n|^2 \to min(n,b) \\ (n,X_i) - b \geq 1, y(X_i) = 1 \\ (n,X_i) - b \leq -1, y(X_i) = -1 \end{cases}$$

будет решаться задача

$$\begin{cases} |n|^2 \to min(n,b) \\ K(n,X_i) - b \geq 1, y(X_i) = 1 \\ K(n,X_i) - b \leq -1, y(X_i) = -1 \end{cases}$$

Подробные доказательства не рассматриваем.

Локальный уровень выброса

Local Outlier Factor, LOF
Идея: выброс обычно расположен далеко от соседей. Если у какого-то прецедента среднее расстояние до соседей большое, а у этих соседей аналогичное расстояние маленькое, этот прецедент — выброс.

Пусть для прецедента z известны расстояния до всех других прецедентов; упорядочим их и отсортируем, получив список $[\rho_1, \rho_2, ..., \rho_{n-1}]$. k-расстояние от z до выборки $r_k(z)$ — расстояние ρ_k, т.е. дистанция до k-го ближайшего соседа.

Расстояние достижимости

Введём величину «расстояние достижимости» до $z1$ из $z2$: $RD(z_1, z_2) = max(r_k(z_2), d(z_1, z_2))$, где $d(z_1, z_2)$ — обычное расстояние между объектами z_1 и z_2. Это — то же, что обычное расстояние, но для данного z_2 оно не может быть меньше $r_k(z_2)$.

Для каждого объекта z_i найдём среднее значение расстояния достижимости **от его соседей** $N_k(z_i)$ **к нему** (не наоборот!):

$$MD(z_i) = \frac{\sum\limits_{j \in N_k(z_i)} RD(z_i, z_j)}{|N_k(z_i)|}$$

Чем меньше $MD(z_i)$, тем ближе объект к своим соседям. Если взять величину, обратную к $MD(z_i)$, получим плотность достижимости: чем она больше, тем в большей степени объект близок к другим.

Коэффициент локального уровня выброса

$$LRD(z_i) = \frac{1}{MD(z_i)}$$

Сравним локальные плотности точки и её соседей. Для этого вычислим среднее отношение плотностей у соседей и у самой точки — коэффициент локального уровня выброса:

$$LOF(z_i) = \frac{\sum\limits_{j \in N_k(z_i)} LRD(z_j)/LRD(z_i)}{|N_k(z_i)|} = \frac{\sum\limits_{j \in N_k(z_i)} LRD(z_j)}{|N_k(z_i)|LRD(z_i)}$$

Если локальные плотности примерно равны, коэффициент близок к 1; если он значительно больше одного, объект z_i — выброс.

Общие выводы по распознаванию выбросов

Достоинства и недостатки — те же, что у всего обучения без учителя:

Достоинства: срабатывают всегда, на практике результаты часто хорошие.

Недостатки: некорректность задачи (нет критерия правильности срабатывания), много сложно интерпретируемых гиперпараметров.

Тема 9

Логические методы классификации

Логические методы классификации

Классификация в логических терминах
Информативность предикатов
Построение предикатов
Решающий список
Решающее дерево

Разные представления результатов классификации

В методах, использованных ранее, результаты классификации очень часто плохо воспринимаются человеком:
«Этот товар будет продаваться плохо, потому что для него величина $\frac{e^{1.12x_1+0.33x_3-x_4}}{18.234}$ больше величины $\frac{e^{-0.2x_1+1.21x_2-x_3+0.01x_4}}{17.324}$»
Объяснить полученный вывод (даже если он максимально правдоподобен) будет сложно.

Людям привычнее объяснения вида:
«Этот товар будет продаваться плохо, потому что скидка на него меньше 3%, цена на него больше средней рыночной на 6% и товары этого производителя в этом году продаются плохо»

Результаты в таких терминах можно передать эксперту для оценки и пополнения.

Классификтор как набор правил

Такой классификатор — организованный набор **логических правил** вида «Если верно некоторое утверждение относительно параметров прецедента, то его класс — такой-то». При этом утверждение — это комбинация функций от параметров: $\varphi : X \to \{true, false\}$. Функции, возвращающие логическое значение, называются **предикатами**. Т.е. условия правил состоят из предикатов.

Всё это замечательно, но возникают вопросы:

1. как строить предикаты, ведь входные данные очень разнообразны?
2. как выбрать из построенных предикатов самые полезные, чтобы классификатор был проще?
3. как сочетать предикаты, чтобы получались условия правил?
4. как организовывать правила, если их понадобится много?

Не все предикаты одинаково полезны

Вопрос: как выбрать самые полезные предикаты для классификации?

Не все предикаты одинаково полезны

Вопрос: как выбрать самые полезные предикаты для классификации?
Ответ: возможных вариантов множество. Самые типичные:

- статистические;
- энтропийные,

а также разнообразные эвристики.

Что такое «полезность предиката»?

Пусть имеется логическая функция (предикат) $\varphi(X)$ на множестве всех прецедентов обучающей выборки. С точки зрения каждого из классов C_i предикат делит выборку на 4 части:

1. $\varphi(X) = true, X \in C_i$;
2. $\varphi(X) = true, X \notin C_i$;
3. $\varphi(X) = false, X \in C_i$;
4. $\varphi(X) = false, X \notin C_i$.

Вопрос: какие предикаты самые полезные для классификации объекта как члена класса C_i (или не члена класса C_i)?

Что такое «полезность предиката»?

Пусть имеется логическая функция (предикат) $\varphi(X)$ на множестве всех прецедентов обучающей выборки. С точки зрения каждого из классов C_i предикат делит выборку на 4 части:

1. $\varphi(X) = true, X \in C_i$;
2. $\varphi(X) = true, X \notin C_i$;
3. $\varphi(X) = false, X \in C_i$;
4. $\varphi(X) = false, X \notin C_i$.

Вопрос: какие предикаты самые полезные для классификации объекта как члена класса C_i (или не члена класса C_i)?
Ответ: те, которые лучше других отделяют C_i и остальные классы. Например, хорошо, если первая из указанных частей намного больше или намного меньше второй.

Попытка формализации

Пусть предикат $\varphi(X)$ возвращает истинное значение для p прецедентов класса C_i из имеющихся P и n прецедентов вне этого класса из имеющихся N. Чтобы эффективно отделить C_i от остальных, хотелось бы, чтобы p был как можно больше, а n — как можно меньше. Для обеспечения этого могут применяться разные простые меры полезности:

- $p - n$;
- $\alpha p - \beta n$;
- $p/P - n/N$;
- $\frac{p}{n+1}$ и др.

Формально их эффективность доказать в общем случае не получается, но сработать они могут.

Рассмотрим более формальные подходы.

Статистический критерий

Допустим, что выборка X, по которой строятся предикаты, состоит из независимых друг от друга прецедентов. Пусть значение предиката $\varphi(X)$ и принадлежность предиката к классу C_i $C_i(X)$ — случайные величины. Если величины $\varphi(X)$ и $C_i(X)$ независимы, то вероятность появления p и n равна

$$F = \frac{C_P^p C_N^n}{C_{N+P}^{n+p}},$$

где C_b^a — биномиальный коэффициент:

$$C_b^a = \frac{b!}{a!(b-a)!}$$

Если эта вероятность мала, но количество прецедентов в φ именно p и n, то, скорее всего, $\varphi(X)$ и $C_i(X)$ не независимы, т.е. между предикатом и принадлежностью к классу есть связь.

Статистическая информативность

Статистическая информативность предиката:

$$I(C_i, \varphi) = -\ln F$$

Чем больше I, тем более информативен предикат. Для отбора лучших предикатов можно, например, установить пороговое значение I и не рассматривать варианты ниже него.

Для ускорения вычисления $ln(a!)$ можно при больших a использовать формулу Стирлинга:

$$\ln(a!) \approx a \ln a - a + \frac{\ln 2\pi a}{2} + \frac{1}{12a} - \frac{1}{360a^2}$$

Энтропийная информативность

Другой вариант критерия полезности формулируется через энтропию.

Пусть некое событие произойдёт с вероятностью f (и не произойдёт с вероятностью $1 - f$). Тогда по определению количество информации, которое связано с наблюдением этого события, равно $-\log_2 f$, а с его отсутствием $-\log_2(1 - f)$.

Энтропия — математическое ожидание количества информации: $H(f) = -f \log_2 f - (1 - f) \log_2(1 - f)$.

Тогда энтропия выборки относительно появления объекта класса C_i равна

$$\hat{H} = H(\frac{P}{P + N})$$

Энтропийная информативность (2)

$$\hat{H}(P,N) = H(\frac{P}{P+N})$$

Если взять только ту часть выборки, для которой предикат $\varphi(X)$ верен, то её энтропия равна $\hat{H}(p,n)$; вероятность появления объекта из этой части выборки — $\frac{p+n}{P+N}$. Для той части выборки, где предикат $\varphi(X)$ неверен, энтропия равна $\hat{H}(P-p,N-n)$, а её вероятность $\frac{P-p+N-n}{P+N}$. Тогда средняя энтропия всей выборки после получения значения предиката $\varphi(X)$ равна

$$IG = \hat{H}(P,N) - \frac{p+n}{P+N}\hat{H}(p,n) - \frac{P-p+N-n}{P+N}\hat{H}(P-p,N-n)$$

Чем больше это значение, тем больше информации даёт $\varphi(X)$

Можно доказать по формуле Стирлинга, что для больших выборок (больших P,N,p,n) энтропийная и статистическая информативности эквивалентны.

Случай множества классов

Все эти критерии легко обобщаются на случай многих классов. Например, для статистического критерия:

$$F = \frac{C_{P_1}^{p_1} C_{P_2}^{p_2} \ldots C_{P_M}^{p_M}}{C_{P_1+P_2+..+P_M}^{p_1+p_2+..+p_M}},$$

где число классов равно M.

Построение базовых предикатов по параметрам

Если параметр логического типа, то его значение само является предикатом: $\varphi(X)$: «сертифицирован ли товар X?» $\to \{true, false\}$;

Если параметр имеет конечное множество значений, то можно из каждого варианта сделать отдельный предикат: если у товара есть параметр «страна производства» с N возможными вариантами, то можно построить N предикатов вида $\varphi(X)$: «произведён ли товар X в России?» $\to \{true, false\}$;

Вопрос: как быть с численными параметрами вроде «цена», «скидка» и т.п.?

Построение базовых предикатов по параметрам

Если параметр логического типа, то его значение само является предикатом: $\varphi(X)$: «сертифицирован ли товар X?» $\to \{true, false\}$;

Если параметр имеет конечное множество значений, то можно из каждого варианта сделать отдельный предикат: если у товара есть параметр «страна производства» с N возможными вариантами, то можно построить N предикатов вида $\varphi(X)$: «произведён ли товар X в России?» $\to \{true, false\}$;

Вопрос: как быть с численными параметрами вроде «цена», «скидка» и т.п.?
Ответ: придётся делить их области определения на подмножества, попадание в каждое из которых делает истинным один предикат.

Численные предикаты

Вопрос: пусть параметр u принимает N разных значений. Сколько разных подмножеств, соответствующих предикатам, можно на нём построить?

Численные предикаты

Вопрос: пусть параметр u принимает N разных значений. Сколько разных подмножеств, соответствующих предикатам, можно на нём построить?
Ответ: каждое из N значений может входить или не входить в каждое из подмножеств, поэтому их число — это количество разных строк нулей и единиц длины N, т.е. 2^N.

Понятно, что перебирать все возможные варианты (ещё и для каждого численного параметра!) слишком долго. Проще всего сначала выделить базовые промежутки, в каждом из которых не более одного значения параметра $u_1, u_2, ..., u_N$, например:

- $v_0 : u < u_1$;
- $v_1 : u_1 \le u < u_2$;
- $v_2 : u_2 \le u < u_3$ и т.д.

Объединение базовых промежутков

Когда базовые промежутки построены, можно их объединять, чтобы сделать правила проще, а предикаты — информативнее. Пусть выбран конкретный метод расчёта информативности предиката $I(\varphi)$. Наращивание промежутков ведётся по следующим принципам:

- объединять только такие промежутки, чтобы общая информативность объединения превышала информативность каждого отдельного промежутка;
- объединять в основном промежутки, идущие подряд;
- если объединяются промежутки, не идущие подряд, то количество таких отдельных кусков лучше не делать слишком большим, иначе предикат станет слишком сложным для восприятия.

Оптимальное решение можно найти только полным перебором; обычно пользуются жадным алгоритмом.

Наращивание признаков

Другие варианты базового разбиения численных признаков (вместо промежутков):

- полупрямые: $u < u_1$, $u < u_2$, $u < u_3$ и т.д.;
- шары: $(u - u_1)^2 < R^2$, $(u - u_2)^2 < R^2$ и т.д.

Точно так же можно наращивать и предикаты, относящиеся к разным признакам — подходы те же, формулы те же, ограничения те же. Типичные методы объединения предикатов разных признаков — логические функции «И» / «ИЛИ» благодаря удобству восприятия таких объединений.